Analytics

Clase II

Julia Picabea

Marzo 2026

TRABAJO FINAL

Figure 1: Magic Quadrant for Data Science and Machine

2021

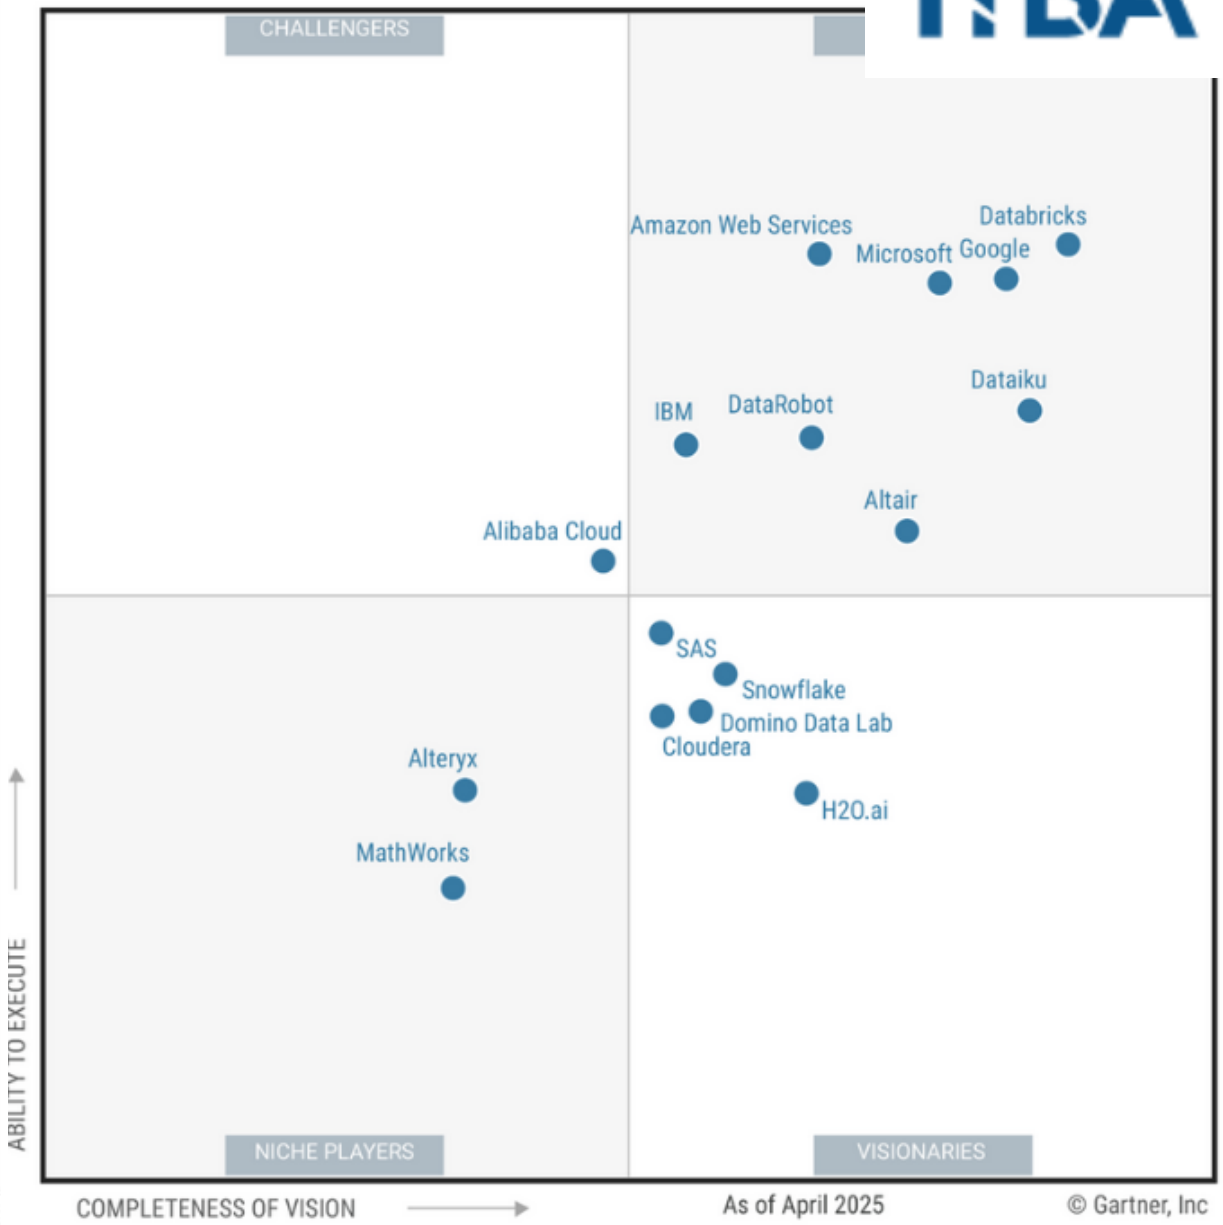

2025

Software

Paquetes:

- SPSS (Statistics-Modeler)
- SAS (Enterprise…)
- …

Libres

- ❑ **Python**
- ❑ R
- ❑ …

Google Colaboratory

Colab is a hosted Jupyter Notebook service that requires no setup to use and provides free access to computing resources, including GPUs and TPUs. Colab is especially well suited to machine learning, data science, and education.

Open Colab | New Notebook

Algunas métricas de negocio

- Indicadores de desempeño.
- Ayudar a tomar mejores decisiones.

HIGH LEVEL

MARKET SHARE
CHURN

MARKETING

CONVERTION RATE
CONTACT RATE
DROP RATE

RRHH

RETENTION RATE

VENTAS

ACCURACY – BIAS
REVENUE

Otras métricas

¿Y si trabajo con datos no numéricos?

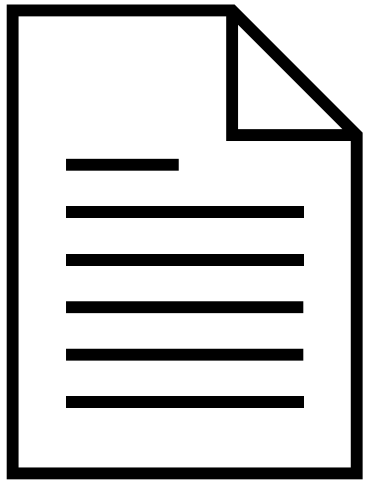

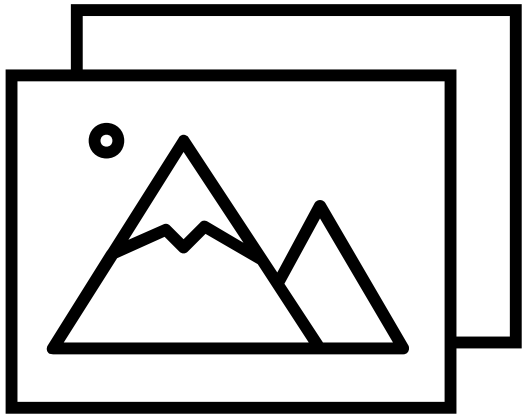

Texto - Imágenes

Otras métricas

- Levenshtein
- ROUGE

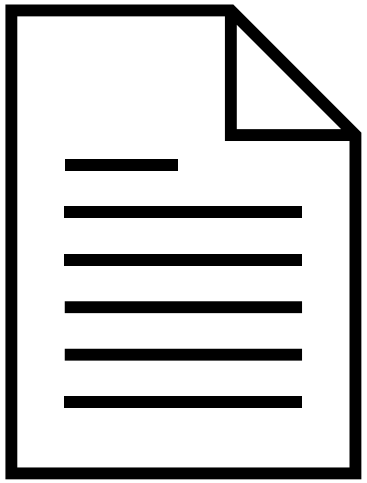

Texto

Levenshtein

picotea@hotmial.com

Levenshtein

picotea@hotmial.com

DOMINIOS EMAIL
@gmail.com
@hotmail.com
@yahoo.com
@itba.edu.ar
.....
.....

Algunas métricas de negocio

HIGI

MARI
C

NG

RATE
ATE
TE

R

RETEN

S

BIAS
E

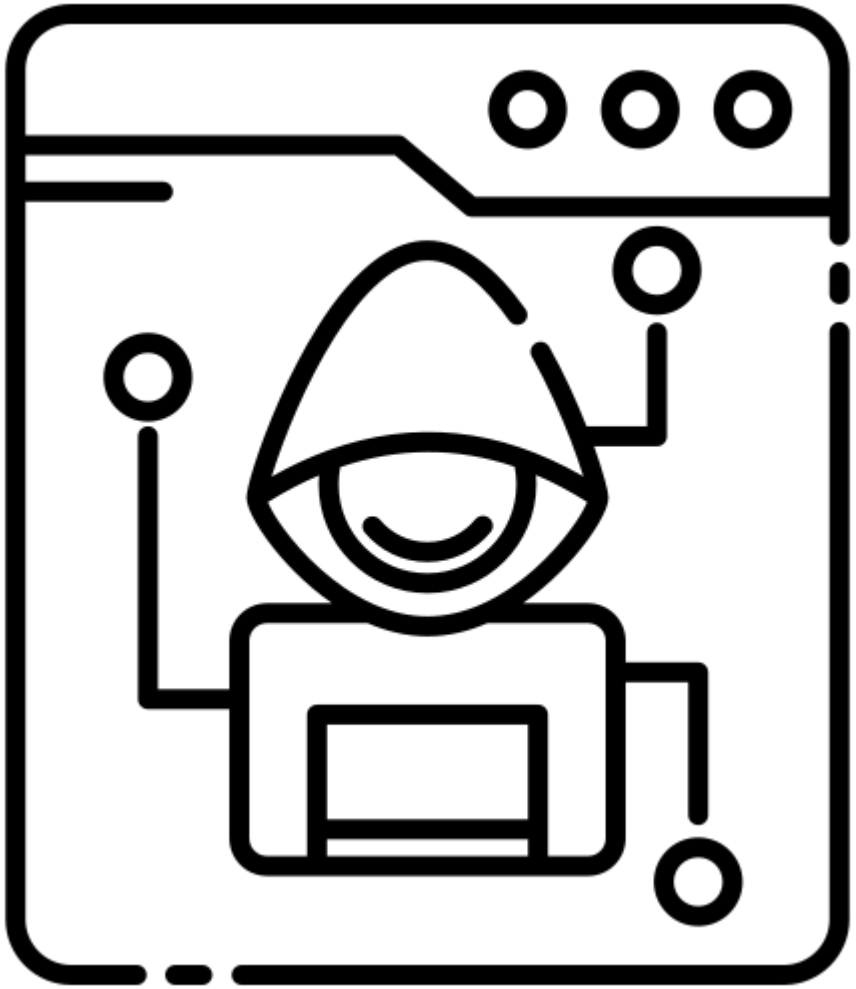

GOODHART'S LAW

- Si solo mido el Bias, puedo dejar de vender.

- $Bias = \frac{Pred - Real}{Real}$ $\quad Bias = \frac{Pred - Real}{Pred}$

- Si solo miro el Drop rate, mostrar menos la página.

$$DR = \frac{cuantos\ se\ van}{total\ que\ llegan\ a\ la\ pagina}$$

GOODHART'S LAW

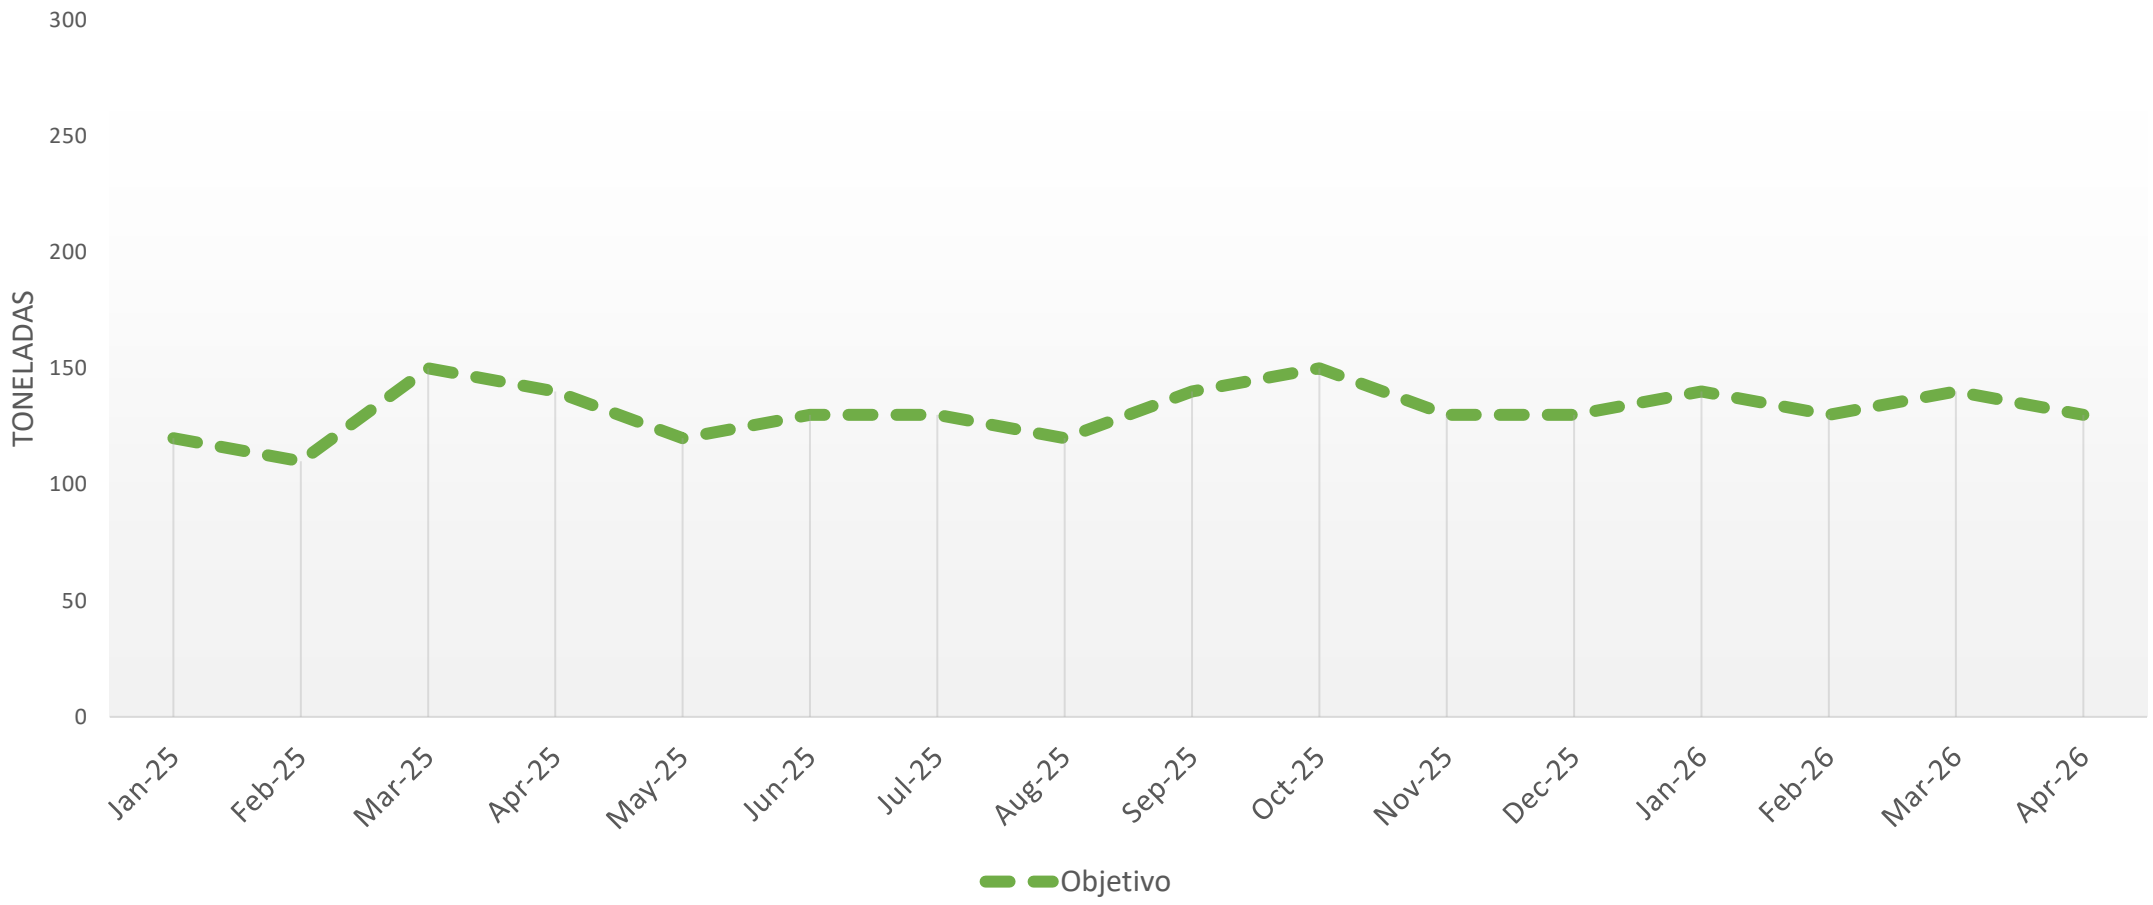

GOODHART'S LAW

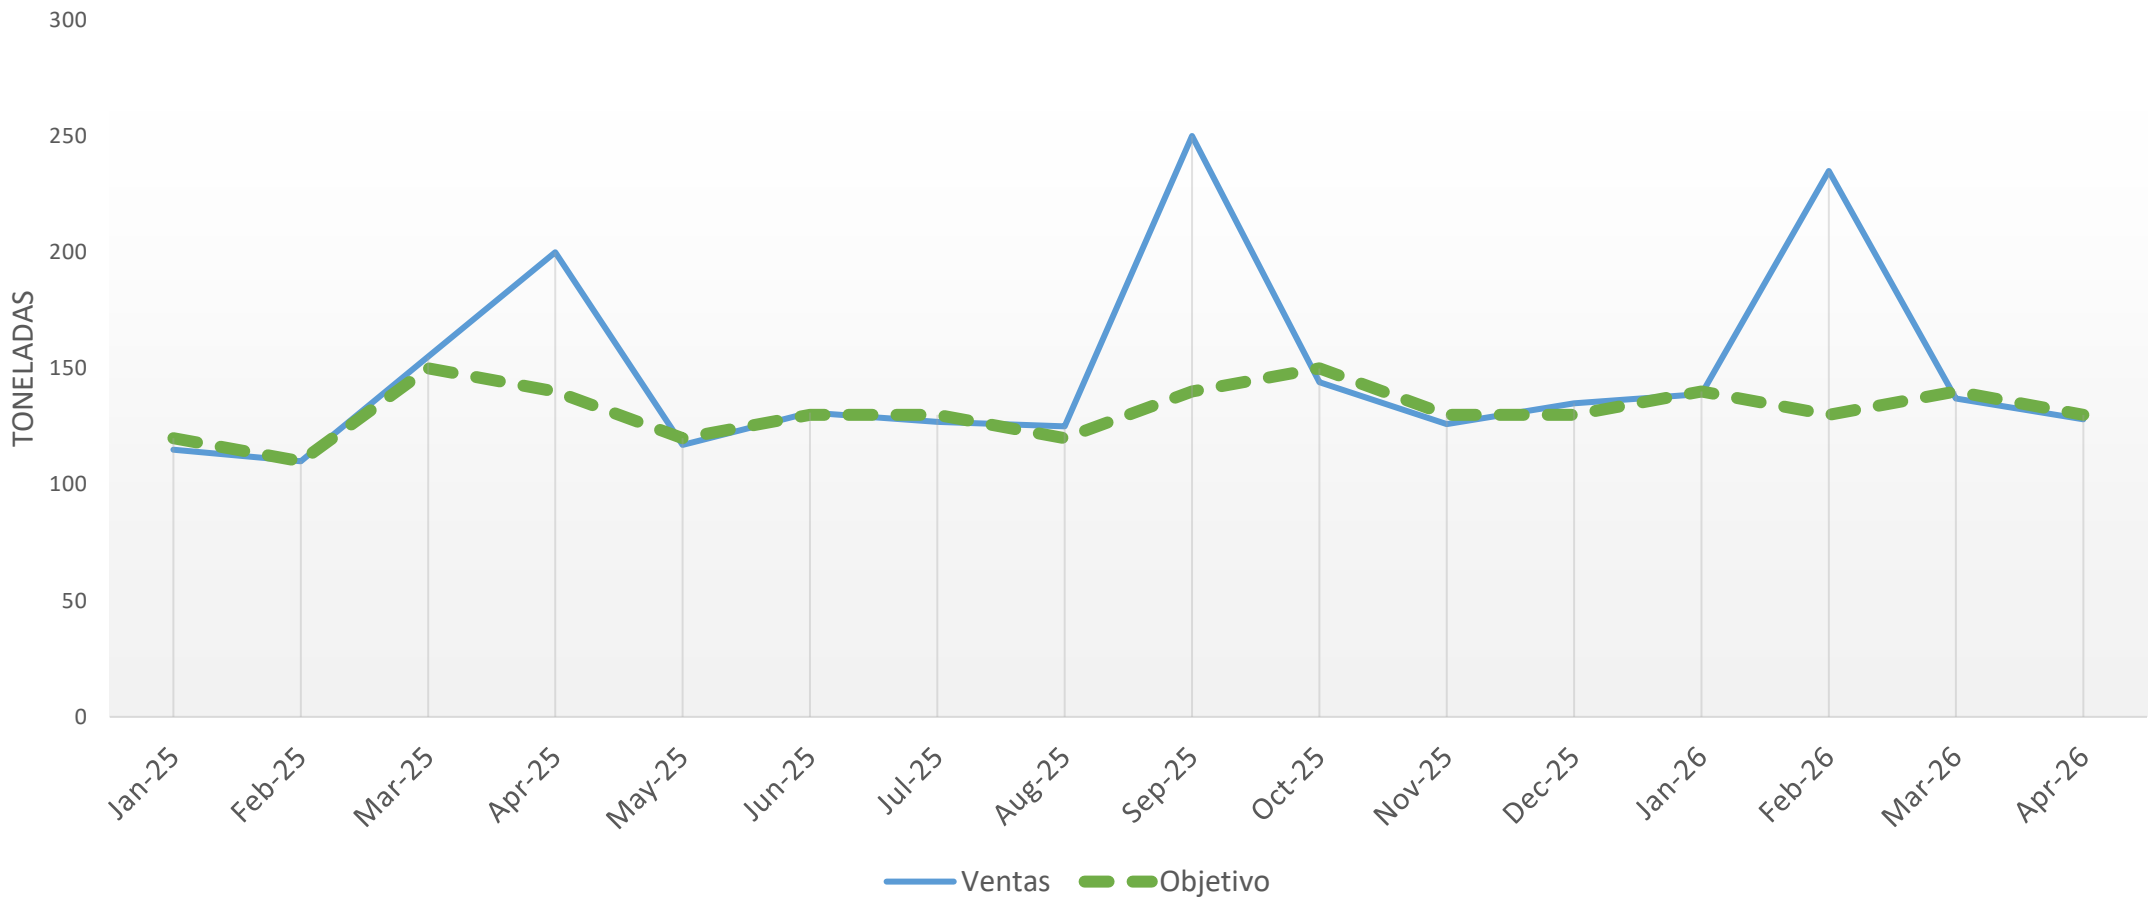

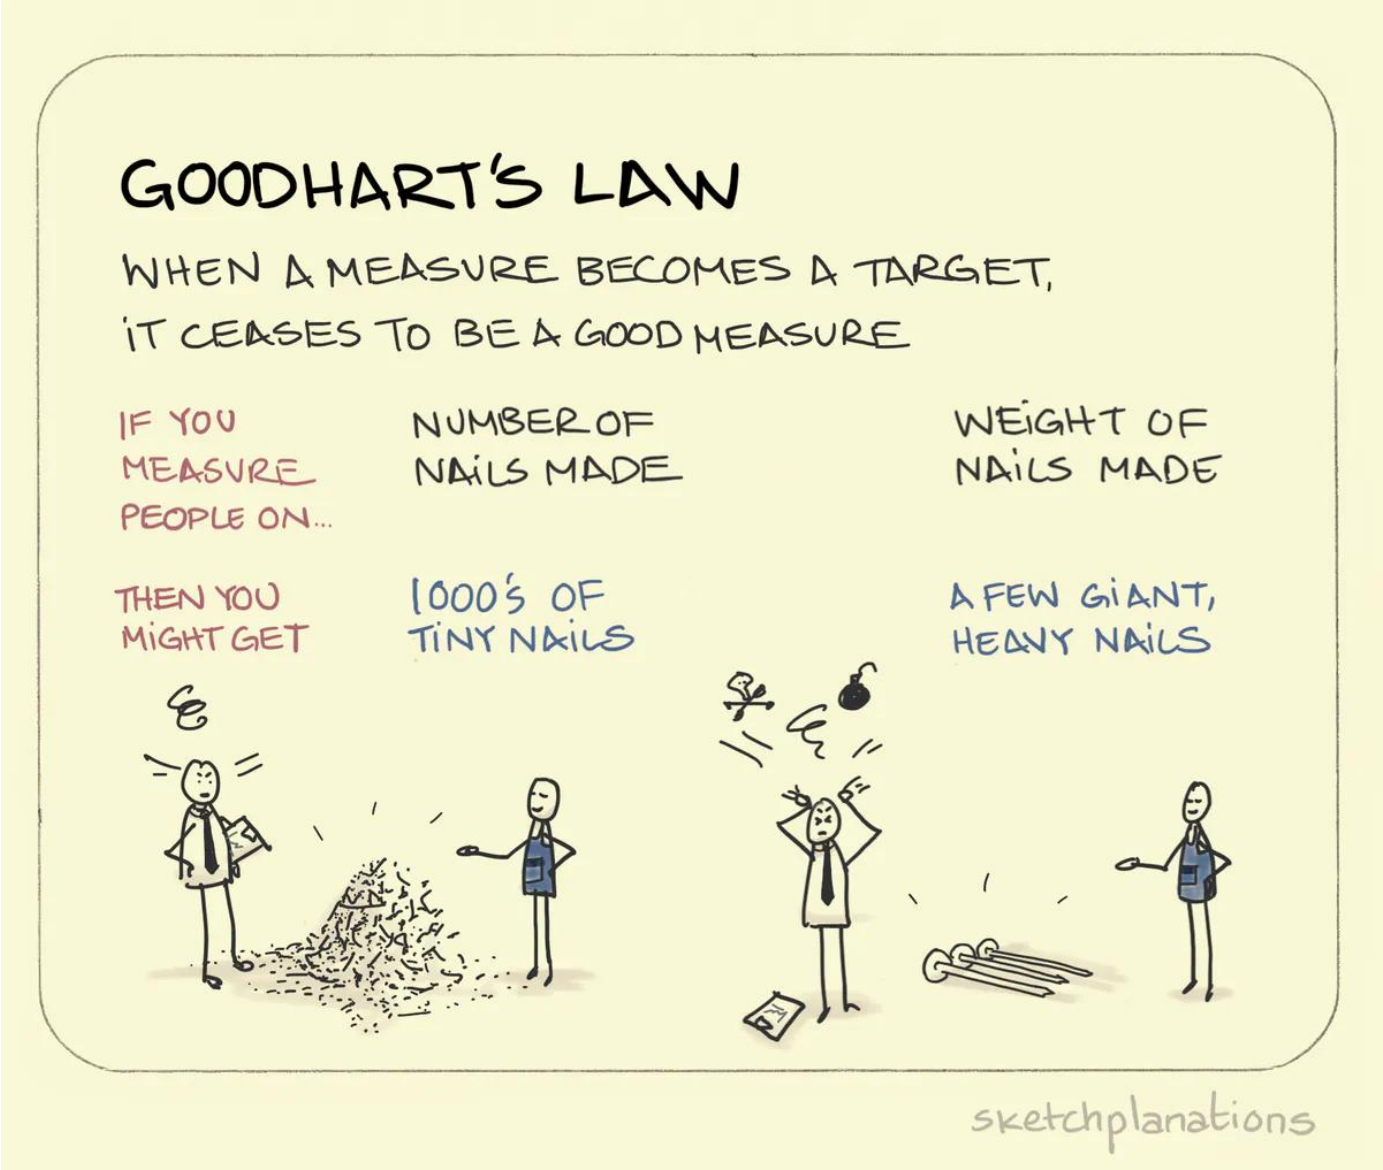
GOODHART'S LAW
WHEN A MEASURE BECOMES A TARGET, IT CEASES TO BE A GOOD MEASURE
IF YOU MEASURE PEOPLE ON...
NUMBER OF NAILS MADE
WEIGHT OF NAILS MADE
THEN YOU MIGHT GET
1000'S OF TINY NAILS
A FEW GIANT, HEAVY NAILS
sketchplanations

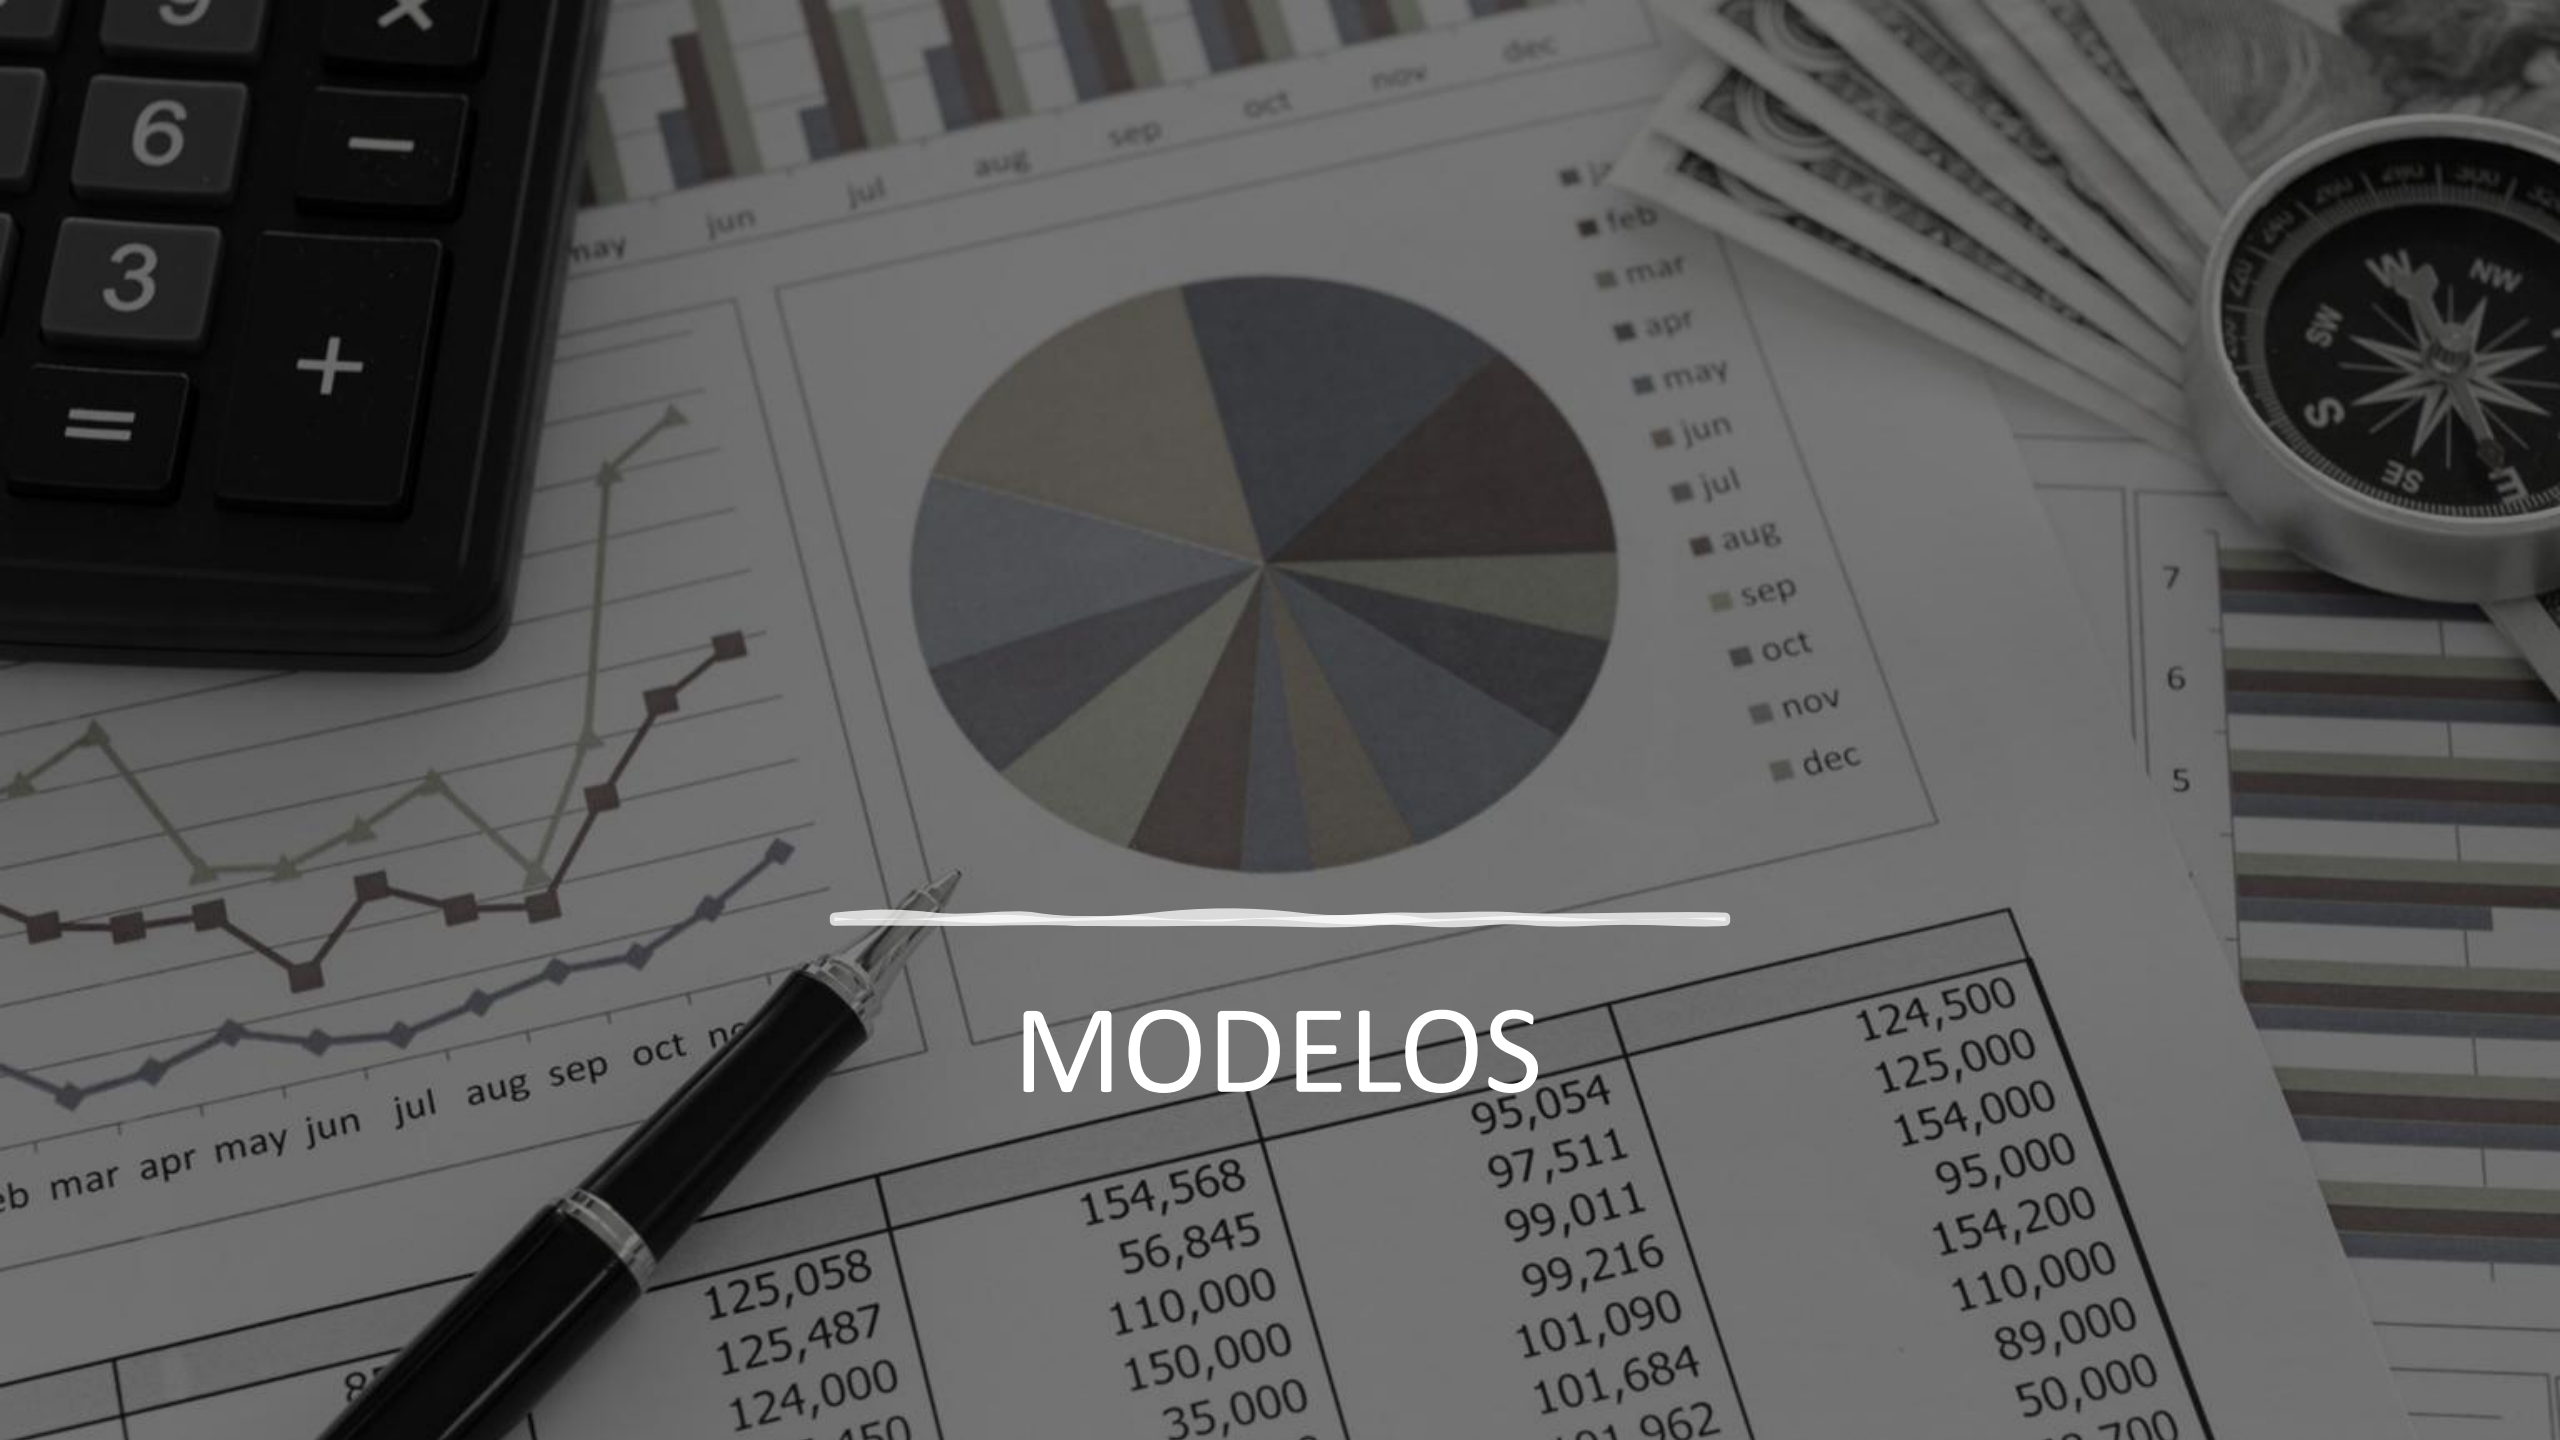
feb
mar
apr
may
jun
jul
aug
sep
oct
nov
dec
125,058
125,487
124,000
154,568
56,845
110,000
150,000
35,000
95,054
97,511
99,011
99,216
101,090
101,684
124,500
125,000
154,000
95,000
154,200
110,000
89,000
50,000

MODELOS

Modelos

- Clases de modelos
- Como medir si un modelo es bueno
- Algunos algoritmos usados

- Conocer los datos
- Definir el problema

- Análisis de datos
- Modelado

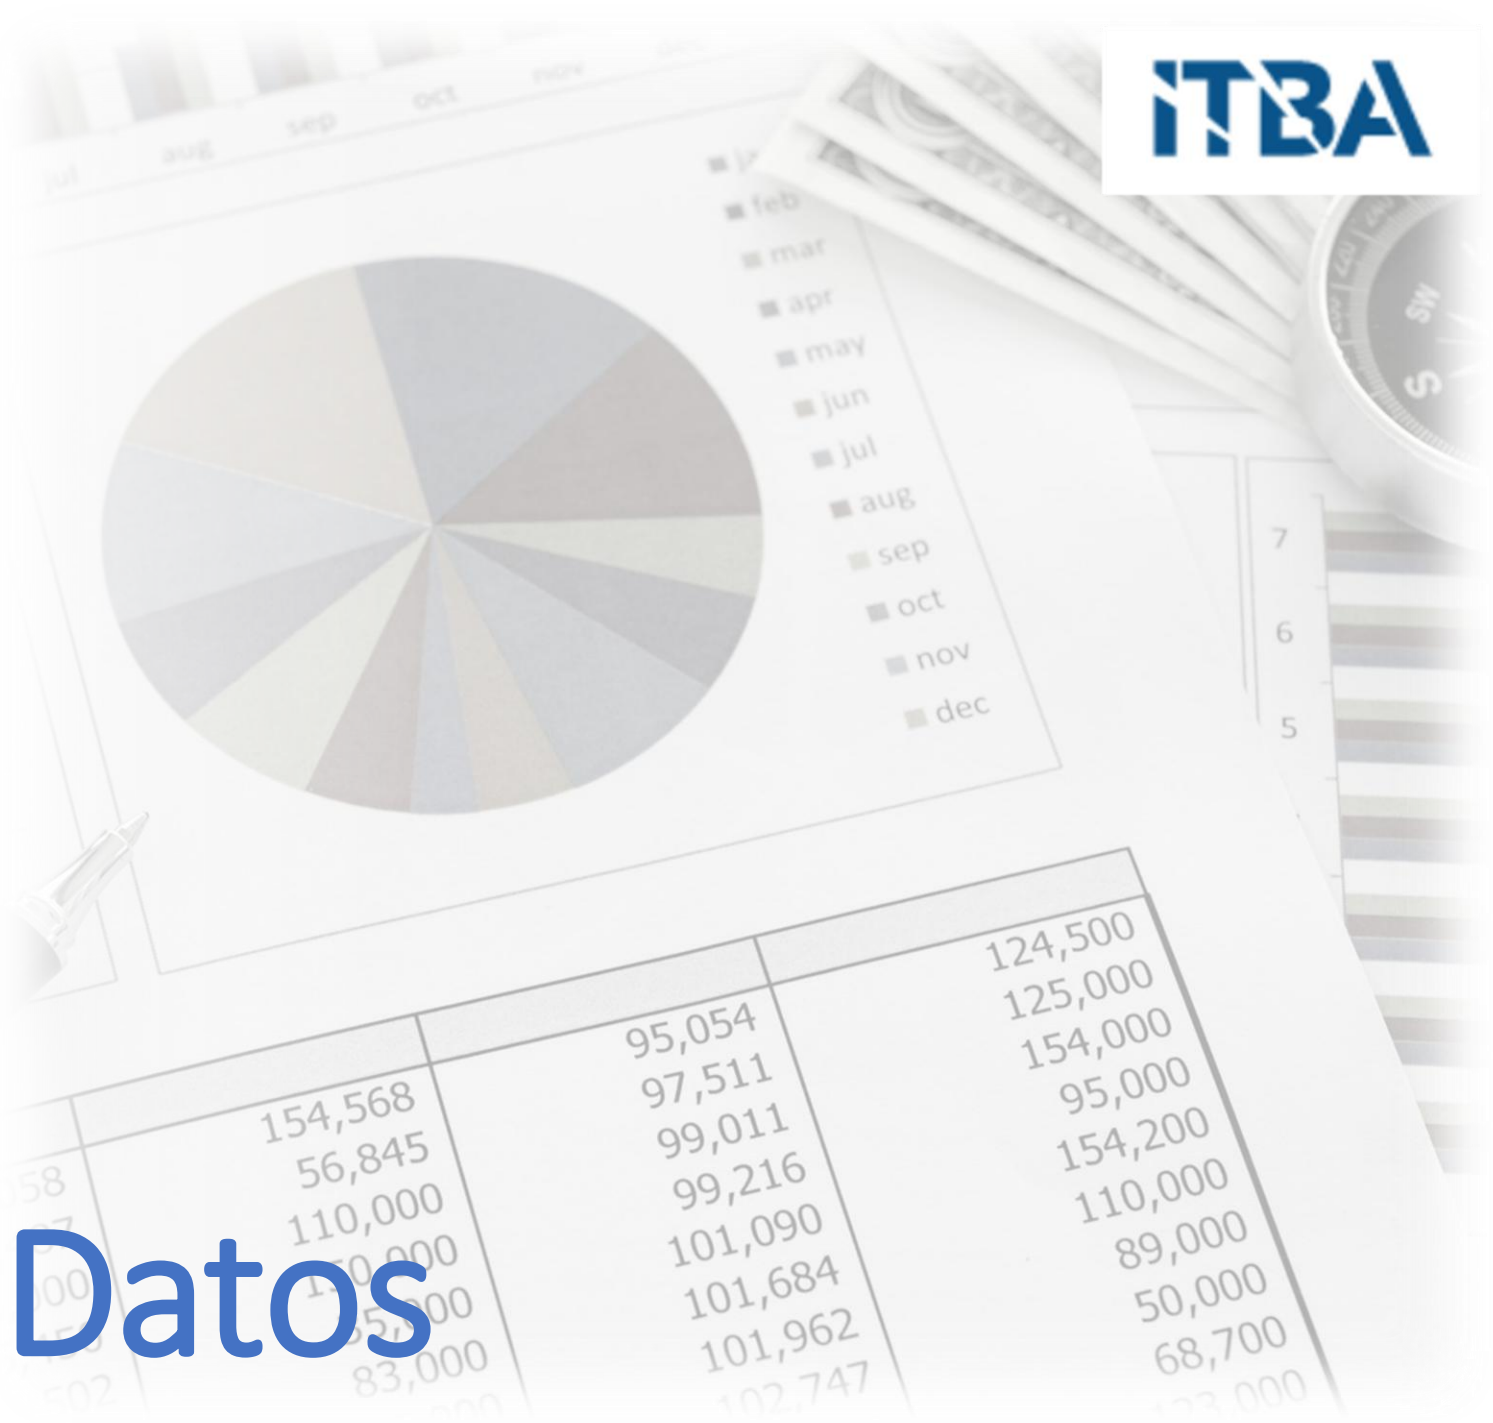

Datos

REDUCIR MI INFORMACIÓN

PREDECIR

CLASIFICACIÓN

CLUSTERING

GENERATIVOS

Definir el problema

Reducir

Reducir mi información – Achicar mi problema

Visualizar los datos

Extraer información

- PCA - Componentes Principales.

Modelos predictivos

Predecir comportamientos

- Regresión Logística
- Series de tiempo
- Arboles de decisión

Clasificación - Clustering

Agrupar clientes/productos/… con características similares:

- K-medias
- Arboles de decisión

Generativos

Creación de contenido:

- Descripciones para e-commerce
- Búsqueda de contenido de documentos
- Análisis de interacciones (CX)

Tipos de modelos

- Clasificación
- Cluster
- Score
- Outliers
- Forecasting

Tipos de modelos

Clasificación	Clasificar datos en categorías
Cluster	
Score	
Outliers	
Forecasting	

Tipos de modelos

Clasificación	
Cluster	Agrupar datos parecidos. Entender comportamientos
Score	
Outliers	
Forecasting	

Tipos de modelos

Clasificación	
Cluster	
Score	Ordena los datos según un criterio
Outliers	
Forecasting	

Tipos de modelos

Clasificación	
Cluster	
Score	
Outliers	Encuentrar datos que están fuera de rango
Forecasting	

Tipos de modelos

- Clasificación
- Cluster
- Score
- Outliers
- Forecasting — Predecir una serie

Tipos de aprendizaje

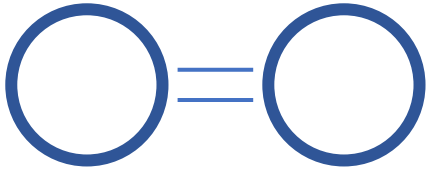

Supervisado

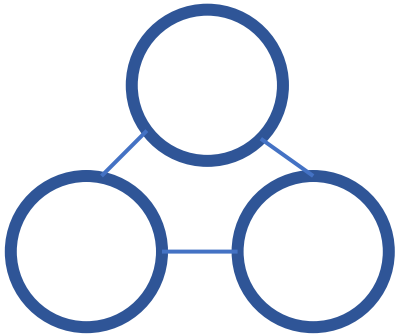

No supervisado

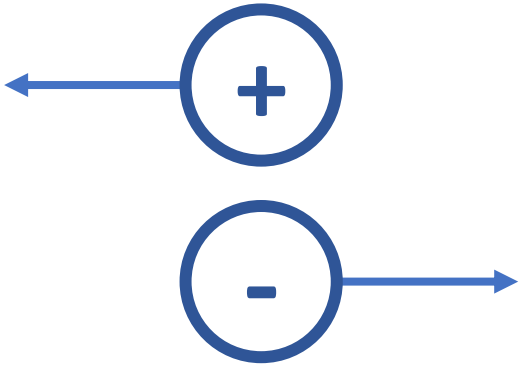

Por Refuerzos

	SUPERVISADO	NO SUPERVISADO
Objetivo	Predecir salidas para datos nuevos.	Encontrar estructura en los datos.
Aplicaciones	Marketing personalizado. Sentiment Analysis. Churn/Atrition.	Detección de anomalías. Agrupar comportamientos parecidos.
Complejidad		Suelen se mas complejos.
Contras	Dependen de los datos de entrada.	Difíciles de interpretar y pueden no se explicativos.
	Árboles de decisión Modelos de regresión	PCA K-medias

- A veces la situación determina el método que voy a utilizar.
- Generar hipótesis iniciales.
- A veces el aprendizaje puede empezar siendo no supervisado y mutar con el tiempo a un modelo supervisado.

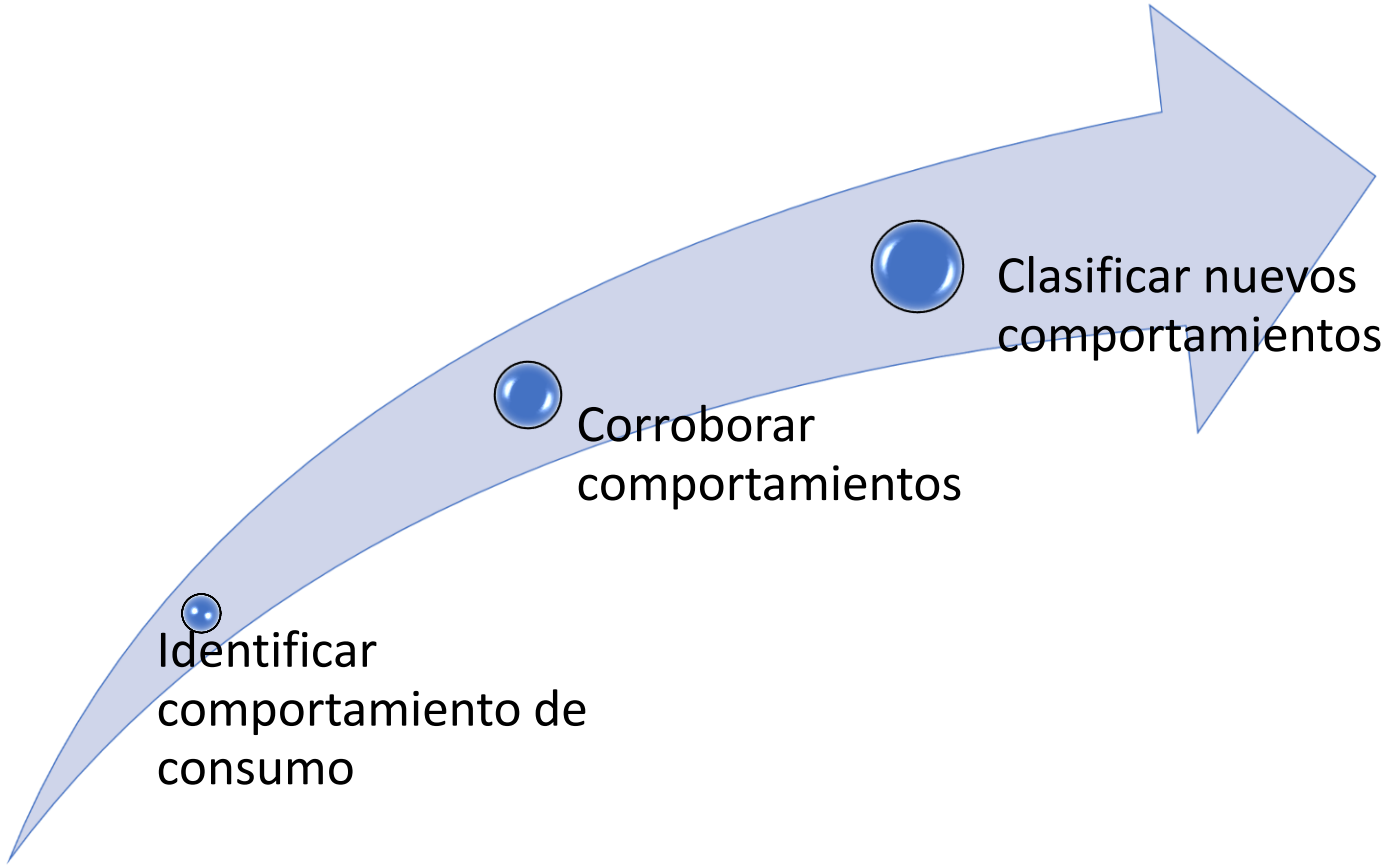

INTERPRETABILIDAD Y FLEXIBILIDAD

Que tan fácil es interpretar las decisiones del modelo

Que tan bien se adapta a datos "difíciles"

Interpretabilidad

Flexibilidad

Modelos supervisados

- ***Aprenden*** de los datos.
- Importante ***enseñarle*** con datos buenos
- Es mas fácil evaluar a priori si un modelo es bueno o no

Sobreajuste

- Memorizar vs generalizar.
- La meta de los modelos es predecir nuevos datos.
- El modelo aprende los detalles y el ruido de los datos.
- Aprende los detalles de los datos de entrenamiento pero no las generalidades para predecir nuevos

Sobreajuste

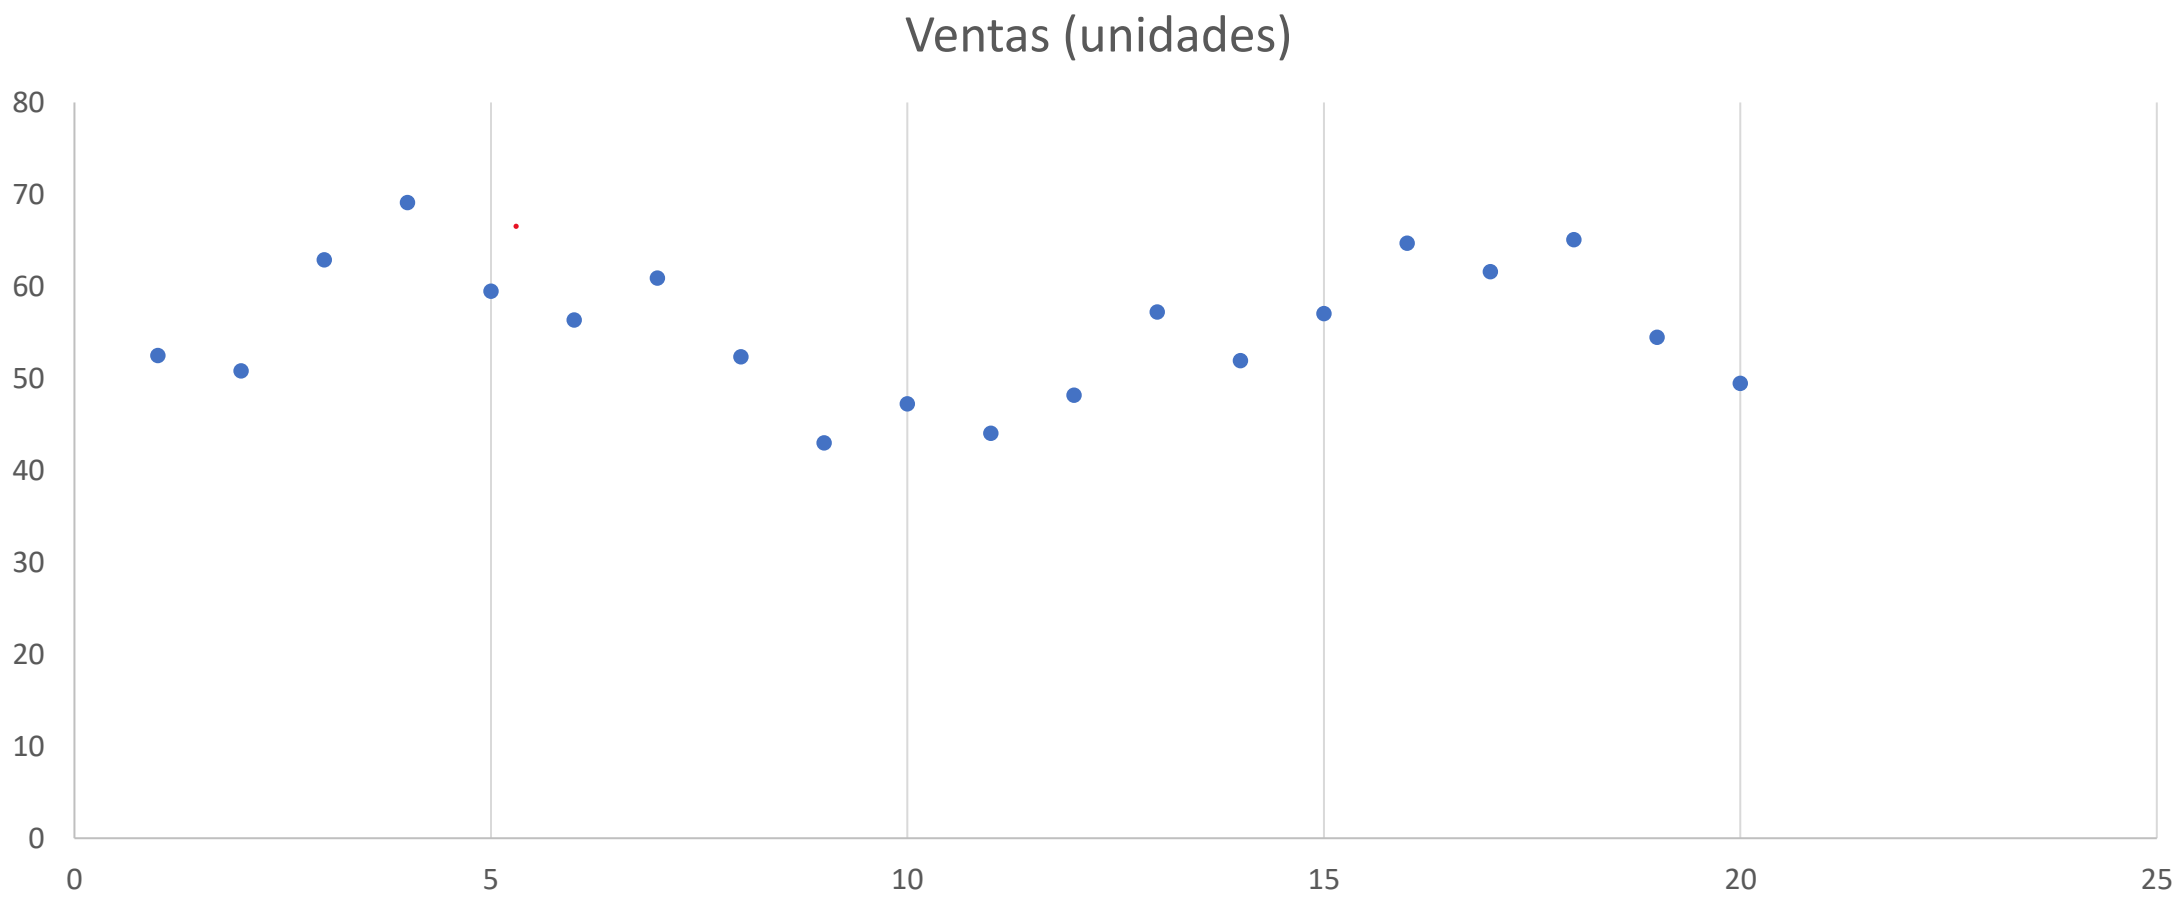

Sobreajuste

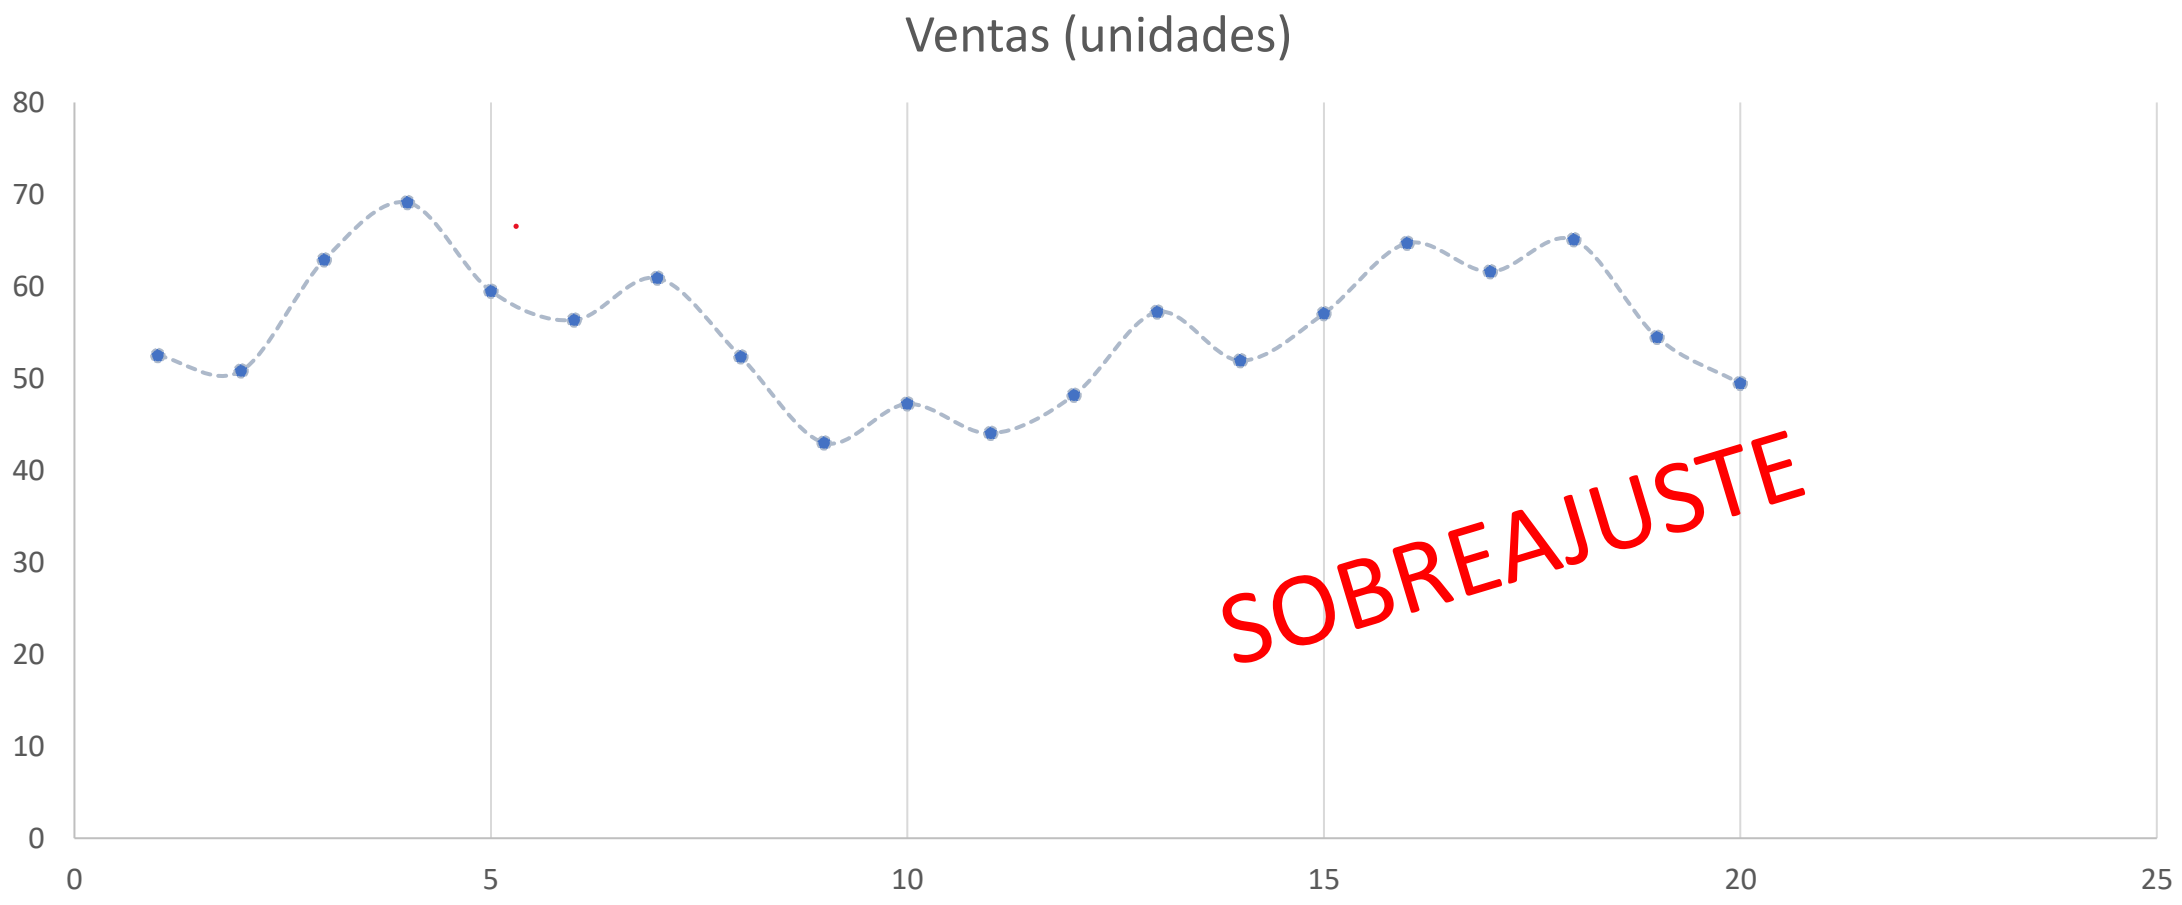

Sobreajuste

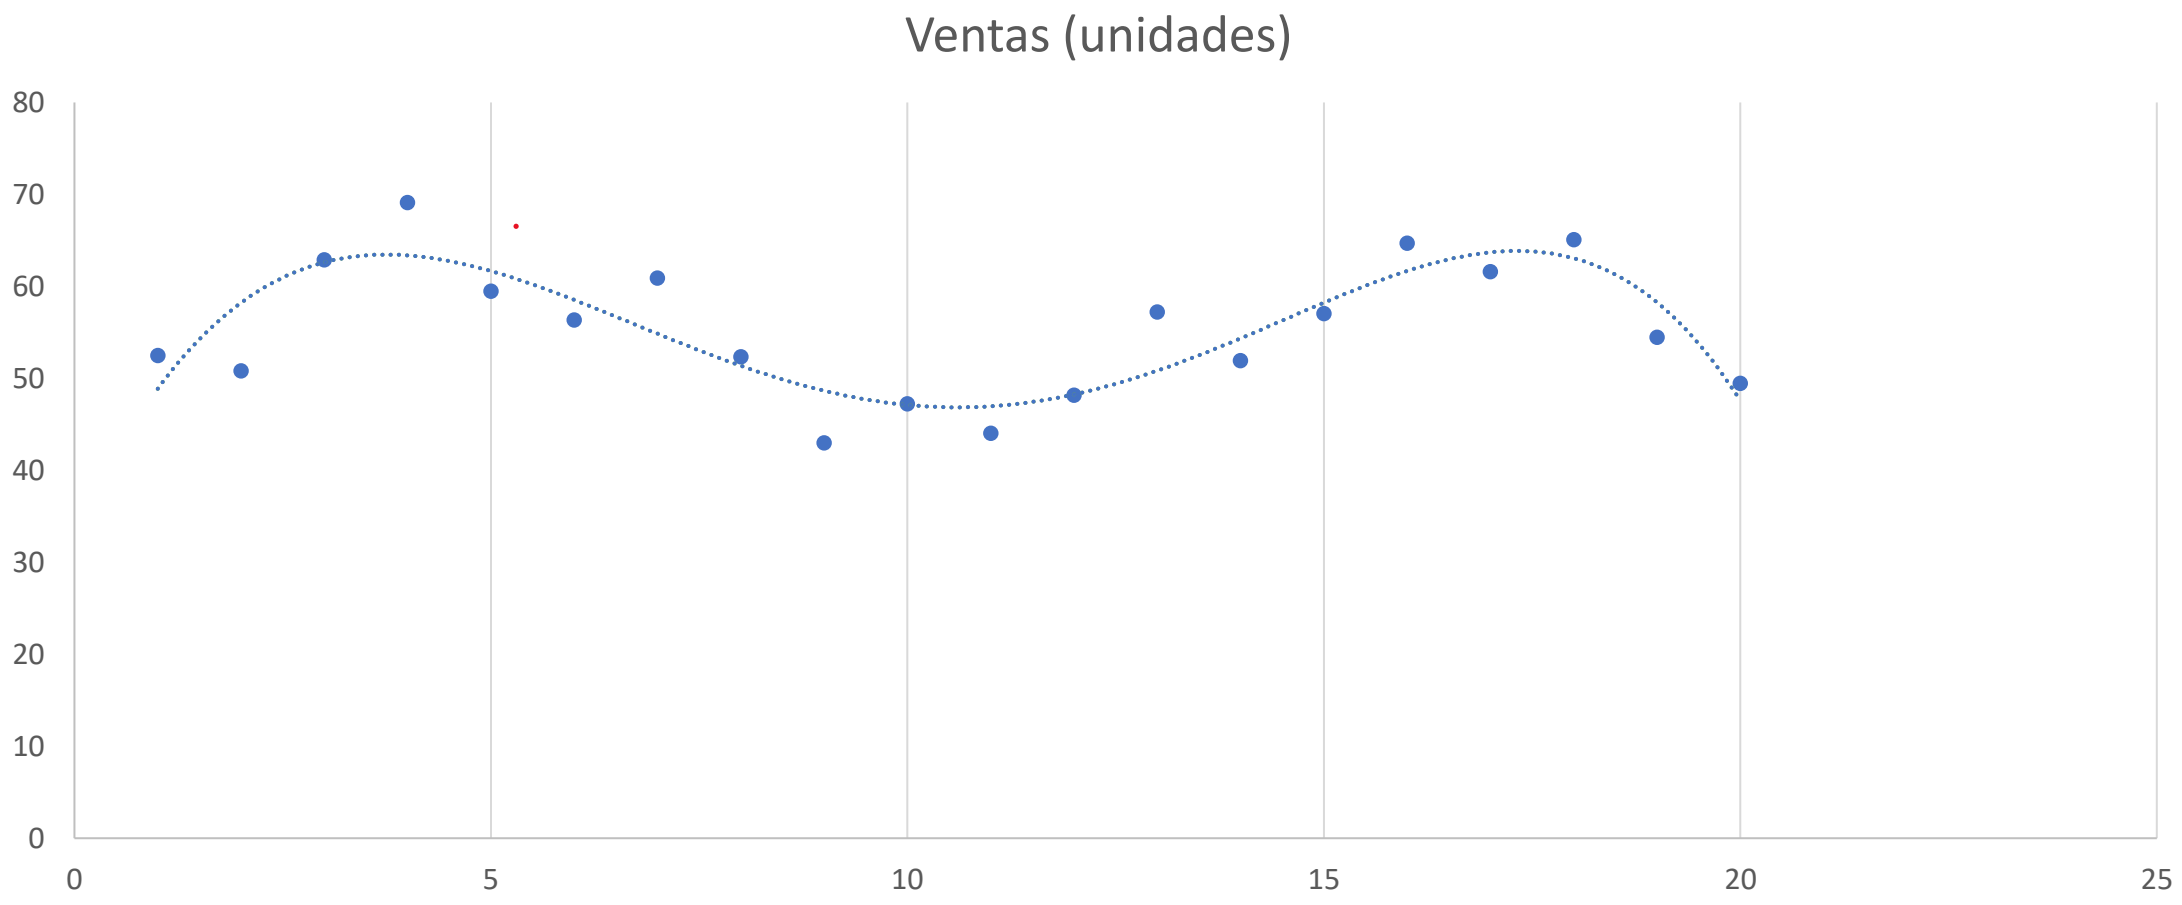

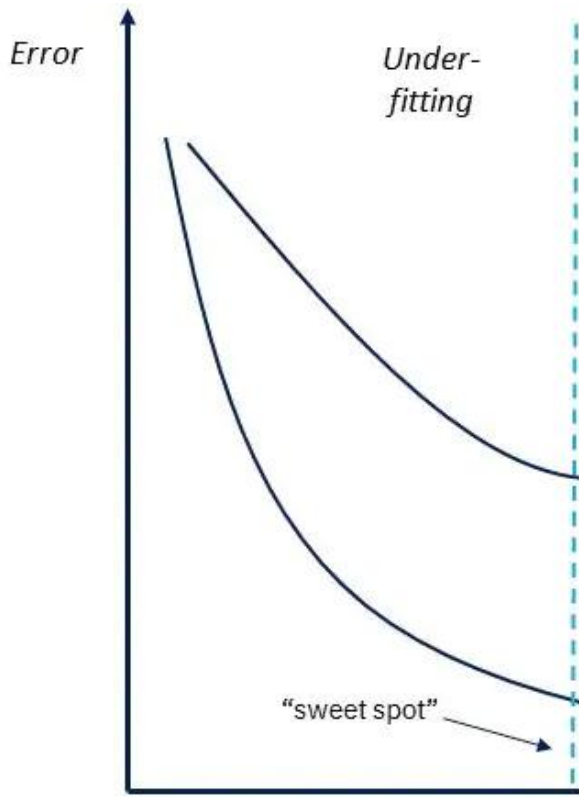

Eje X =complejidad del modelo

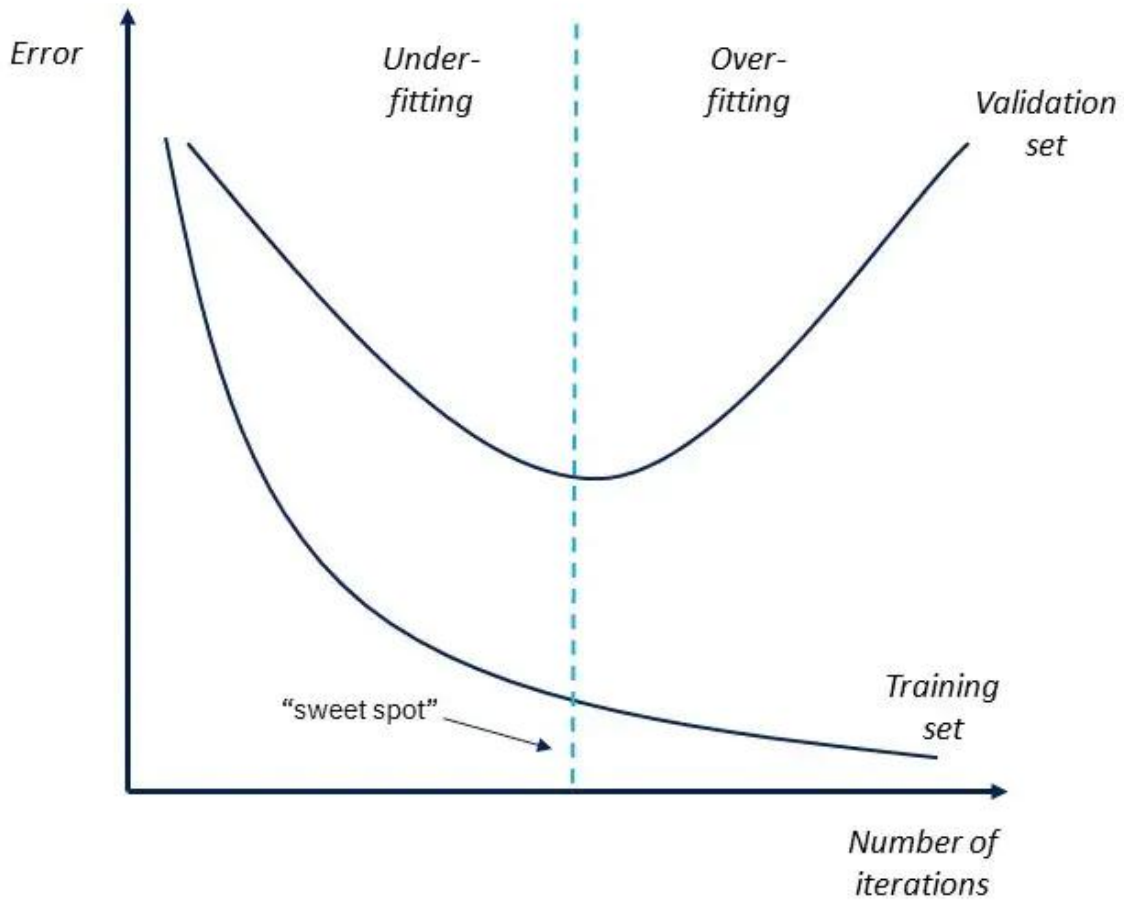

Eje X =complejidad del modelo

THE BEST WAY TO
EXPLAIN OVERFITTING

Modelos robustos

Si un modelo da muy bien, DESCONFIA.

Maneras de evitar sobreajuste:

- Train y Test data
- Crossvalidation

Regularización: lo que aporta un nuevo término tiene que ser suficiente para compensar lo que aumenta en complejidad.

Train - Test

Se separan los datos en dos o tres conjuntos

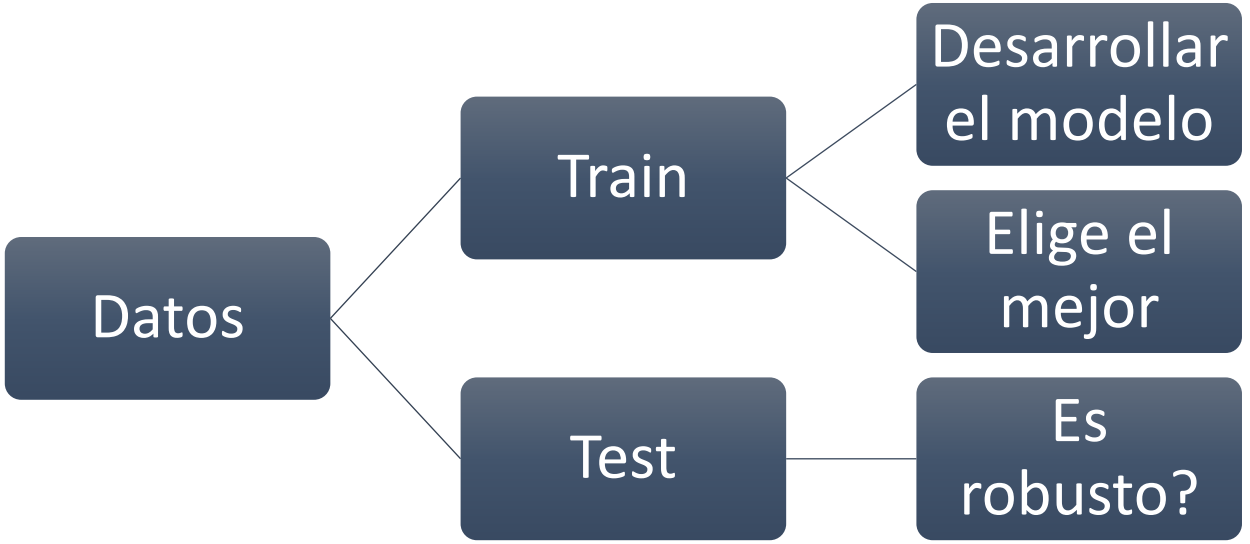

El modelo tiene que dar parecido en los datos del Test a lo q dio en con el entrenamiento

Train - Test

Se separan los datos en dos o tres conjuntos

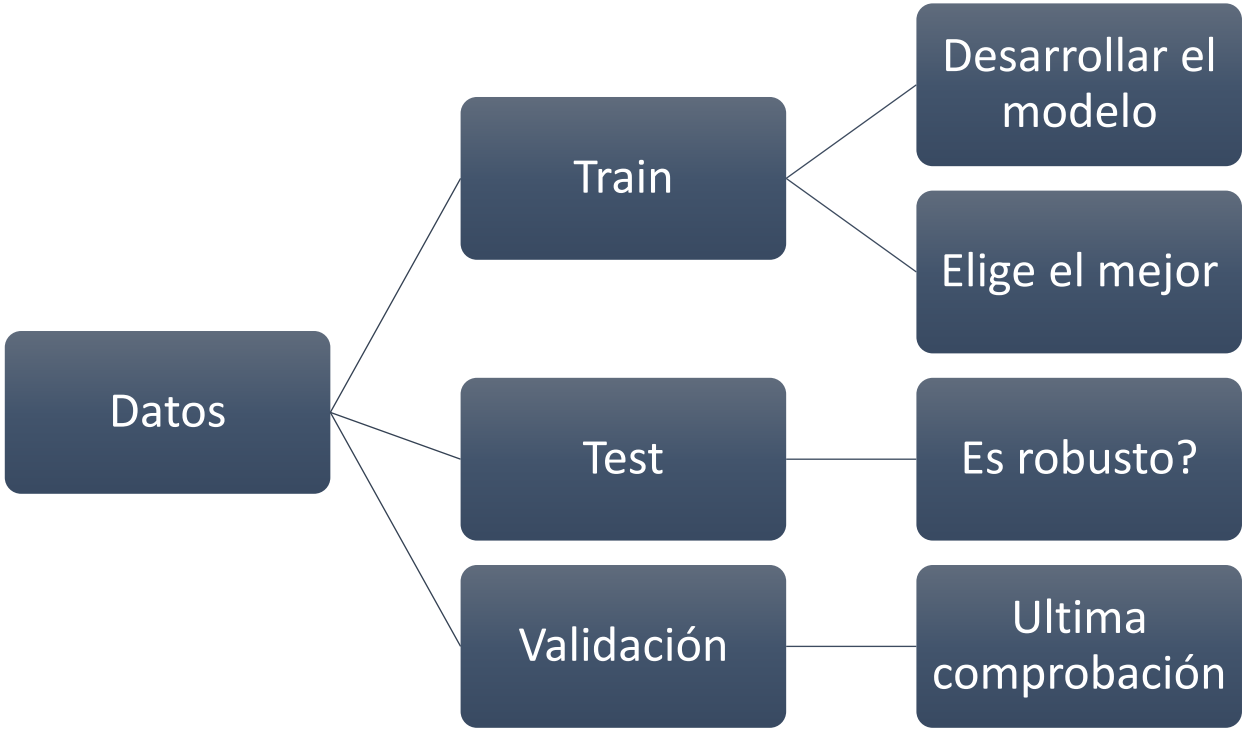

El modelo tiene que dar parecido en los datos del Test a lo q dio en con el entrenamiento

Crossvalidation

Procesos de “resampleo” para evaluar modelo

- Armar k (k=5) grupos
- Para cada grupo, juntar el resto en un conjunto de entrenamiento

- Grupo elegido como conjunto de validación

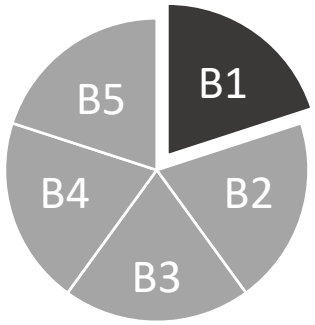

GIGO

Garbage in Garbage out

Limpieza de datos

Distintos tipos de data requieren distintas limpiezas

Valores faltantes
Entradas inconsistentes
Fechas y time
Escalado y normalización
Outliers

No existe datos perfectamente limpios!

If Data Science is the sexiest job of the 21st century, data cleaning is the most unsexy part of data science

Gobernanza de datos

Los datos no se gestionan solo con tecnología, sino con estructuras de poder y responsabilidad.

- Regulaciones para el almacenamiento y uso de info.
- Ley de protección de datos personales.
- Blacklists.

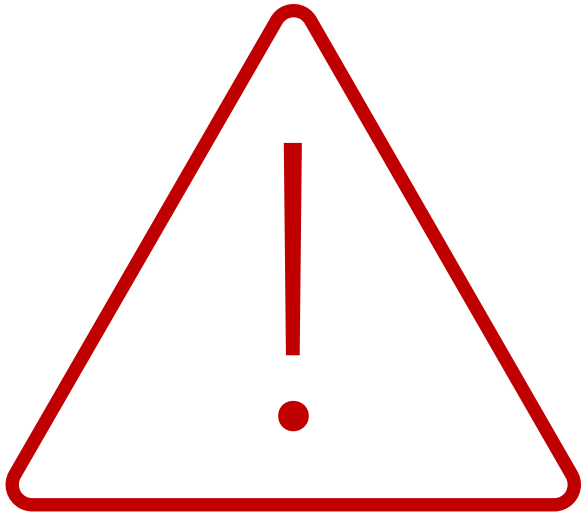

¿Por qué hablar de gobernanza?

- Toman decisiones basadas en datos
- Automatizan procesos con algoritmos
- Están sujetas a regulaciones (ej: **GDPR, AI Act, CCPA**)
- Intercambian datos con terceros

SIN GOBERNANZA

- Hay duplicados e inconsistencias
- No se sabe quien es el responsable
- Aumenta el riesgo legal (y reputacional)
- Se pierde valor económico

Fallas en gobernanza

- Neerlandes - Fraude en ayudas sociales (2016)

“AI was allegedly able to use information that has no legal importance in decision making, such as sex, religion, ethnicity, and address.”

- Snowflake (2024):

“No fue solo un ataque externo, sino configuraciones incorrectas de acceso, falta de control de credenciales y ausencia de políticas de acceso uniforme en entornos cloud”

¿Cómo evaluar los resultados?

¿Cómo evaluar los resultados?

Uso el modelo para una campaña de venta de un producto.

Resultado de la campaña 30%

- ❑Es buen resultado?
- ❑Mejore?

A/B testing

Grupos de control

Matriz de confusión

Accuracy

Precision

Recall

F1 Score

Curva ROC

AUC

ROUGE

A/B testing

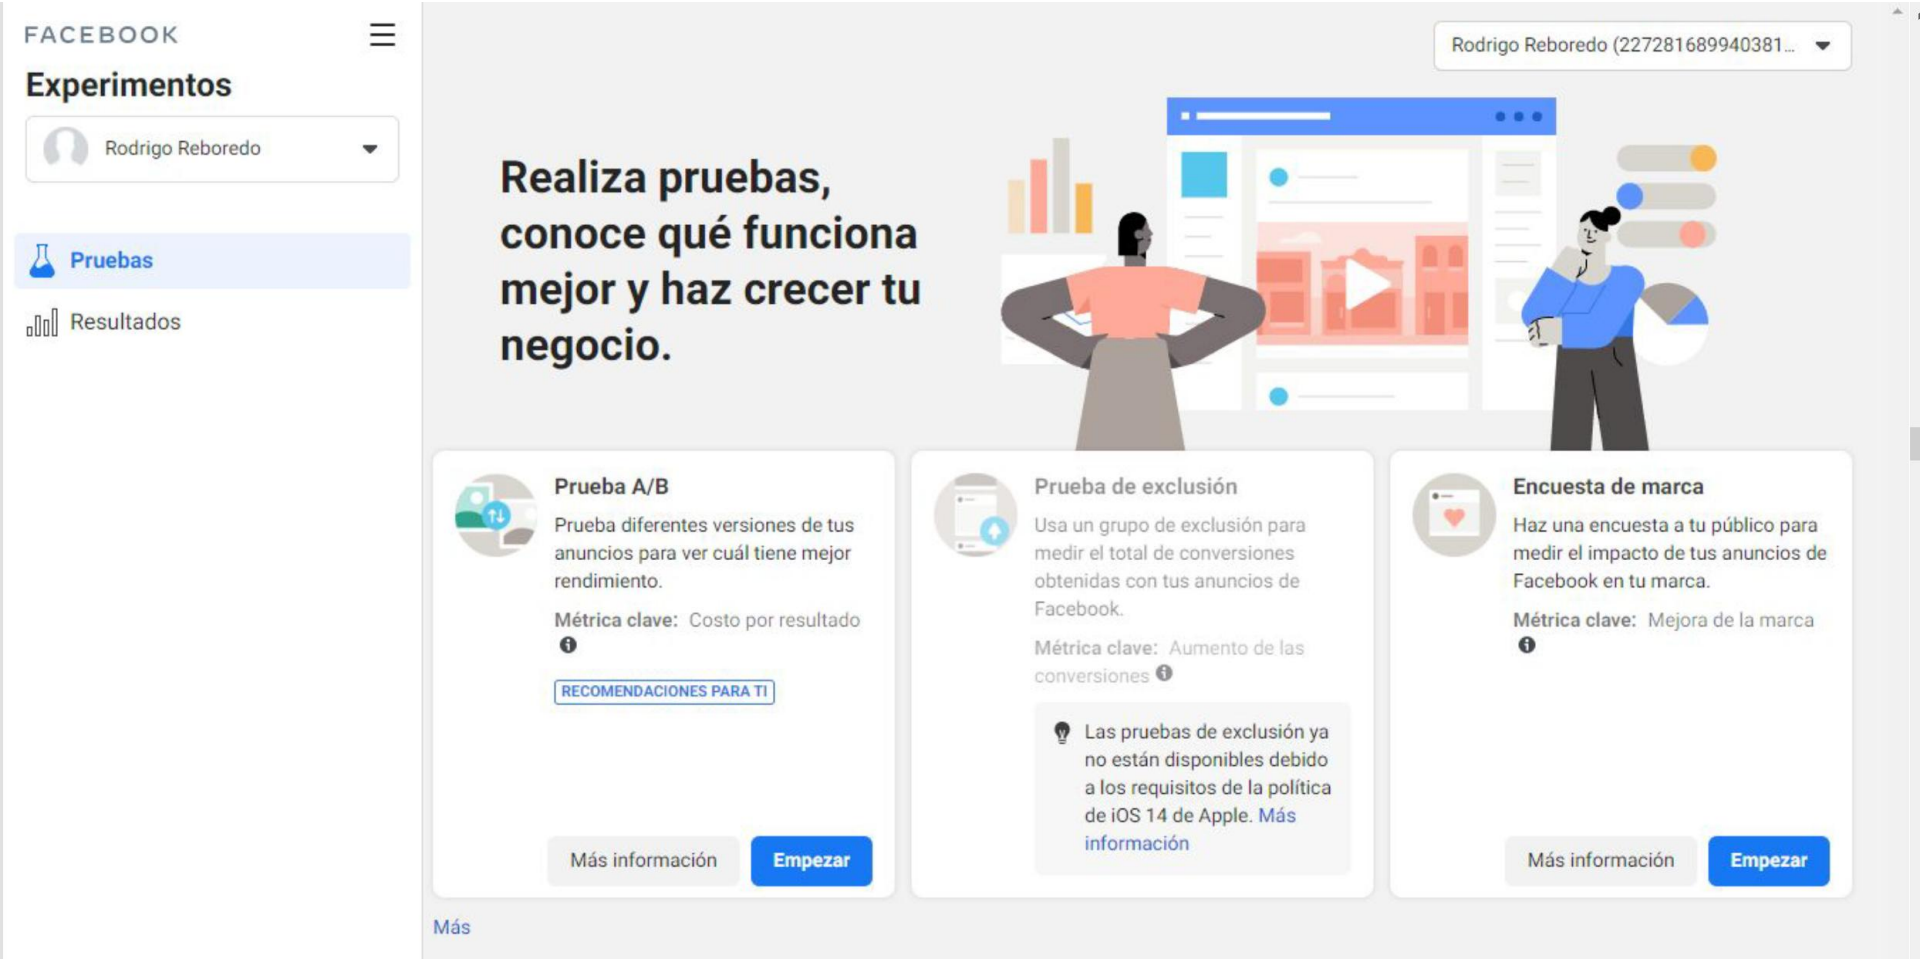
FACEBOOK
Experimentos
Rodrigo Reboredo
Pruebas
Resultados
Rodrigo Reboredo (227281689940381...
Realiza pruebas, conoce qué funciona mejor y haz crecer tu negocio.
Prueba A/B
Prueba diferentes versiones de tus anuncios para ver cuál tiene mejor rendimiento.
Métrica clave: Costo por resultado
RECOMENDACIONES PARA TI
Más información
Empezar
Prueba de exclusión
Usa un grupo de exclusión para medir el total de conversiones obtenidas con tus anuncios de Facebook.
Métrica clave: Aumento de las conversiones
Las pruebas de exclusión ya no están disponibles debido a los requisitos de la política de iOS 14 de Apple. Más información
Encuesta de marca
Haz una encuesta a tu público para medir el impacto de tus anuncios de Facebook en tu marca.
Métrica clave: Mejora de la marca
Más información
Empezar
Más

¿Como medir los resultados?

Poner el modelo “a prueba”.

- Grupo de control

Mejor que el azar?

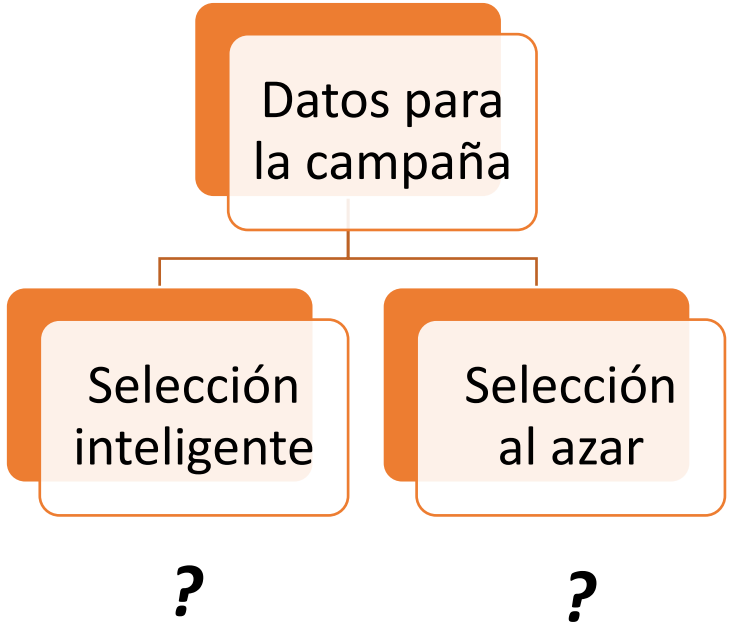

Campaña

- Quiero identificar quien va a sacar el producto y quien otra cosa.
- Tengo plata para hacer una campaña pero no quiero gastar en lo que no me van a sacar el producto.
- Quiero encontrar quienes cometen fraude.

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

Campaña

- PRESICION: Quiero que el modelo prediga correctamente los positivos. No prediga positivos de mas. Segunda columna.

- RECALL: Quiero identificar los positivos reales. Ni me importan los negativos reales. Segunda fila.

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

Matriz de confusión

PREDICCION

REAL

	Grupo 0 No fraude	Grupo 1 Fraude
Grupo 0 No fraude	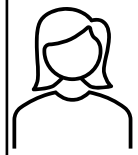	
Grupo 1 Fraude		

Matriz de confusión

PREDICCION

REAL

	Grupo 0 No fraude	Grupo 1 Fraude
Grupo 0 No fraude	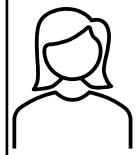 Verdadero Negativo	Falso Positivo
Grupo 1 Fraude	Falso Negativo	Verdadero Positivo

Matriz de confusión

PREDICCION

REAL

	Grupo 0 Negativo	Grupo 1 Positivo
Grupo 0 Negativo	Verdadero Negativo	Falso Positivo
Grupo 1 Positivo	Falso Negativo	Verdadero Positivo

Accuracy – Recall - Precision

PREDICCION

REAL

	Grupo 0 Negativo	Grupo 1 Positivo
Grupo 0 Negativo	Verdadero Negativo	Falso Positivo
Grupo 1 Positivo	Falso Negativo	Verdadero Positivo

Accuracy
Total bien predichos

Recall
Miro lo positivos reales y veo cuales predije bien

Presicion
Miro lo que predije positivos y veo cuantos son positivos

Accuracy – Recall - Precision

- Accuracy = bien clasificados/total de casos

- Precision=tP/tP+fP

(Positivos que predije/ Total de positivos que predije)

- Recall= tP/tP+fN (sensibilidad)

(Positivos que predije / Total de positivos que hay)

Modelo

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

Accuracy

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

Bien clasificados = 49226
Total de casos = 66000

Accuracy = 75%

Accuracy = bien clasificados/total de casos

Precision

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

True positive = 13437
False Positive = 2955

Precision = 82%

Precision=tP/tP+fP

Recall

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

True positive = 13437
False Negative = 13819

Recall = 49%

Recall= tP/tP+fN (sensibilidad)

Accuracy – Recall - Precision

- Accuracy = 75%
- Presicion = 82%
- Recall = 49%

Pros y contras

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37787	100
Grupo 1	13	0

- Accuracy: si los grupos están desbalanceados no sirve. (**99%**)

Grupo 0 tiene 37887 registros

Grupo 1 tiene 13 registros

F1 Score

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	37789	2955
Grupo 1	13819	13437

F1 Score = 2* 0.49 * 0.82/ (0.49 + 0.82)

F1 Score = 0.61

F1 score = 2 * Precisión*Recall/(Precisión+Recall)

Matriz de confusión

Accuracy

Precision

Recall

F1 Score

Curva ROC

AUC

ROUGE

Algoritmos

Análisis de Componentes Principales (PCA)

- Queres bajar la cantidad de variables pero no podes identificar cuales son mejores.
- Asegurarte de q las variables son independientes entre si.
- Estas de acuerdo en que las variables se vuelvan menos interpretables?

PCA - OBJETIVOS

- Busca nuevos ejes para los datos para maximizar la varianza.
- Desde donde mirar para obtener mas información.
- Reducir dimensión de los datos sin perder información.
- Facilitar los cálculos

PCA - OBJETIVOS

- Si se tiene p variables.
- A veces la mayor parte de la variabilidad del sistema esta en un número menor (k) de componentes principales.
- Hay redundancia en los datos.
- Las k componentes principales reemplazan a las p originales
- No hay perdida de información importante.

PCA - OBJETIVOS

- Intenta representar el espacio original en un espacio de menor dimensión.
- De esta manera se perciben relaciones que quedaban ocultas en el total de variables.
- La perdida de información es mínima.
- Revela relaciones que no eran evidentes a primera vista.

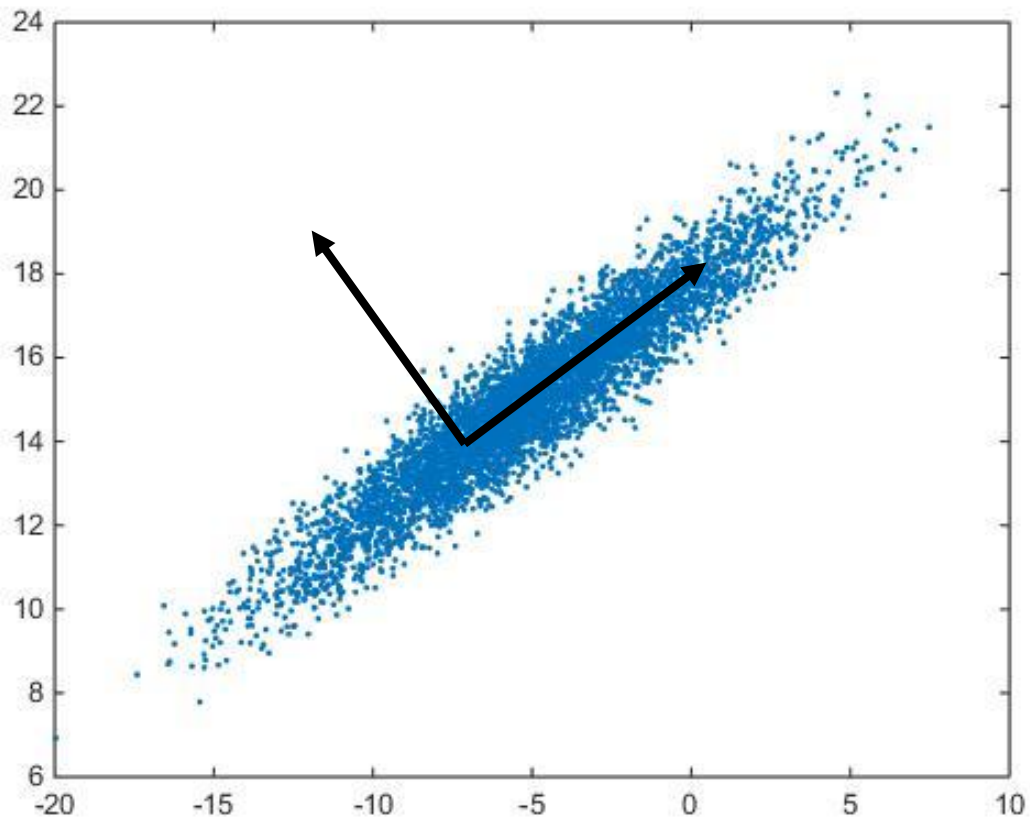
24
22
20
18
16
14
12
10
8
6
-20
-15
-10
-5
0
5
10

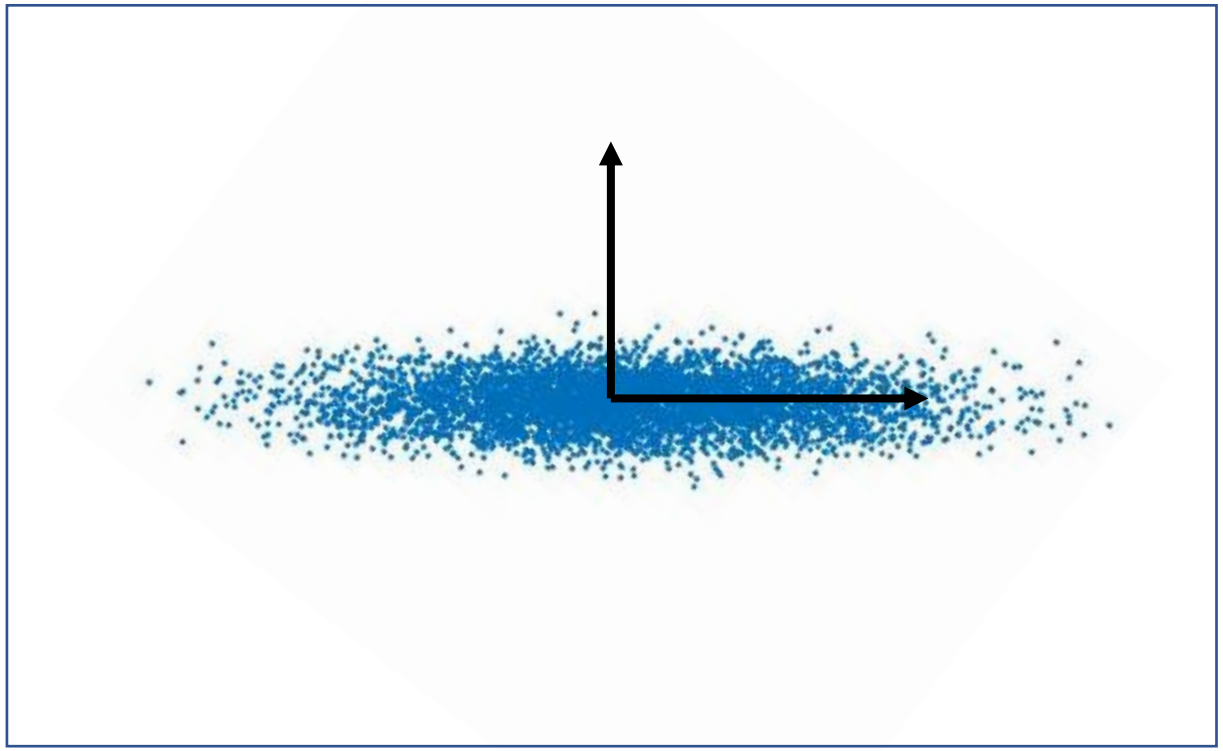

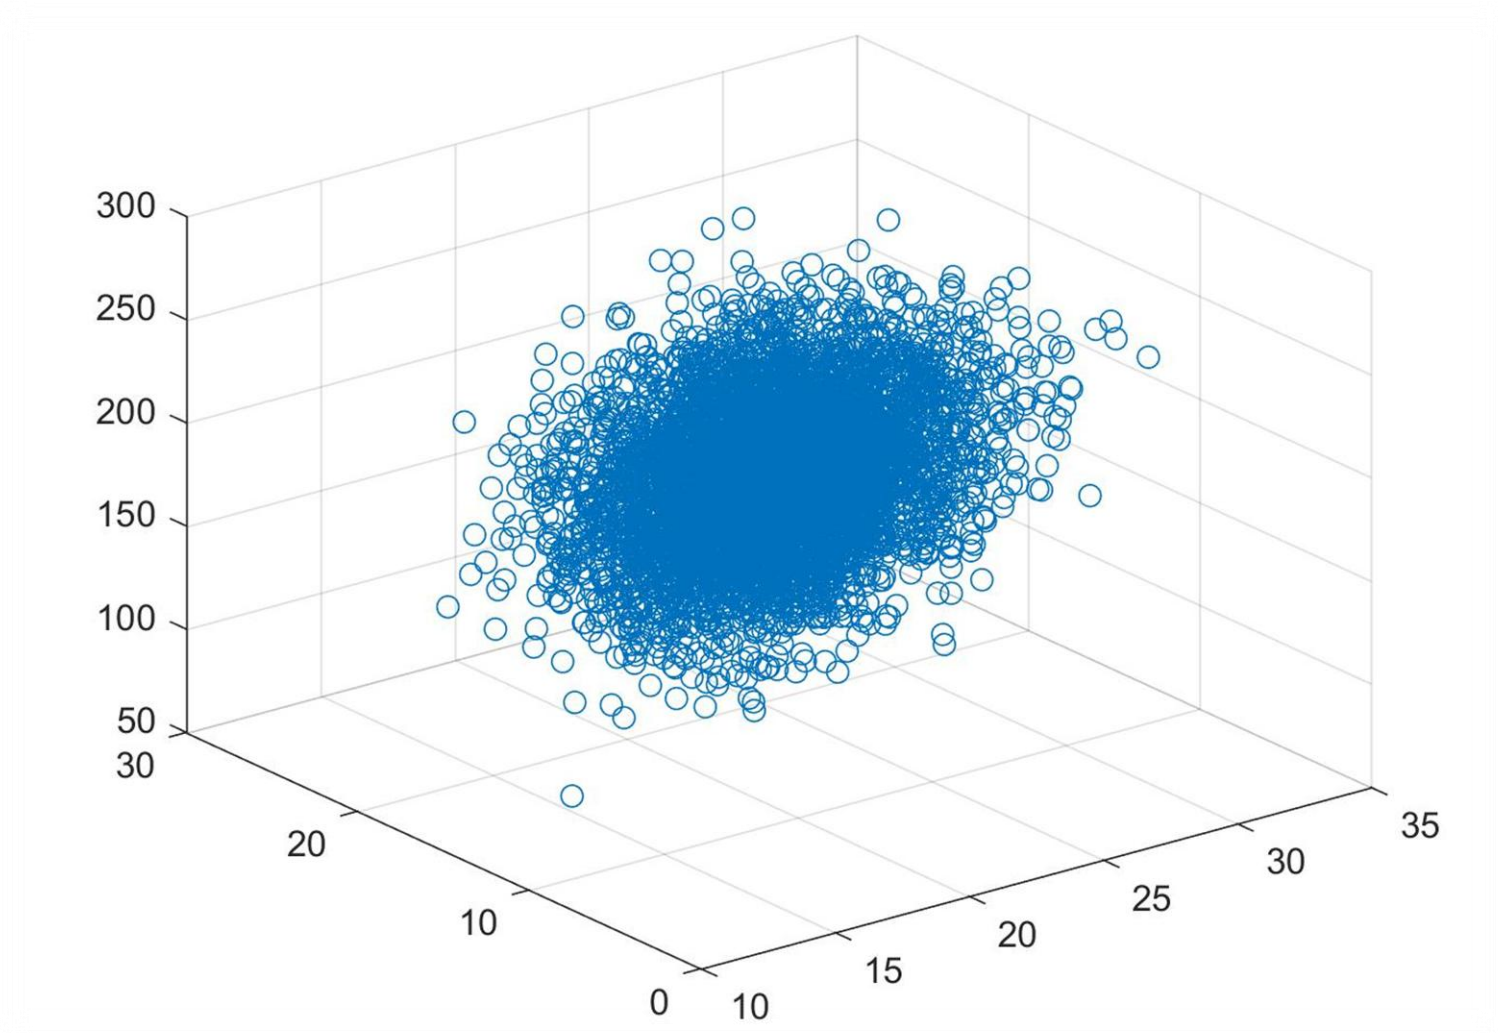
300
250
200
150
100
50
30
20
10
0
10
15
20
25
30
35

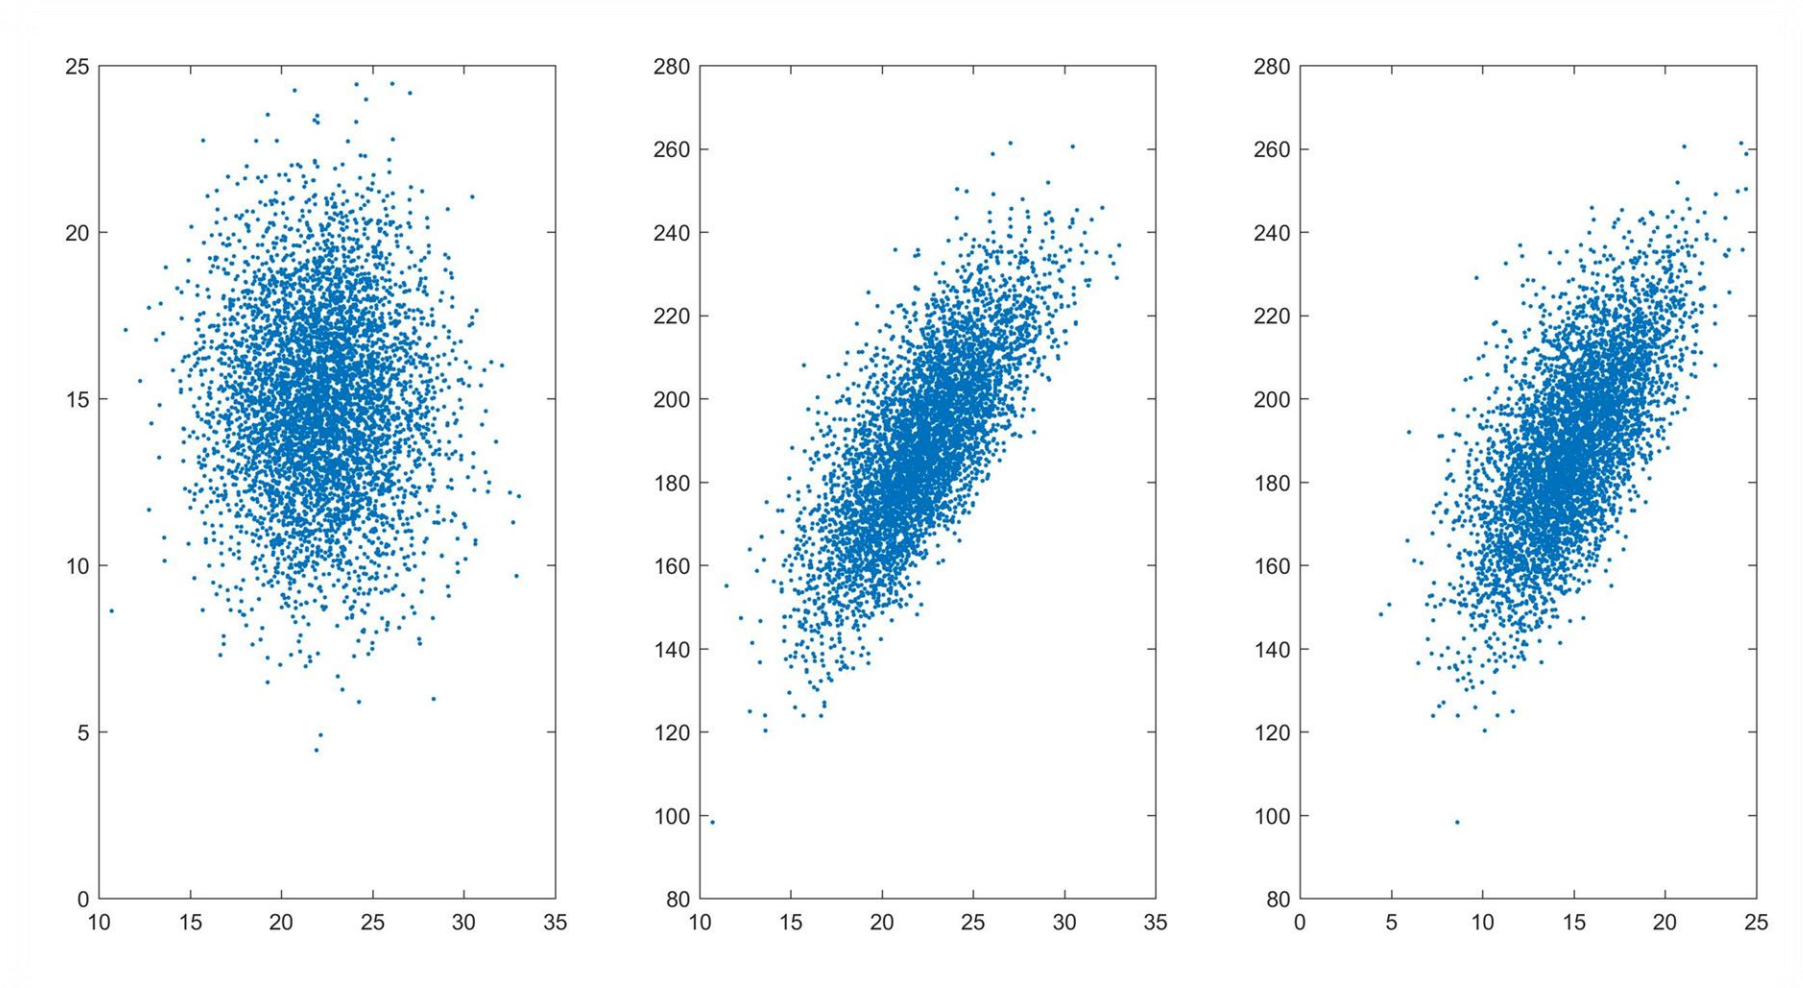
25
20
15
10
5
0
10 15 20 25 30 35
280
260
240
220
200
180
160
140
120
100
80
10 15 20 25 30 35
280
260
240
220
200
180
160
140
120
100
80
0 5 10 15 20 25

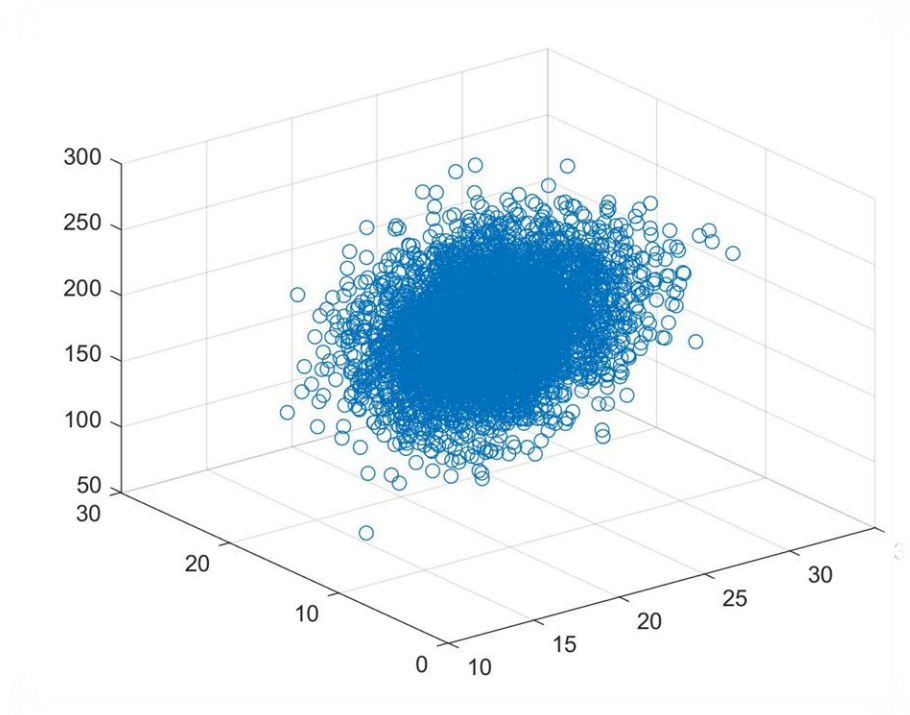

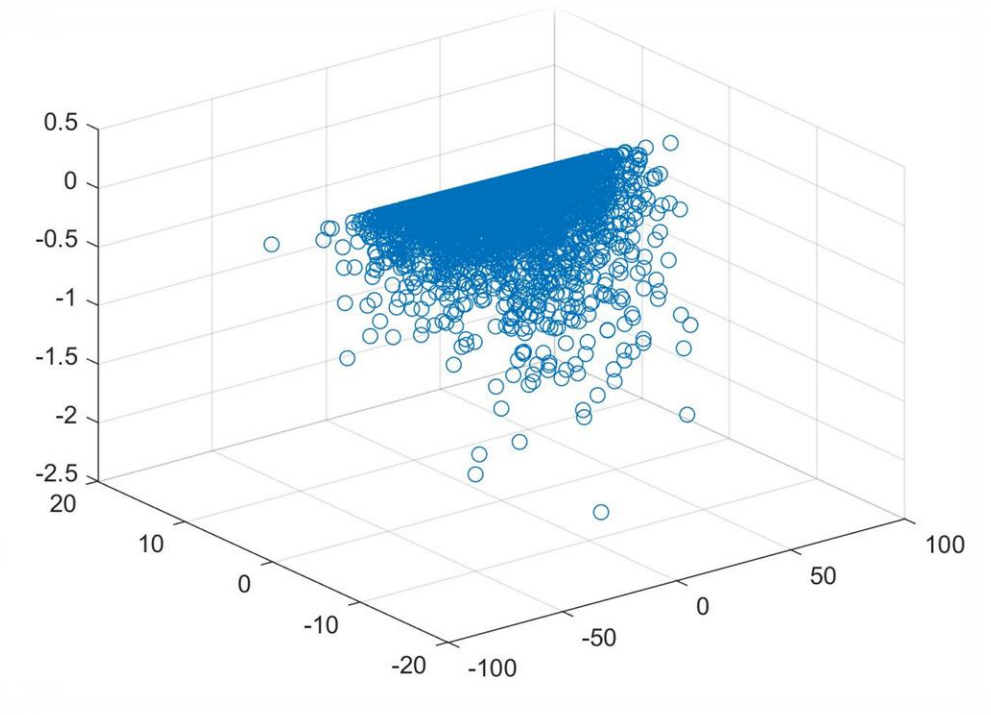

Transforma la nube de puntos

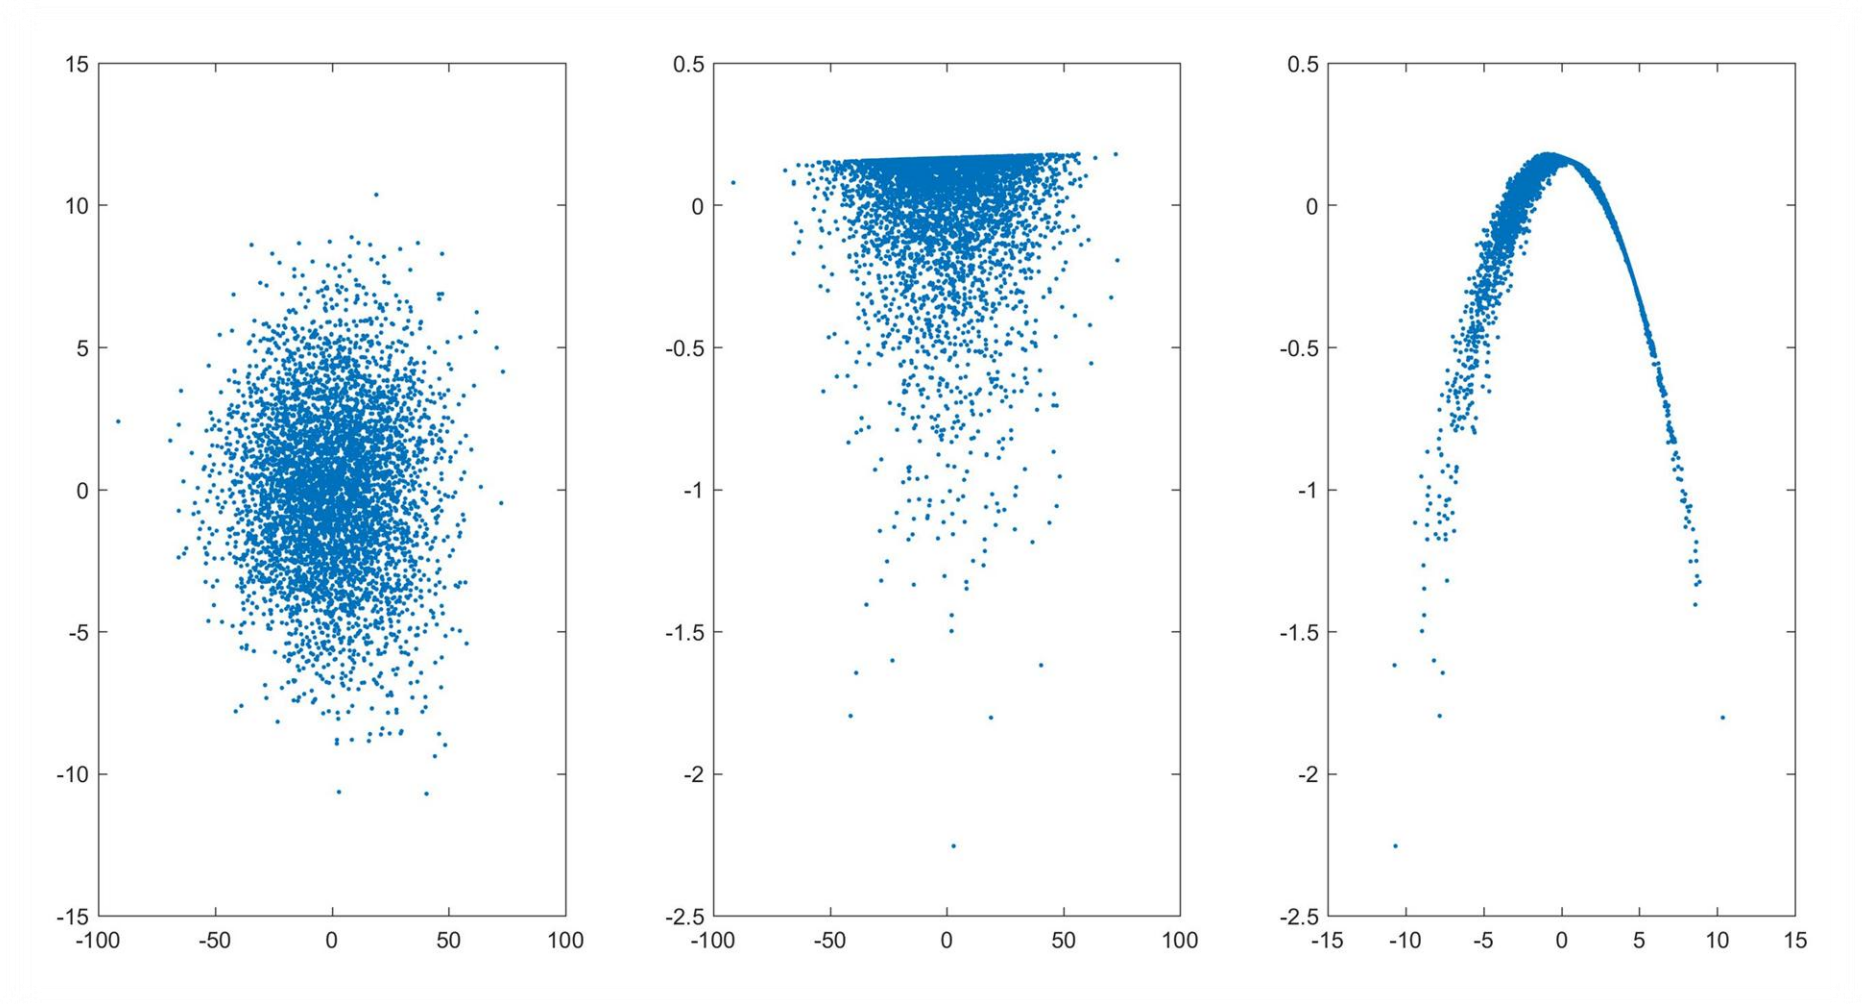
15
10
5
0
-5
-10
-15
-100
-50
0
50
100
0.5
0
-0.5
-1
-1.5
-2
-2.5
-100
-50
0
50
100
0.5
0
-0.5
-1
-1.5
-2
-2.5
-15
-10
-5
0
5
10
15

Componentes Principales - PCA

- Reducir la dimensionalidad - Compresión
- Extraer características
- Visualización de datos
- Facilitar cálculos

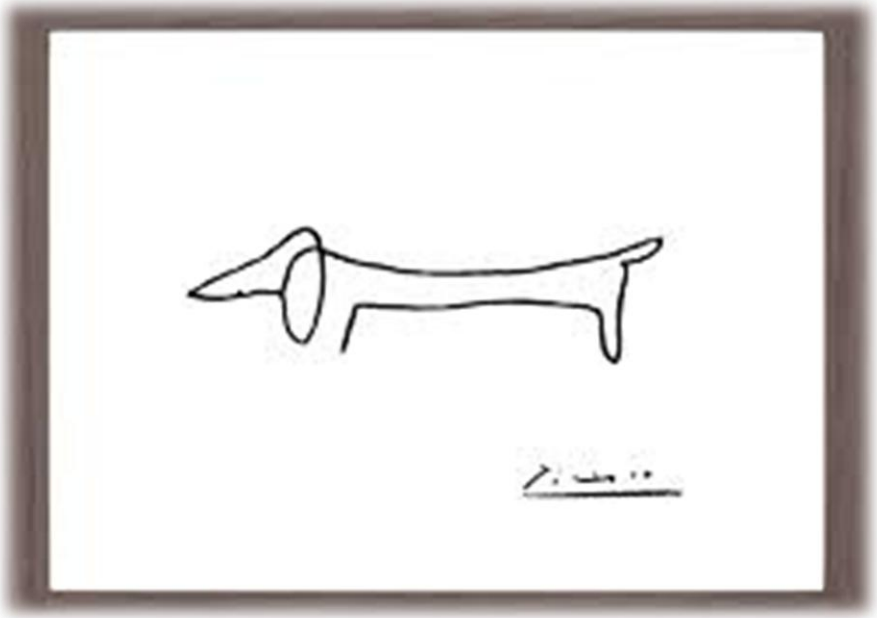

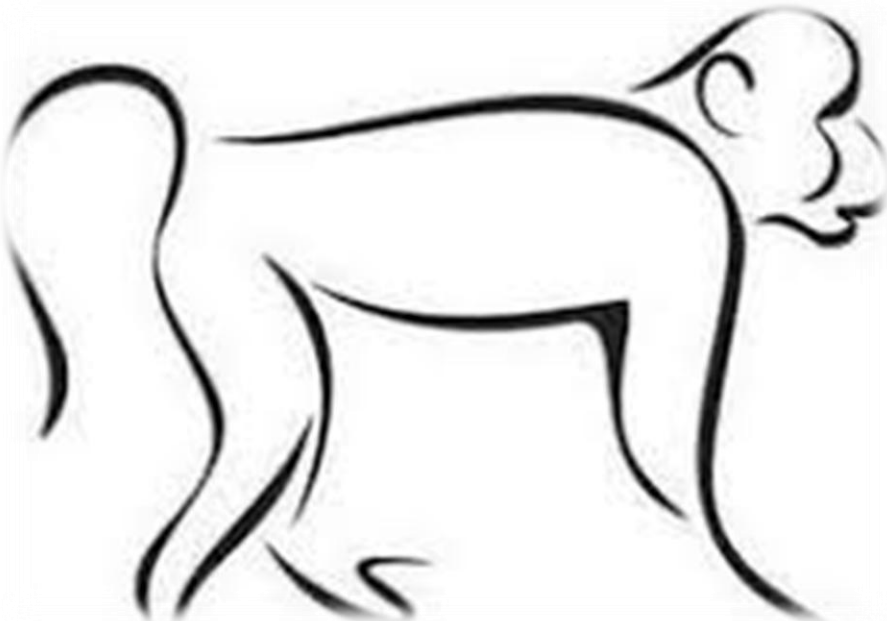

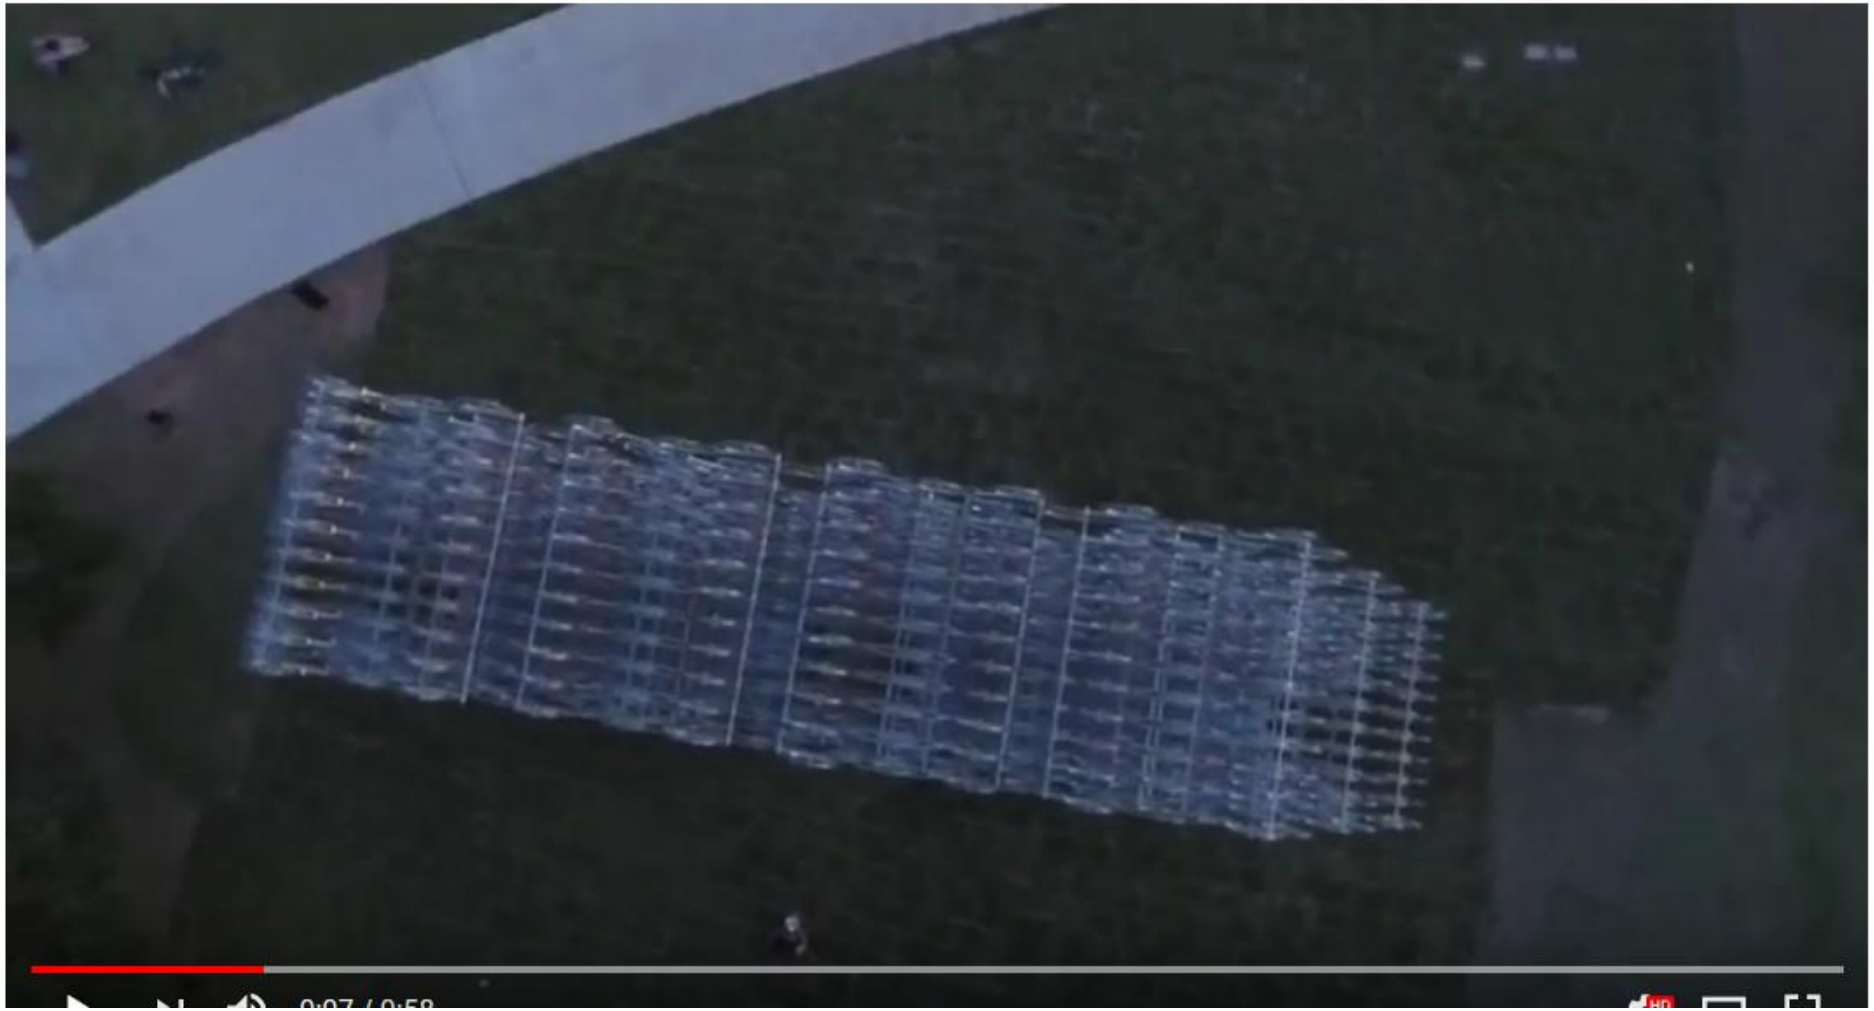
0:07 / 0:58

0:33 / 0:58

https://youtu.be/bcTUb8Fjtdw

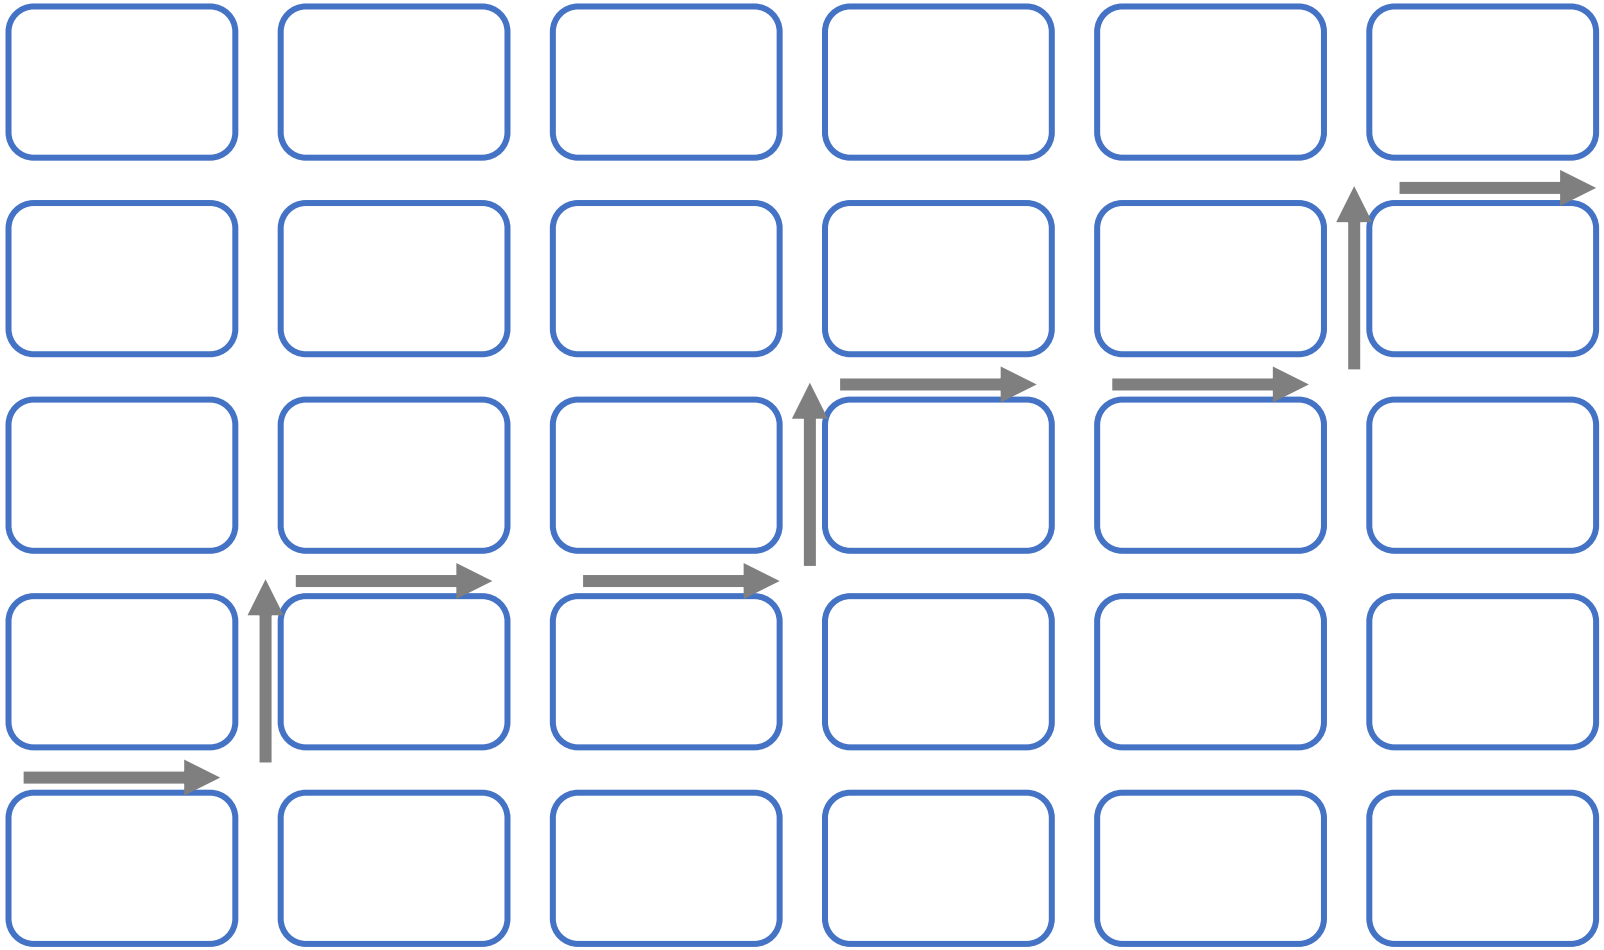

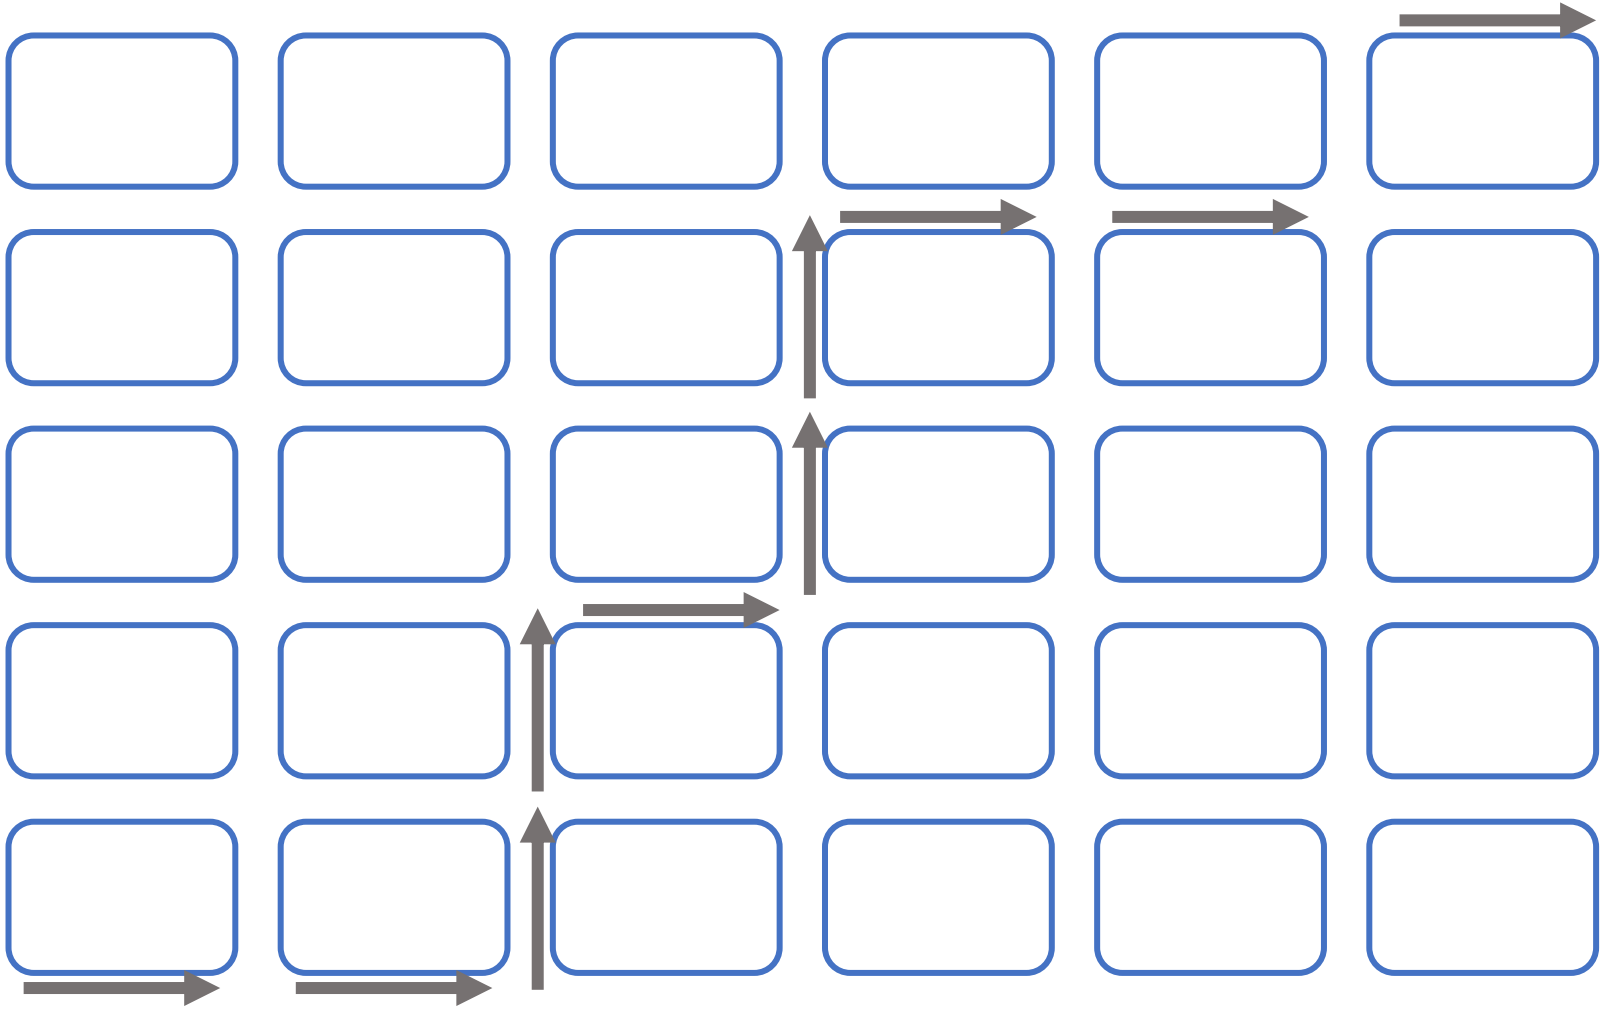

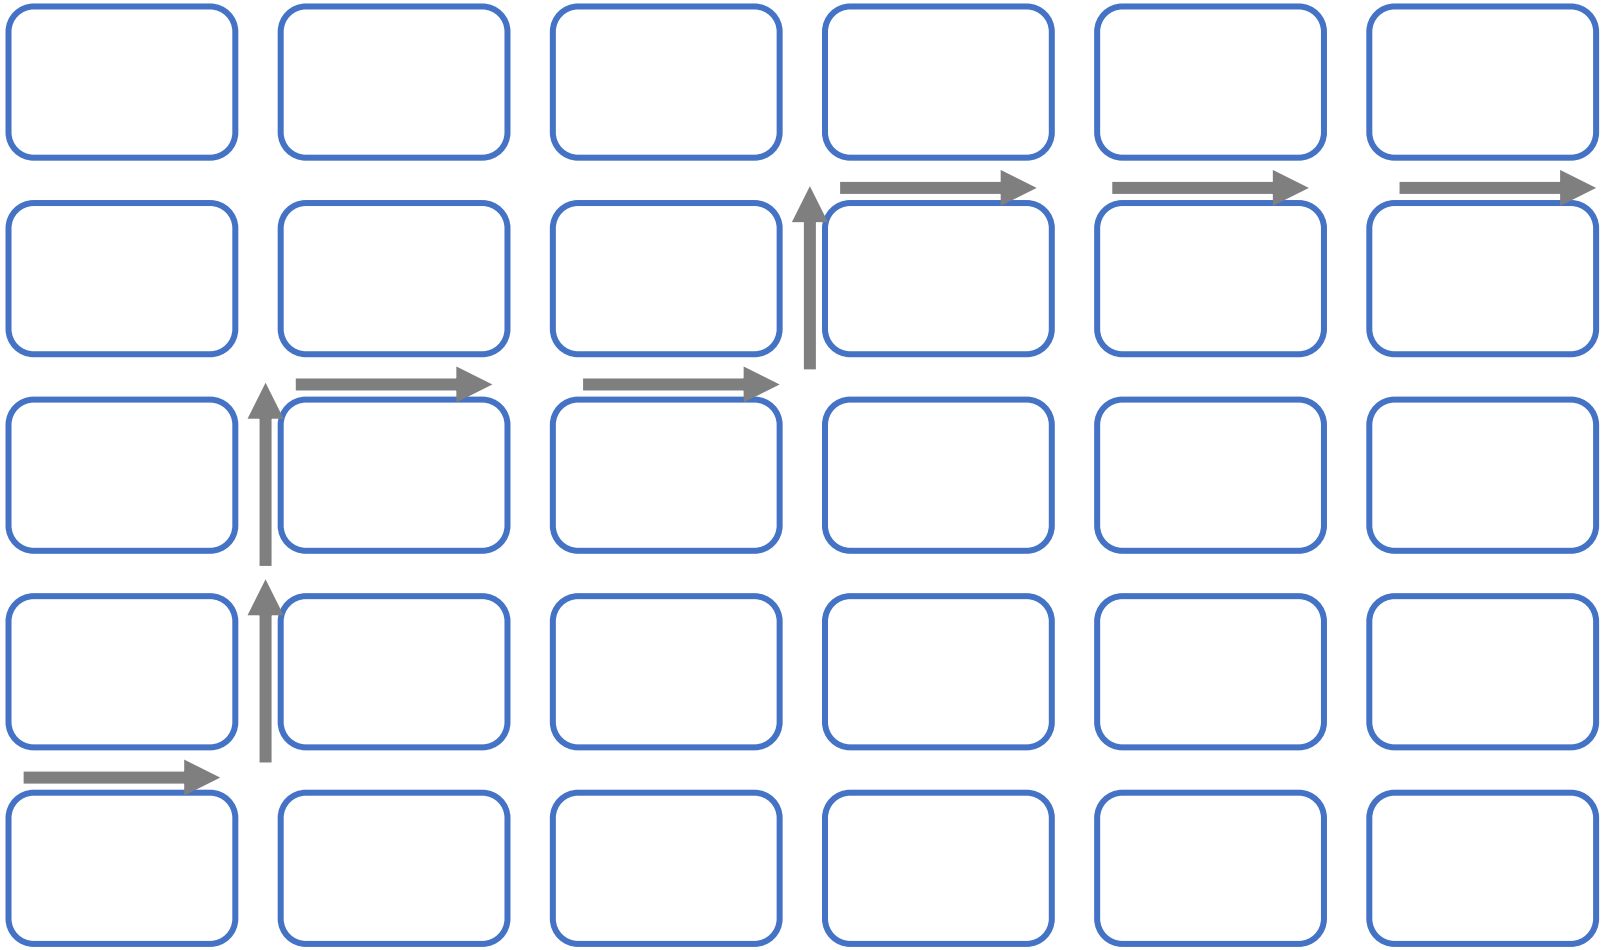

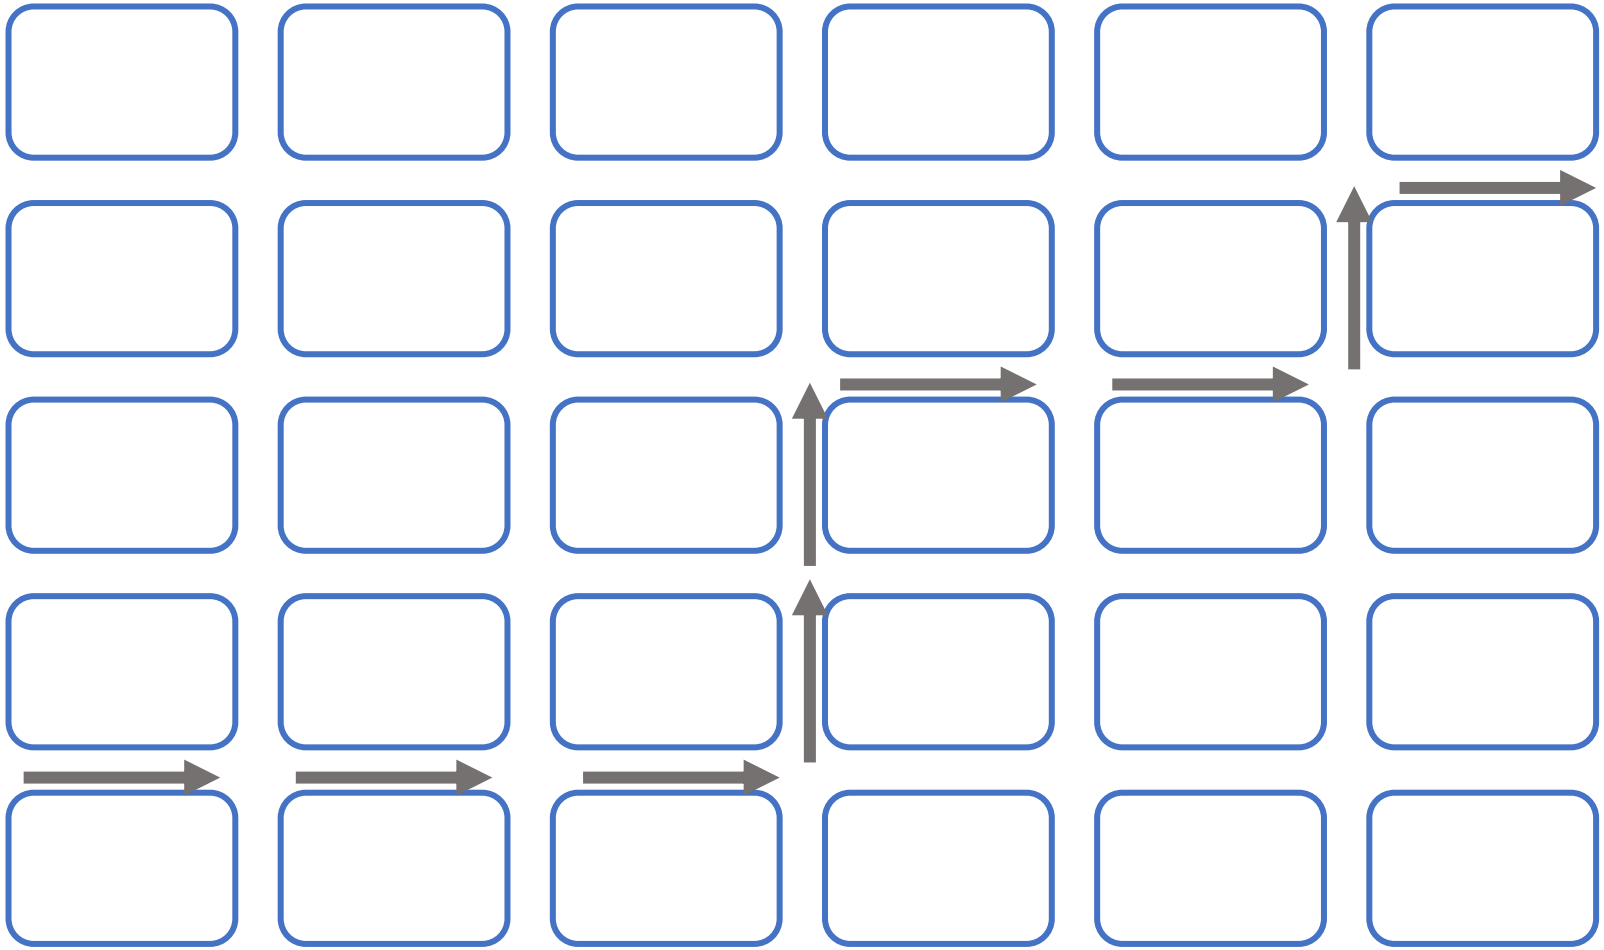

Datos de sensores

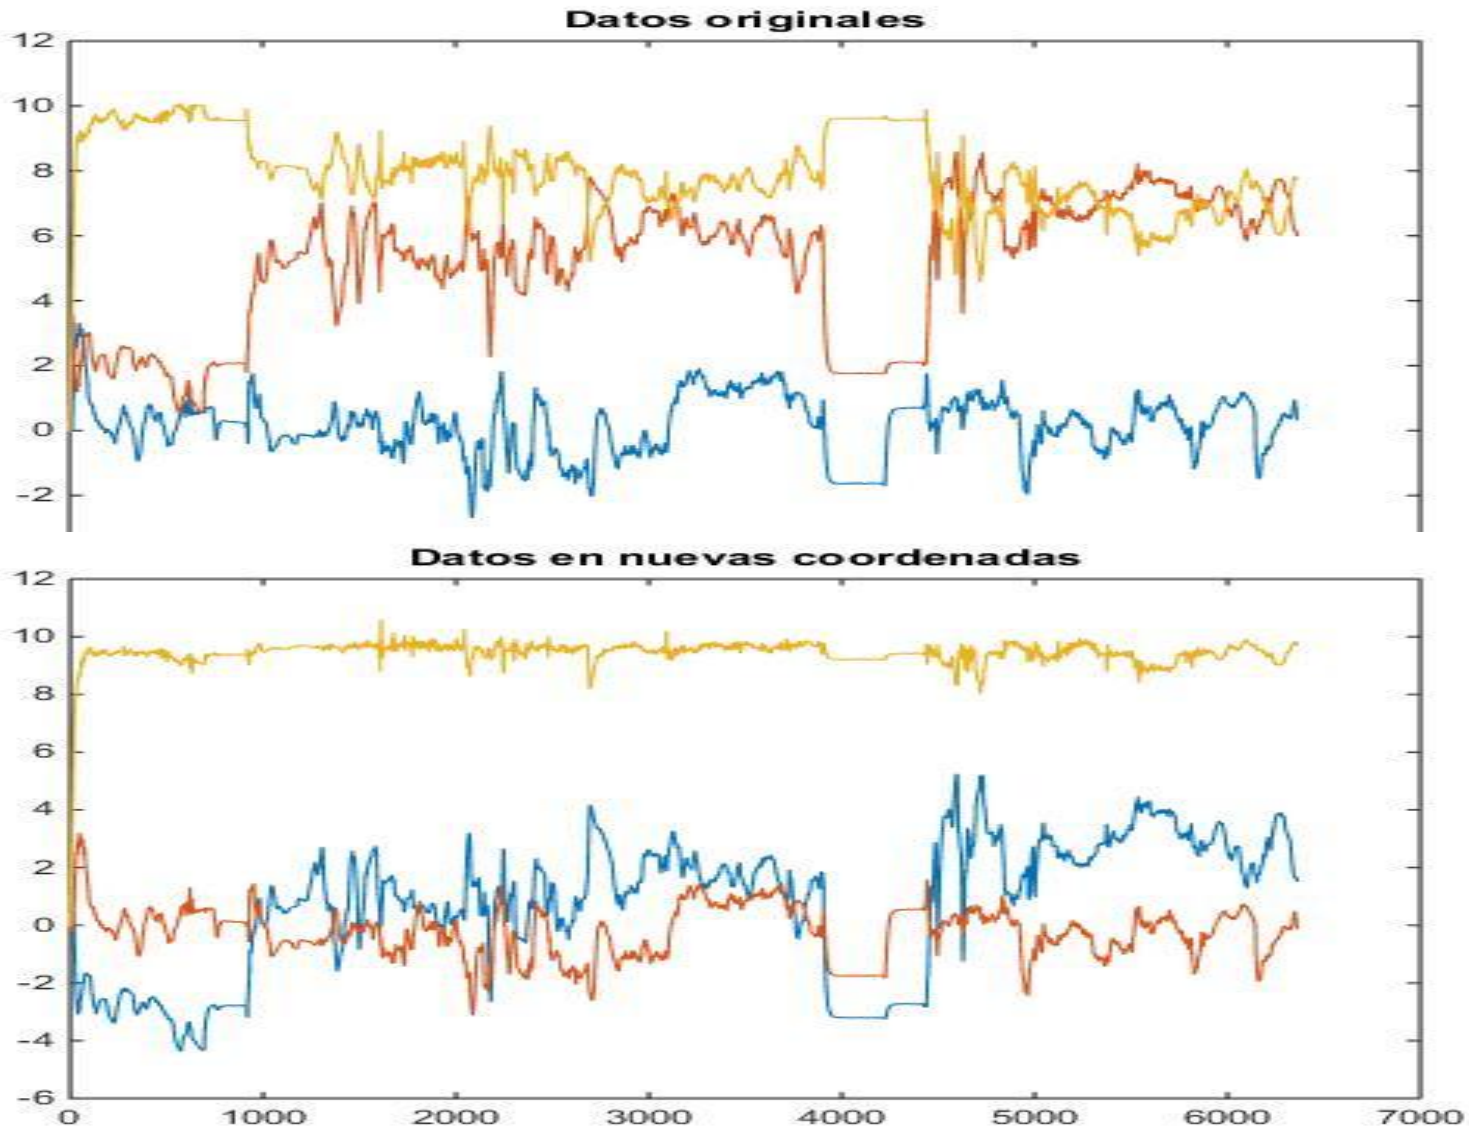

Proyección en la dirección que minimiza el costo de proyectar

Busca las direcciones donde esta la mayor varianza. Donde los datos están mas dispersados.

Deconstruyo los datos en autovalores y autovectores.

El autovector me da la dirección y el autovalor la varianza sobre esa dirección.

Los datos no cambian, solo desde donde los miro

PCA

Matriz de covarianza

$$cov(X,Y) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{(n-1)}$$

$$C = \begin{pmatrix} cov(x,x) & cov(x,y) & cov(x,z) \\ cov(y,x) & cov(y,y) & cov(y,z) \\ cov(z,x) & cov(z,y) & cov(z,z) \end{pmatrix}$$

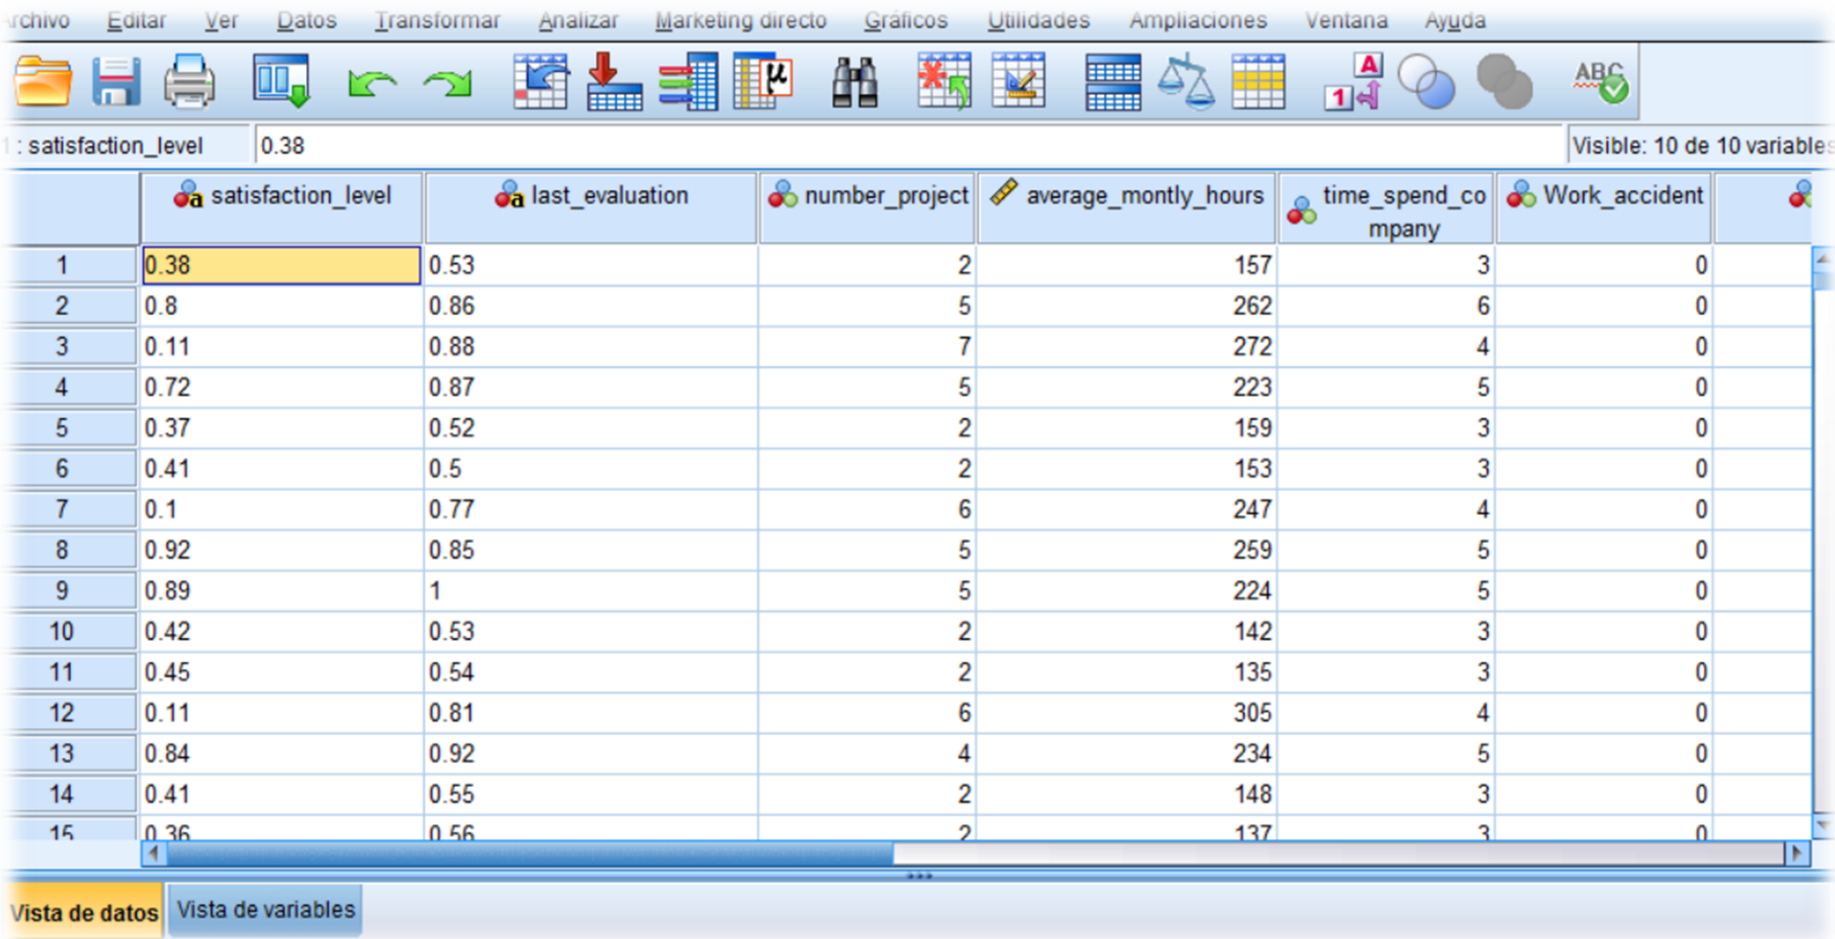

	satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident
1	0.38	0.53	2	157	3	0
2	0.8	0.86	5	262	6	0
3	0.11	0.88	7	272	4	0
4	0.72	0.87	5	223	5	0
5	0.37	0.52	2	159	3	0
6	0.41	0.5	2	153	3	0
7	0.1	0.77	6	247	4	0
8	0.92	0.85	5	259	5	0
9	0.89	1	5	224	5	0
10	0.42	0.53	2	142	3	0
11	0.45	0.54	2	135	3	0
12	0.11	0.81	6	305	4	0
13	0.84	0.92	4	234	5	0
14	0.41	0.55	2	148	3	0
15	0.36	0.56	2	137	3	0

- Tengo una matriz cuadrada
- Calculo autovalores y autovectores

Detectar grupos

Consumo

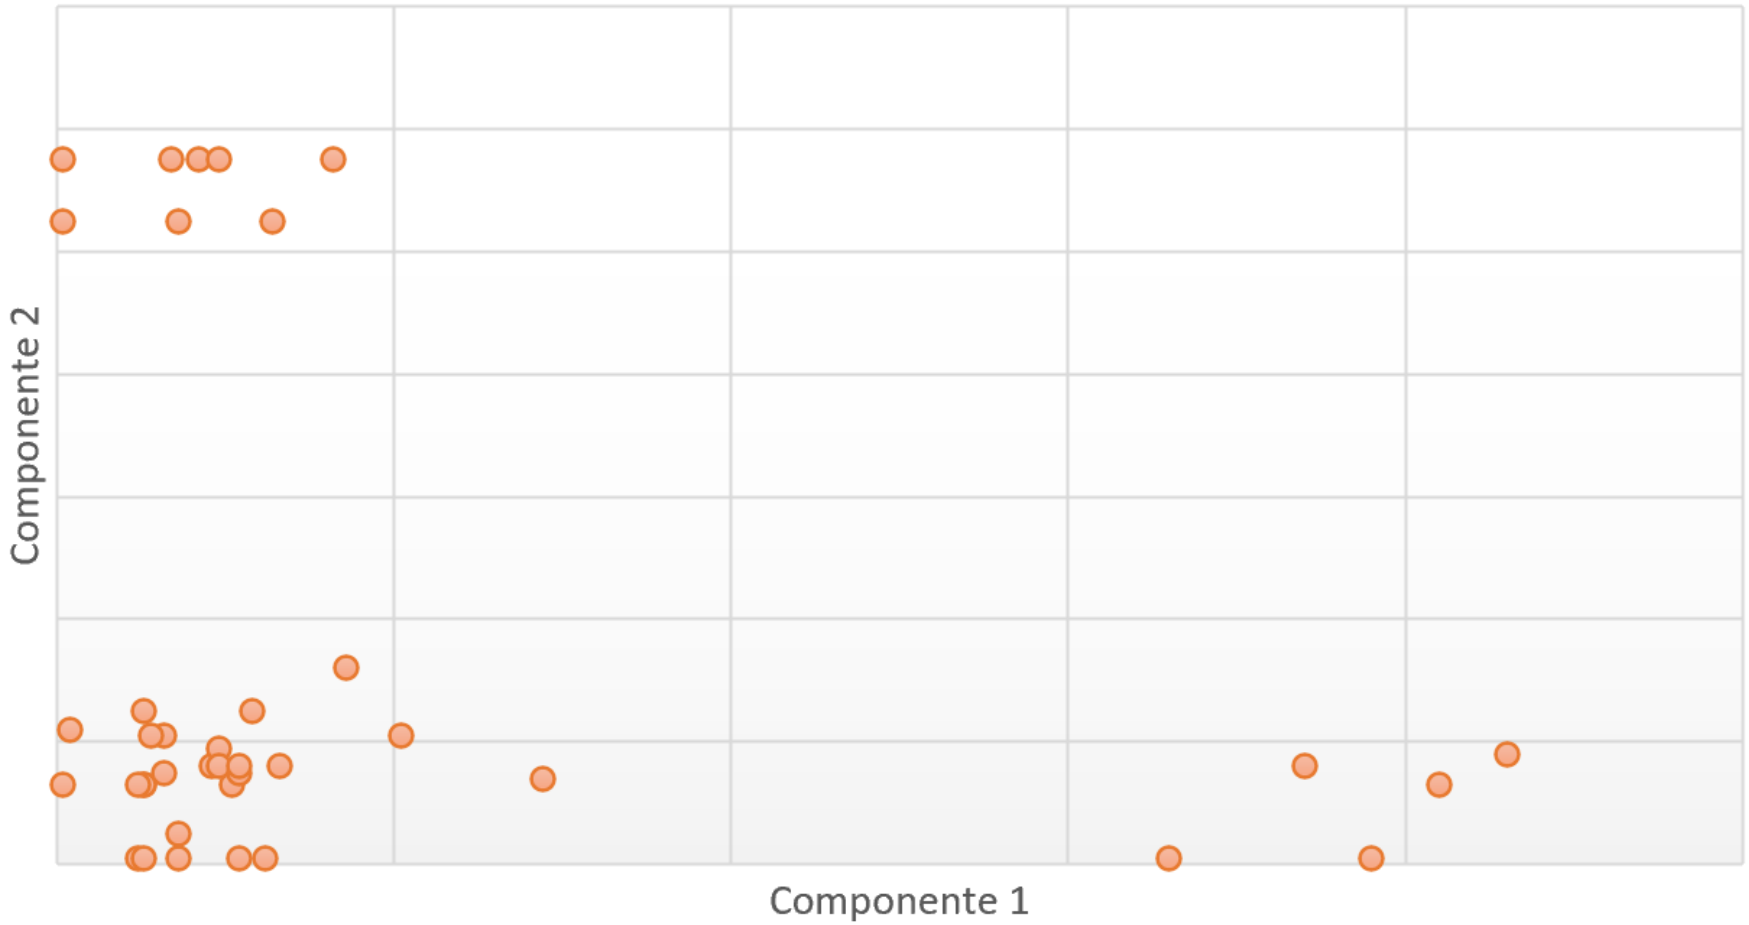

Detectar outliers

Movimientos en cuenta

PCA

- Transforma la data en nuevas coordenadas.
- CP no están correlacionadas.
- Ordenadas por la info del sistema q aportan.

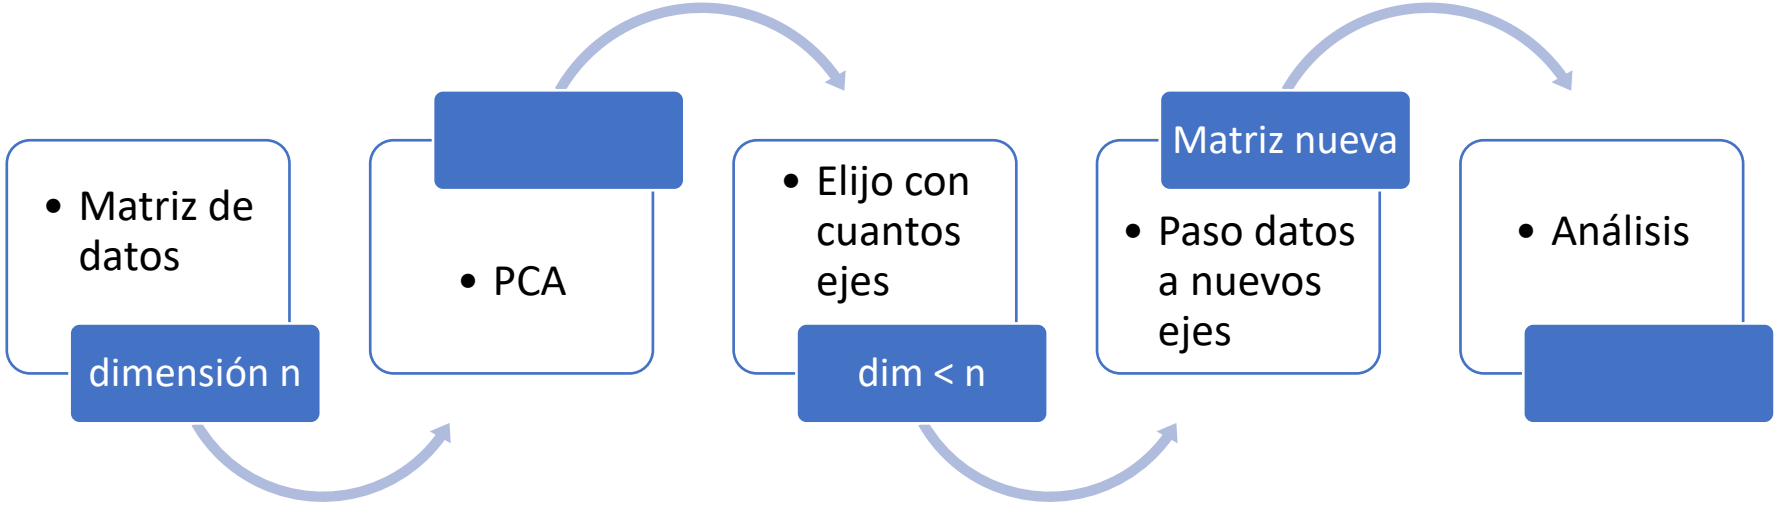

Reducir dimensión

Proyectar los datos a un espacio de menor dimensión

¿Con cuantas dimensiones me quedo?

- Porcentaje de explicación de la varianza
- Autovalores mayores que uno.
- Quiebre en el grafico de sedimentación

¿Qué necesita?

- Variables numéricas
- Correlación entre las variables
- Suficientes casos *
- Datos “limpios”

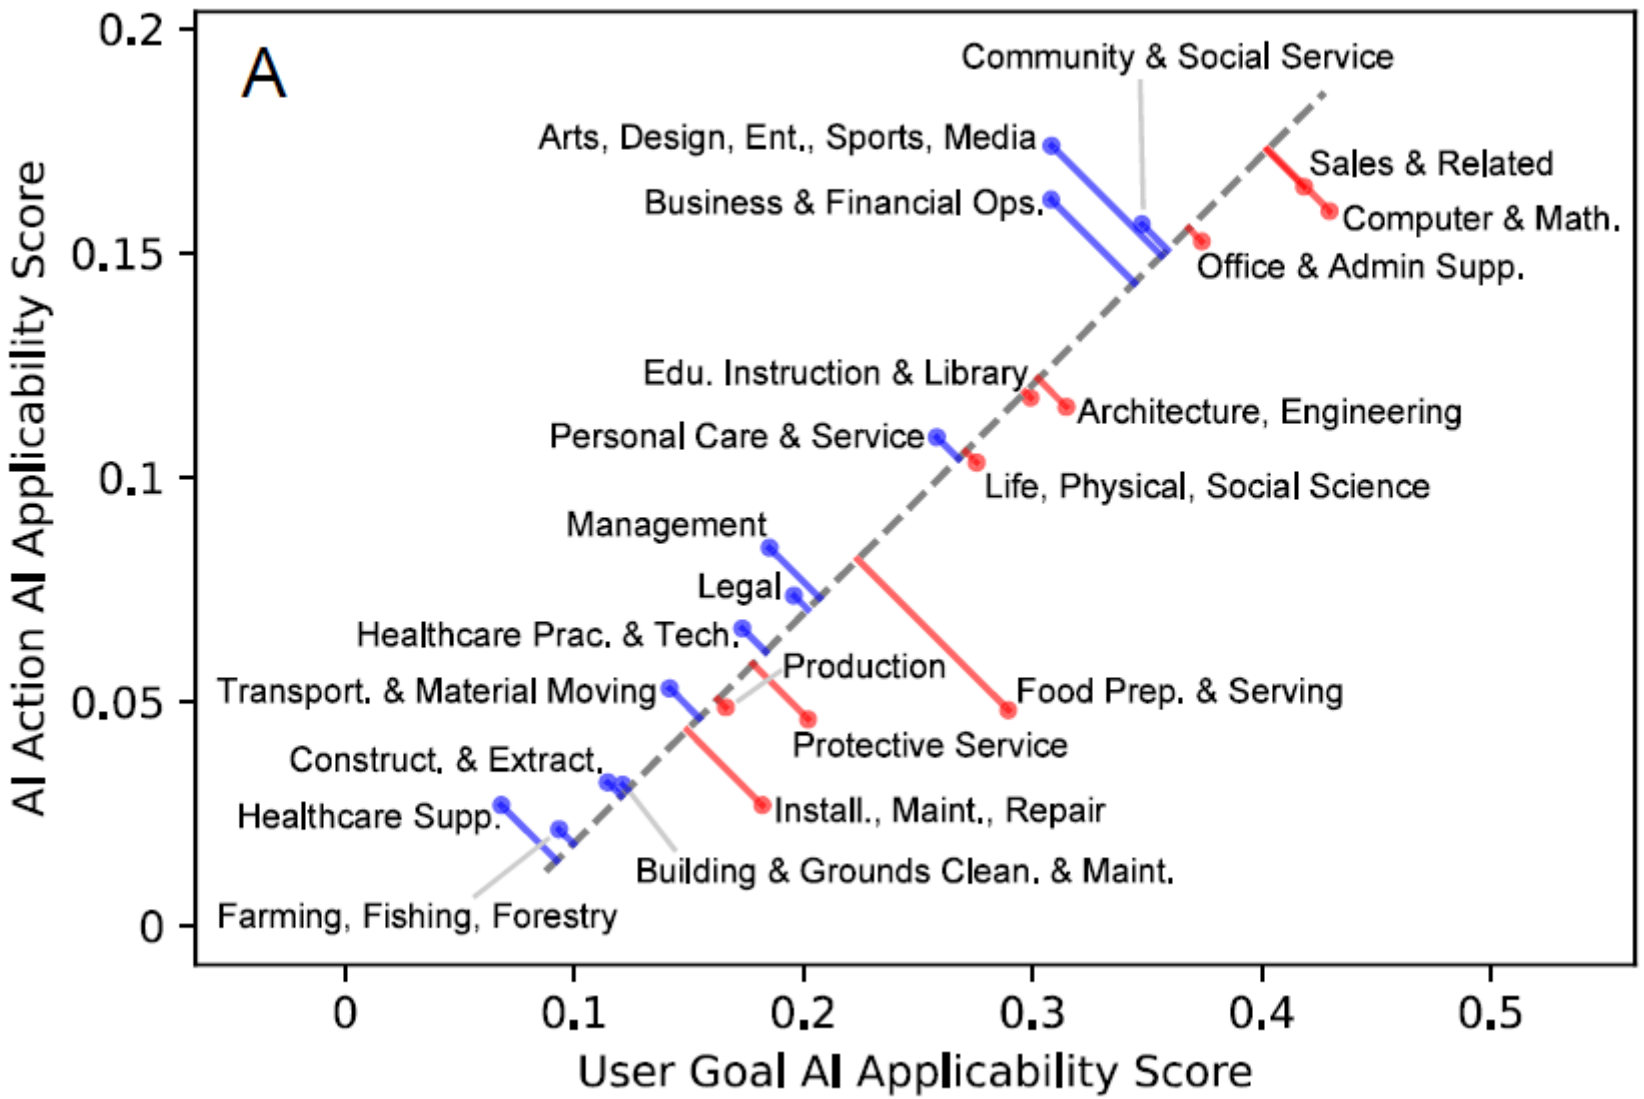

Working with AI: Measuring the Applicability of Generative AI to Occupations (2025)
Microsoft Research https://arxiv.org/abs/2507.07935v6

PCA ejemplo
Python