Analytics

Clase III

Julia Picabea

Abril 2026

TRABAJO FINAL

¿Cómo evaluar los resultados?

Modelos de Score

Calificar registros con respecto a un hecho:

- Credit Score
- Churn/Attrition
- Adquirir un producto

Modelos de Score

- Clasifica – ordena los registros
- Variables dicotómicas: pertenencia a un grupo, compra de un producto, enfermos vs sanos.
- Busco la “probabilidad” que tiene un nuevo individuo de pertenecer a un grupo u otro.
- Necesito tener datos de individuos y su grupo de pertenencia.

Modelos de Score

Ordena los registros según una “probabilidad”

REGISTRO	SCORE
N1	0.97
N2	0.93
N3	0.89
N4	0.87
N5	0.85
N6	0.85
…	…
N998	0.32
N999	0.29
N1000	0.23

SCORE

Modelos de Score

Supervisado

Se cual es la “realidad’

REGISTRO	SCORE	GRUPO
N1	0.97	1
N2	0.93	1
N3	0.89	0
N4	0.87	1
N5	0.85	0
N6	0.85	1
…	…	
N998	0.32	0
N999	0.29	1
N1000	0.23	0

Es útil el orden que me dio?

1000 clientes

Quienes se dan de baja?

300 casos que quiero identificar (30%)

Los puedo agrupar según deciles

CHURN

Top	Grupo 1	Grupo 2
10	75	25
20	126	74
30	174	126
…	…	…
50	234	266
…	…	…
80	300	500
90	300	600
100	300	700

Es útil el orden que me dio?

1000 clientes

Quienes se dan de baja?

300 casos que quiero identificar (30%)

Que % del total hay en cada decil?

Top	Churn	% Churn
10	75	25%
20	126	42%
30	174	58%
…	…	…
50	234	78%
…	…	…
80	300	100%
90	300	100%
100	300	100%

Es útil el orden que me dio?

1000 clientes

Quienes se dan de baja?

300 casos que quiero identificar (30%)

Que % del total hay en cada decil?

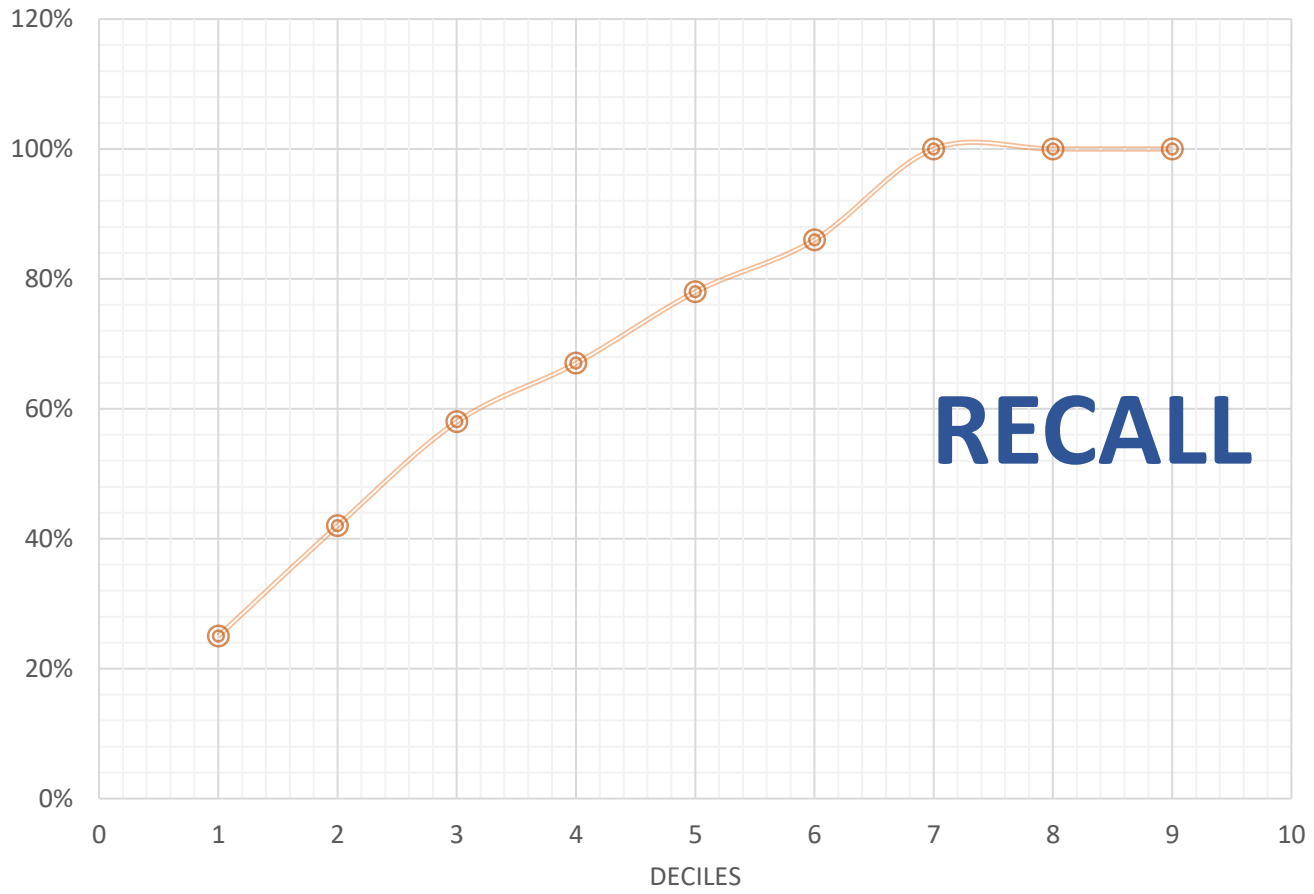

Cuantos traigo de mas?

1000 clientes

300 casos que quiero identificar (30%)

Cuantos FP tengo en cada decil?

Top		No Churn
10		25
20		74
30		126
…		…
50		266
…		…
80		500
90		600
100		700

Cuantos traigo de mas?

1000 clientes

300 casos que quiero identificar (30%)

Cuantos FP tengo en cada decil?

Top	FP	No Churn
10	4%	25
20	11%	74
30	18%	126
…	…	…
50	38%	266
…	…	…
80	71%	500
90	86%	600
100	100%	700

Cuantos traigo de mas?

1000 clientes

300 casos que quiero identificar (30%)

Cuantos FP tengo en cada decil?

Top	FP	% Churn
10	4%	25%
20	11%	42%
30	18%	58%
…	…	…
50	38%	78%
…	…	…
80	71%	100%
90	86%	100%
100	100%	100%

CURVA ROC

Tasa de falsos positivos

vs

Cuantos **+** logre identificar del total **+**

	Predicho -	**Predicho +**
Real -	Verdaderos -	Falsos +
Real +	Falsos -	Verdaderos +

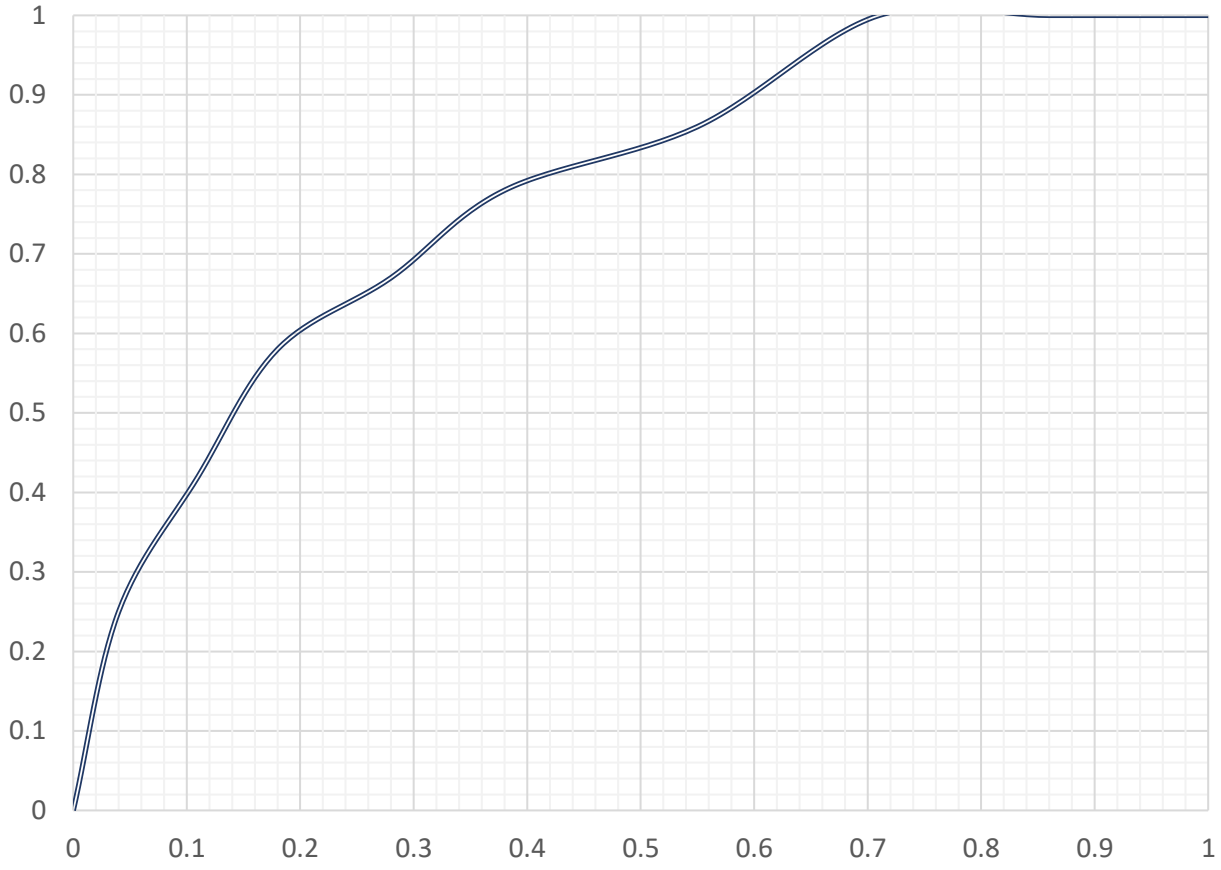

CURVA ROC

RECALL

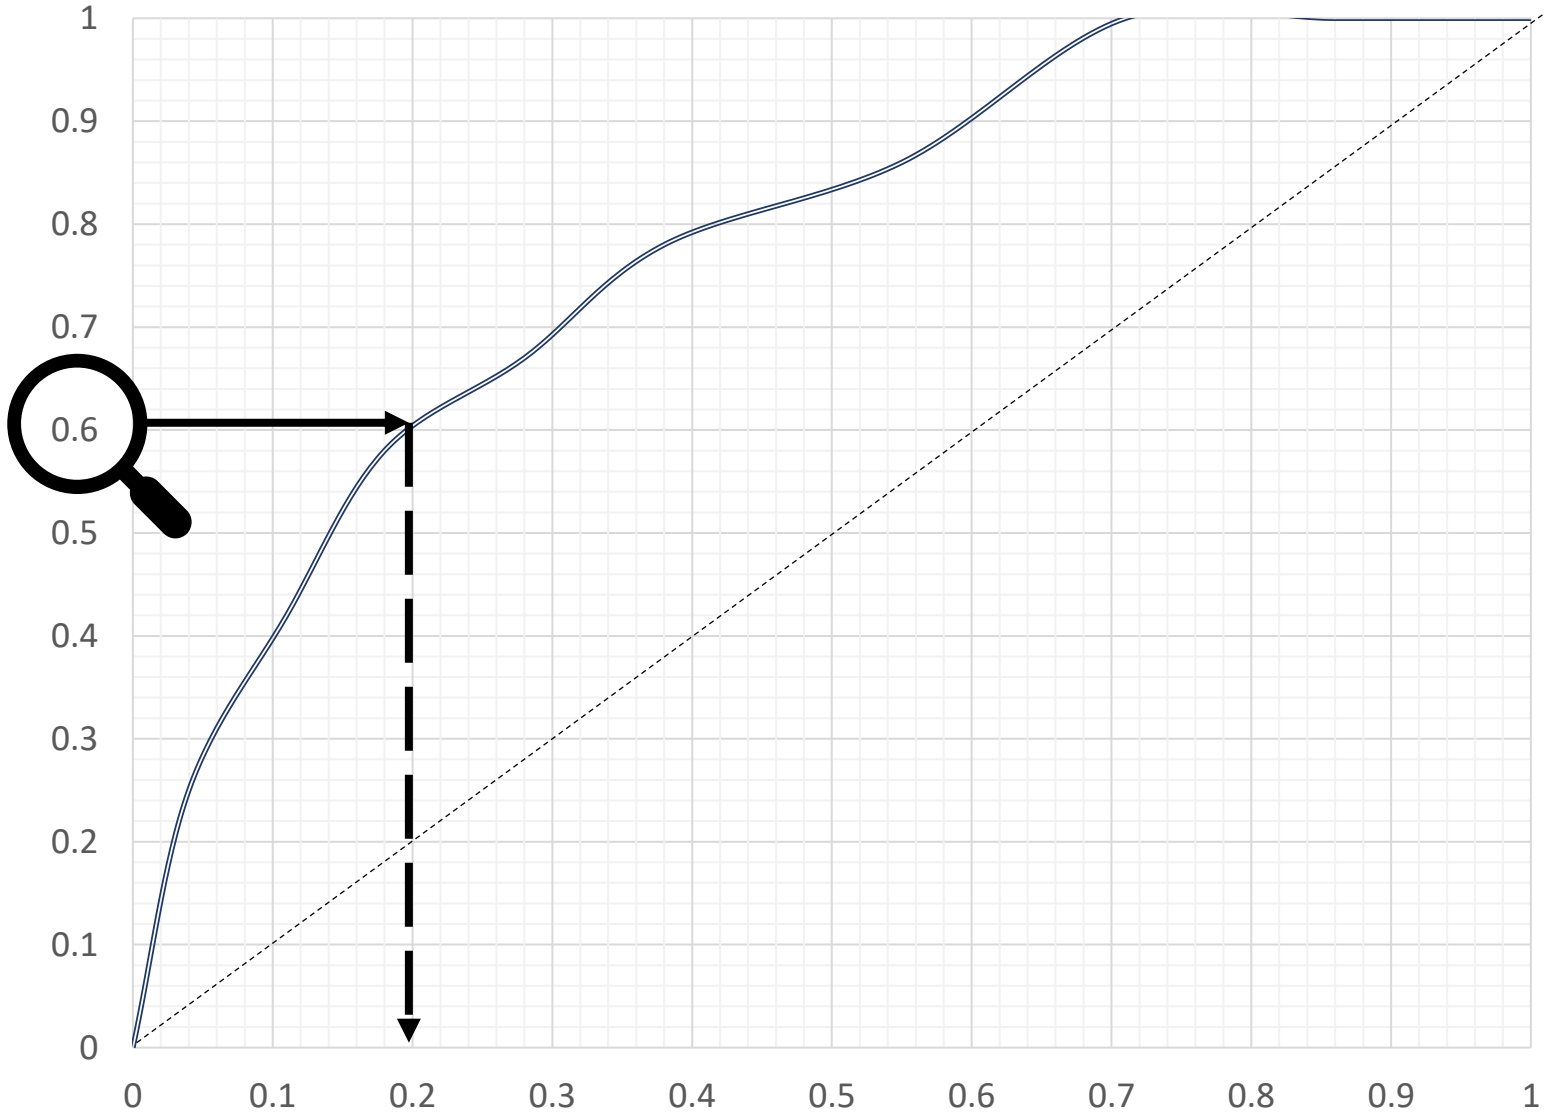

Si quiero el **60%** de los que se dan de baja,

voy a traer **20%** de los que no se dan de baja

CURVA ROC

AUC

- >0.9 excelente
- 0.8-0.9 buena
- 0.7-0.8 aceptable
- 0.5 no clasifica

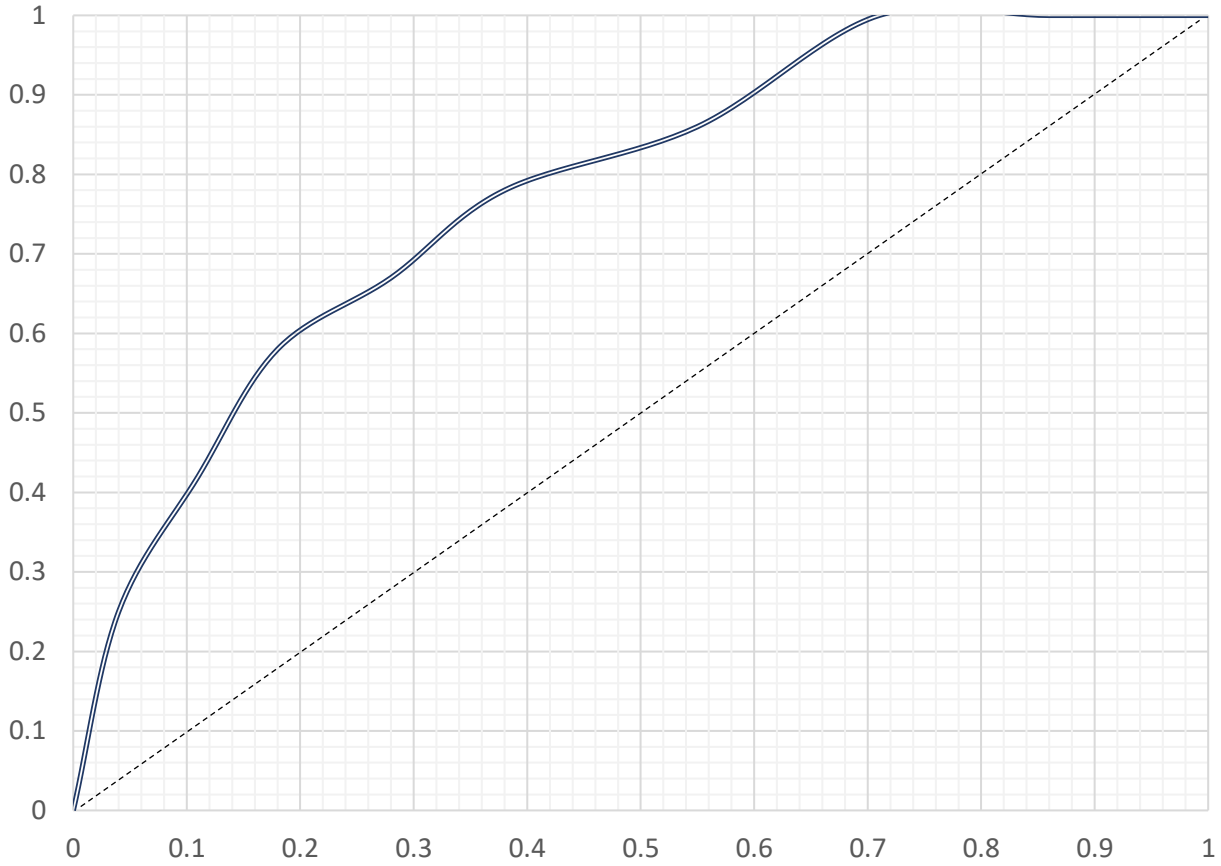

¿Cómo evaluar los resultados?

PREDICCION

REAL

	Grupo 0 Negativo	Grupo 1 Positivo
Grupo 0 Negativo	Verdadero Negativo	Falso Positivo
Grupo 1 Positivo	Falso Negativo	Verdadero Positivo

¿Cómo evaluar los resultados?

RECALL

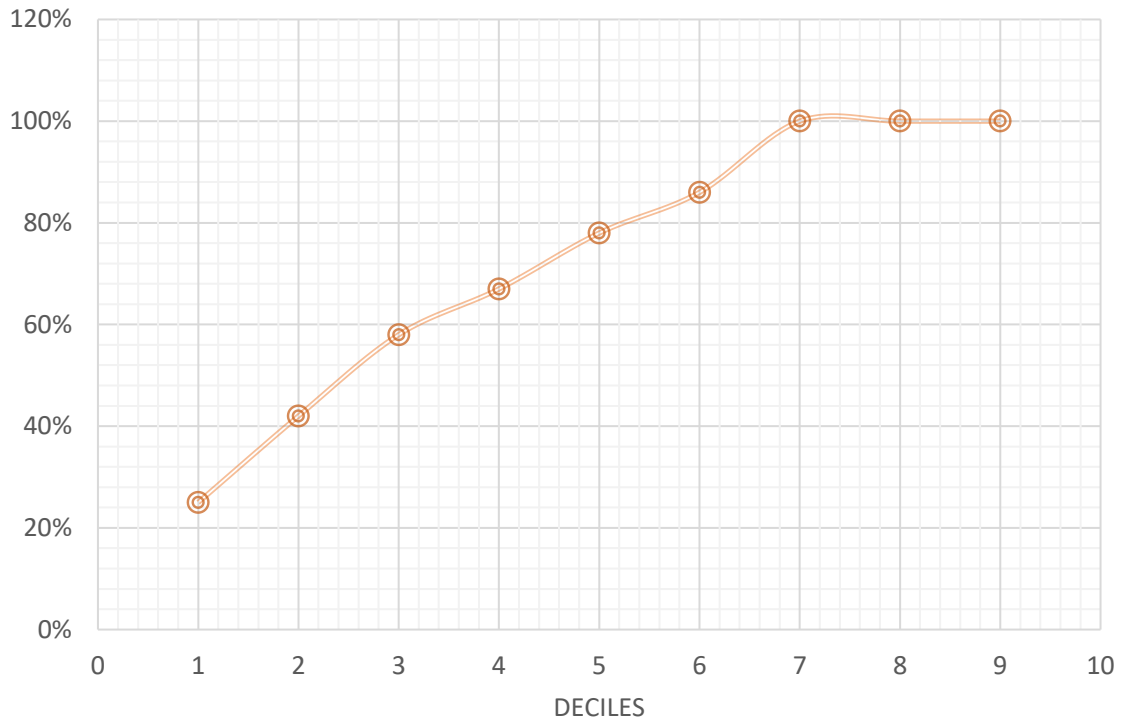

ROC

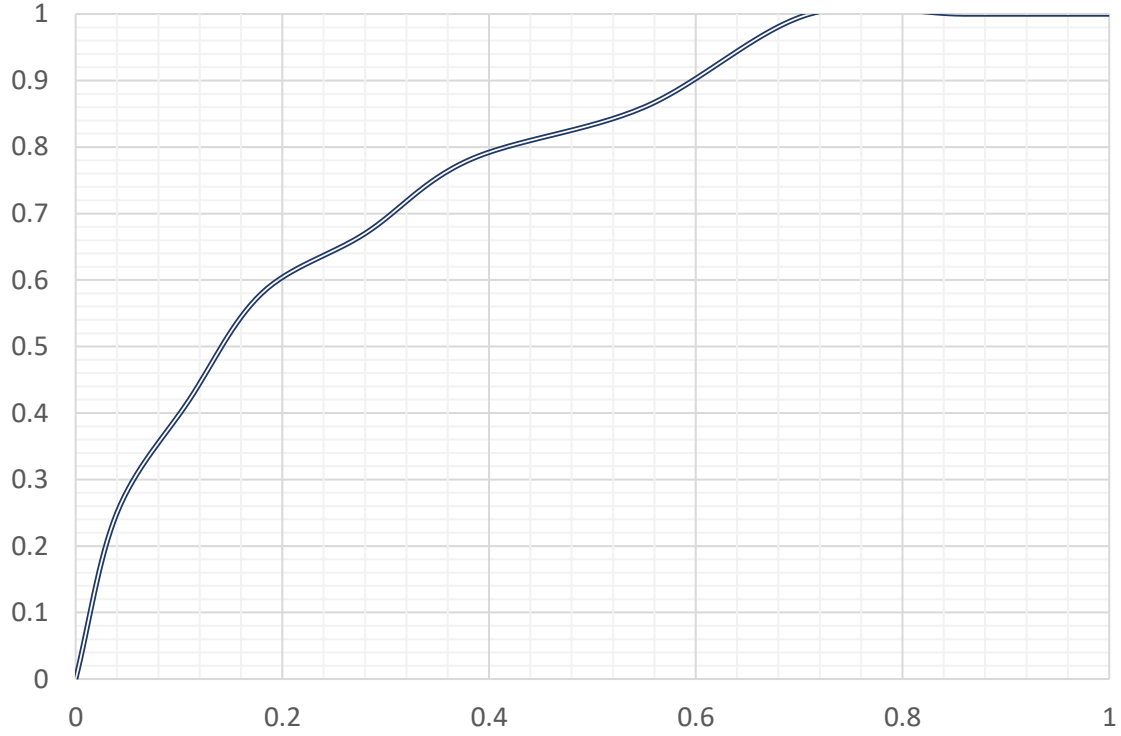

Segmentación

- Entender el comportamiento de los clientes.
- Categorizarlos en base a: demografía, comportamiento de consumo,

Para que?

- Hacer campañas mas personalizadas, enfocadas a las necesidades del cliente.
- Definir estrategias.
- Promociones, marketing, productos.

- Seguros: telemetría/telemática Alinear primas a comportamientos de manejo. Usage based insurance.
- Gestión de personal: Entender el perfil de los empleados que se van.
- Consumidores: patrones de compras.
- Detección de Fallas: identificar piezas con fallas.
- Detectar perfil de consumidores/usuarios.
- Usuarios de transporte público.

Tipos de aprendizaje

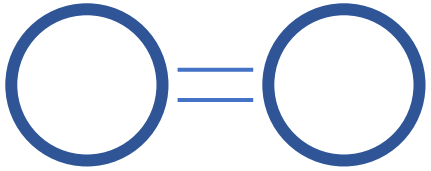

Supervisado

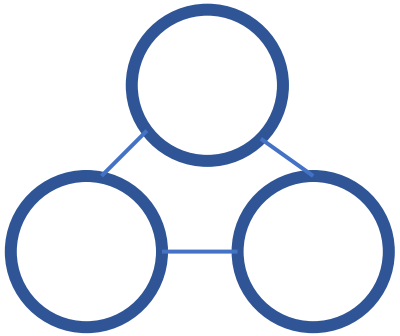

No supervisado

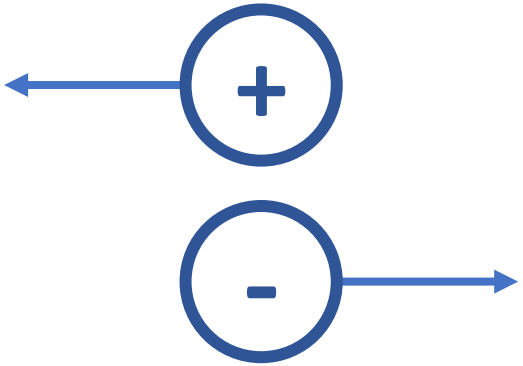

Por Refuerzos

	Supervisado	No supervisado
Objetivo	Predecir salidas para datos nuevos.	Encontrar estructura en los datos.
Aplicaciones	Marketing personalizado. Sentiment Analysis. Churn/Atrition.	Detección de anomalías. Agrupar comportamientos parecidos.
Complejidad		Suelen se mas complejos.
Contras	Dependen mucho de los labels de entrada.	Difíciles de interpretar y pueden no se explicativos.
	Árboles de decisión Modelos de regresión	Pca K-medias

Modelos supervisados

- ***Aprenden*** de los datos clasificados.
- Busco **reglas** para clasificar los nuevos
- Importante ***enseñarle*** con datos buenos
- Es mas fácil evaluar a priori si un modelo es bueno o no

Regresión Logística

Modelos Black Box

SI

- Segmentación de mercado.
- Campañas de marketing.
- Predicción de Churn.

NO

- Decidir si le puedo dar un préstamo/crédito a alguien.
- Se quieren entender que todo el modelo.

Regresión Lineal

Mínimos cuadrados para ajustar una curva
Variables continuas

$$h_\theta(x) = \theta^T x$$

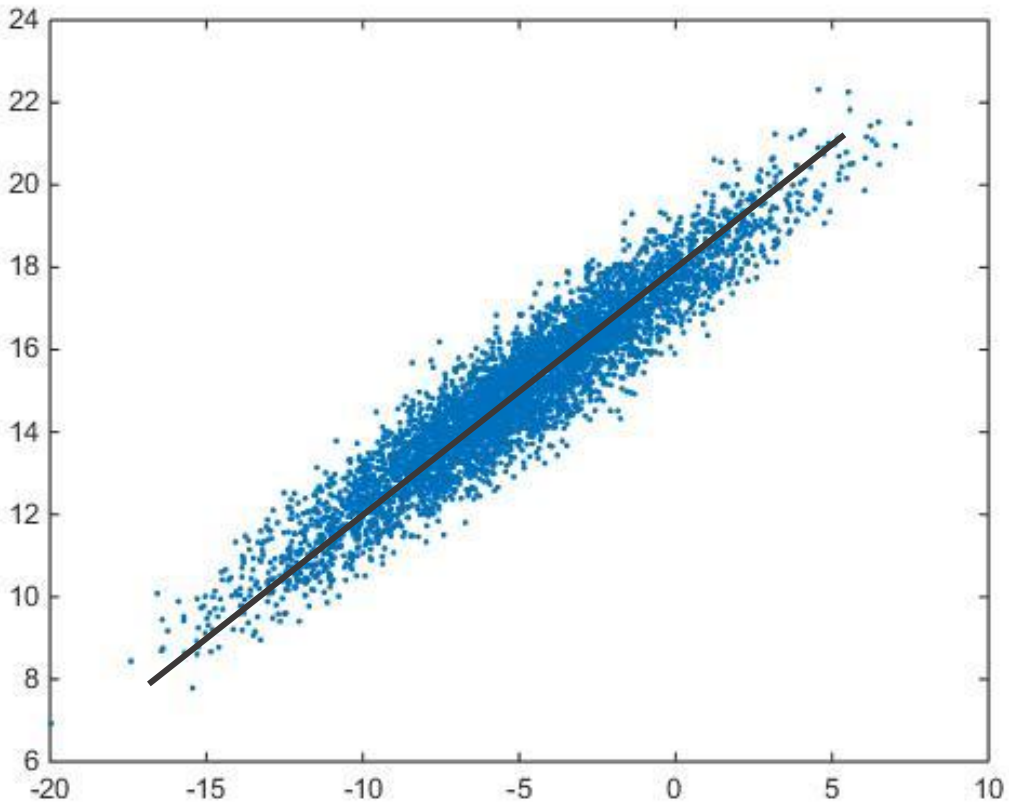

Regresión Lineal

¿Qué pasa cuando lo que quiero aproximar no es continuo?

$$h_\theta(x) = f(\theta^T x)$$

No cumple los supuestos de Regresión lineal

No tiene sentido la aproximación

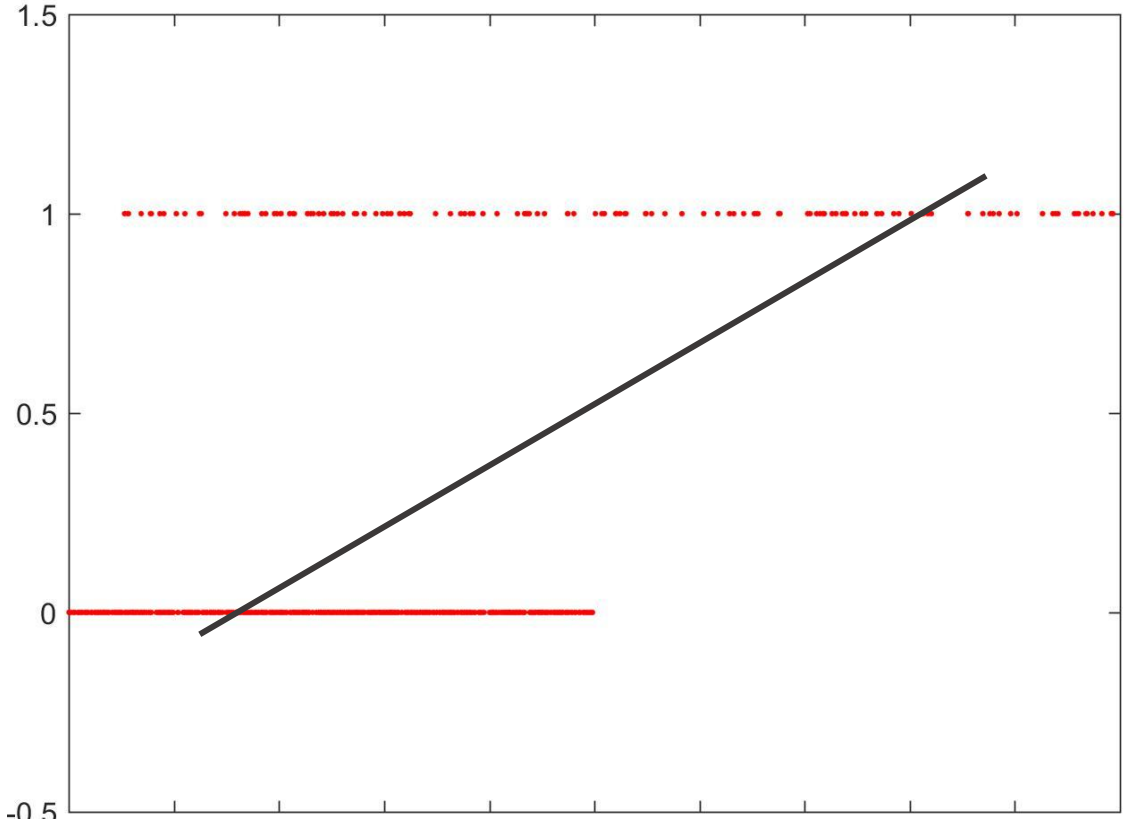

Regresión Logística

- Problemas de clasificación como retención, conversión, probabilidad de compra.

- Variables independientes categóricas o continuas.
- Respuesta binaria (lo que quiero predecir)

Modela la “probabilidad” de un evento con una respuesta categórica (dos salidas).

EJEMPLO

Empresa de seguros quiere estimar la probabilidad de que una persona tenga un accidente automovilístico.

EJEMPLO

Empresa de seguros quiere estimar la probabilidad de que una persona tenga un accidente automovilístico.

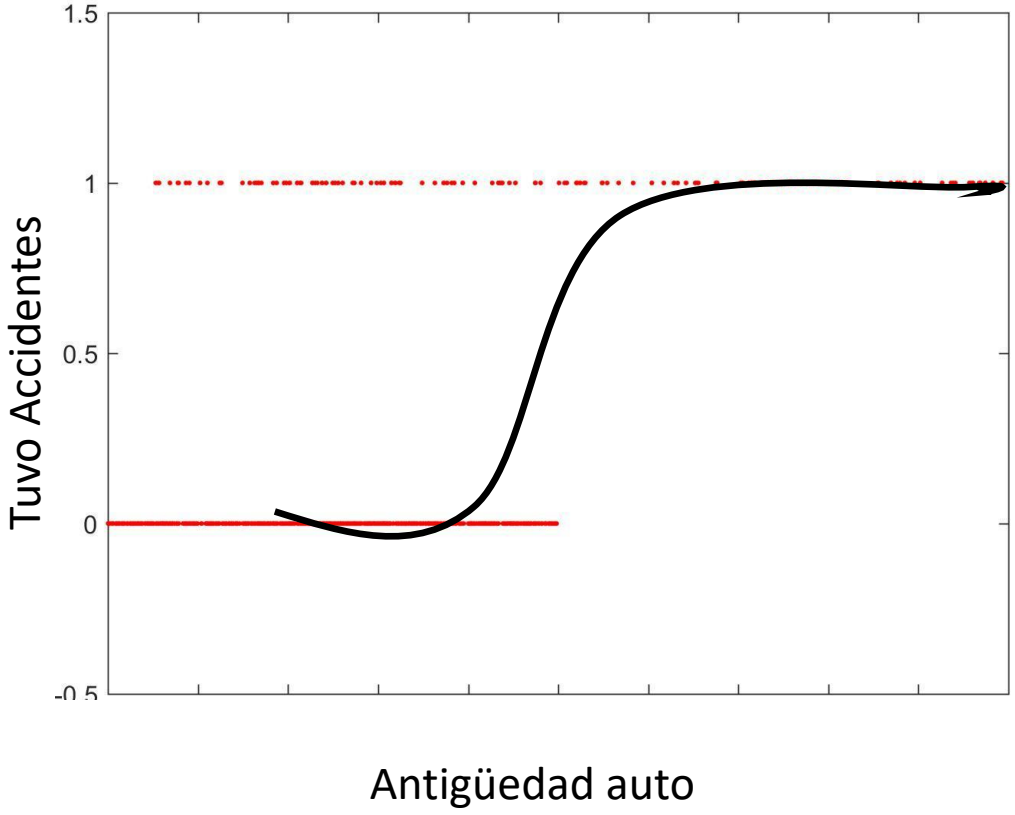

Tuvo accidentes vale 0 cuando la persona no se accidento y 1 en el otro caso.

EJEMPLO

Clientes de un banco

- Cuando toman un préstamo personal.
- Ingreso vs antigüedad

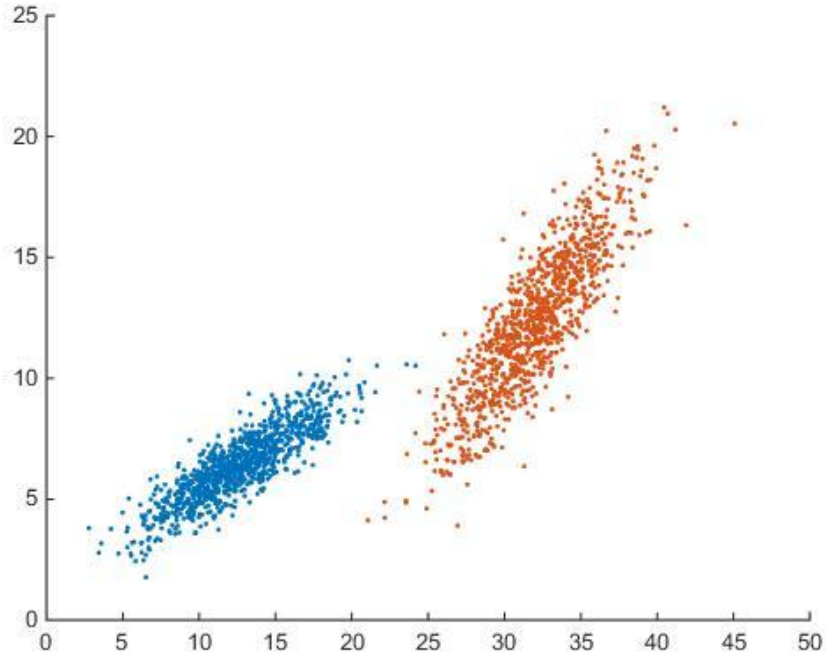

EJEMPLO

Clientes de un banco

- Cuando toman un préstamo personal.
- Ingreso vs antigüedad

Ingreso	Antiguedad
10	7
17	11
21	5
12	17
…	…
…	…
…	…
34	8

- Toman préstamo 1
- No toman préstamo 0

EJEMPLO

Clientes de un banco

- Cuando toman un préstamo personal.
- Ingreso vs antigüedad

Ingreso	Antiguedad	Préstamo
10	7	0
17	11	0
21	5	1
12	17	0
…	…	…
…	…	…
…	…	…
34	8	1

- Toman préstamo 1
- No toman préstamo 0

EJEMPLO

Clientes de un banco

- Cuando toman un préstamo personal.
- Ingreso vs antigüedad

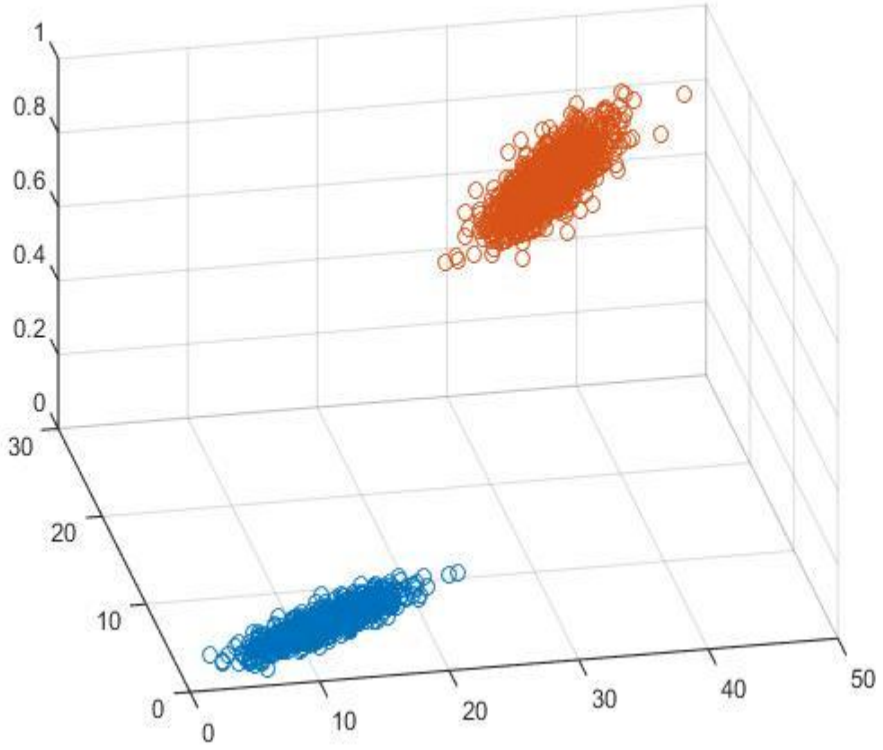

- Toman préstamo 1
- No toman préstamo 0

Regresión Logística

- Busco $p(Y = 1/x, \alpha)$

  $x = \alpha$ son los datos que tengo.

- Para aproximar p_t usa una función sigmoidea:

$$\frac{1}{1 + e^{-f(x)}}$$

$f(x)$ es una función lineal

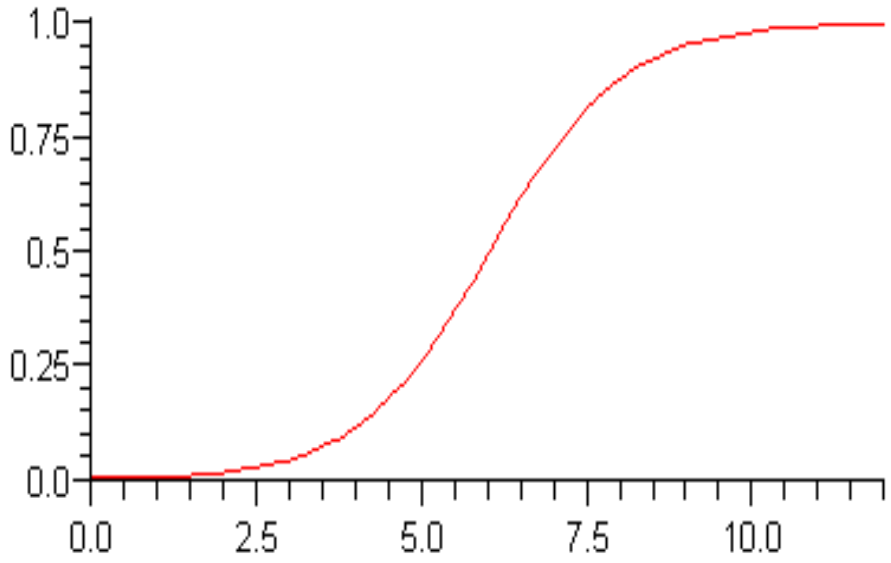

Regresión Logística

Clientes de un banco

- Cuando toman un préstamo personal.
- Ingreso vs antigüedad

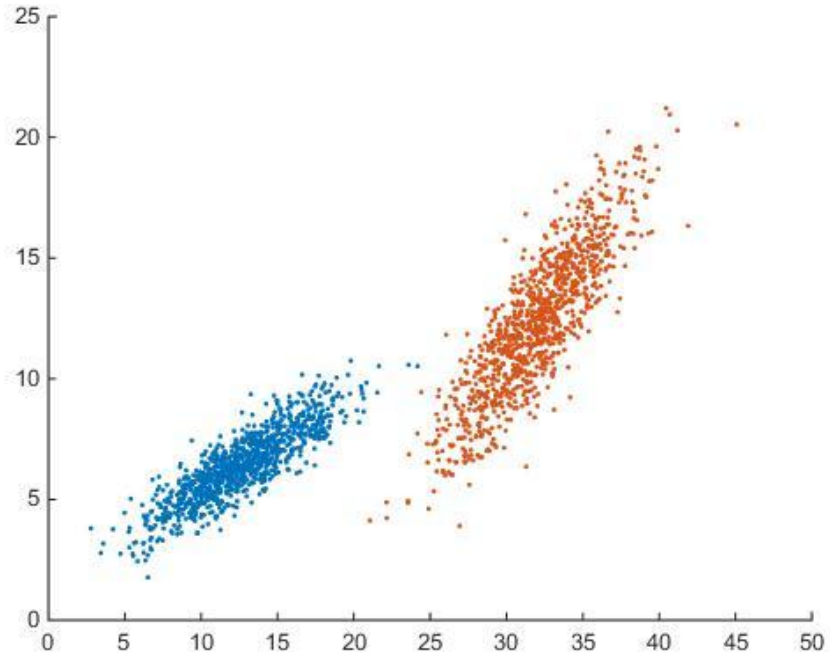

Toman préstamo si $\frac{1}{1+e^{-f(x)}}$>1/2

$$\theta_1 + \theta_2 Ingreso + \theta_3 Ant \geq 0$$

Regresión Logística

Arma la función de costo

¿Cómo?

$$Cost(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & si\ y = 1 \\ -\log(1 - h_\theta(x)) & si\ y = 0 \end{cases}$$

Y los combina para armar la función a minimizar

$$J(\theta) = -y.\log(h_\theta(x)) - (1 - y).\log(1 - h_\theta(x))$$ ***+ Término de regularización***

¿Es bueno el modelo?

- Significatividad de las variables.
  $p<0.05$ (Rechazar Hip nula)
- Prueba Hosmer-Lemeshow
  $p>0.05$ (Acepto el modelo)
- Matriz de confusión y variación del punto de corte

Bondad del ajuste

- A veces a pesar del *p* de las variables, el modelo no predice “tan bien”.
- Mide si el modelo describe adecuadamente los datos.
- Hosmer-Lemeshow indica un pobre ajuste si *p* es menor que 0.05

Regresión Logística

Output del modelo

- Me devuelve la “probabilidad” de que pertenezca al grupo.

Yo puedo decidir donde hago el corte:

- Miro la distribución de registros viejos y elijo un punto de corte. (Curva ROC)

- Si quiero ofrecer un producto a determinada cantidad de clientes, hago el corte ahí.

Accuracy – Recall - Precision

PREDICCION

REAL

	Grupo 0	Grupo 1
Grupo 0	Verdadero Negativo	Falso Positivo
Grupo 1	Falsos Negativo	Verdadero Positivo

- Accuracy = bien clasificados/total de casos

Porcentaje de bien clasificados

- Precision=tP/tP+fP

Porcentaje correcto entre los que dije q eran positivos

- Recall= tP/tP+fN (sensibilidad)

Porcentaje correcto de positivos sobre el universo total de positivos

¿Cómo evaluar los resultados?

A/B testing

Grupos de control

Matriz de confusión

Accuracy

Precision

Recall

F1 Score

Curva ROC

AUC

ROUGE

RL ejemplo Python

Árboles de decisión

Árbol de decisión

- Clasifica los registros
- Variables dicotómicas: pertenencia a un grupo, compra de un producto, enfermos vs sanos. (podría ser continua)
- Aprendizaje Supervisado
- Muy fácil de interpretar y explicar

Árbol de decisión

- Discrete target function
- Data con errores o valores faltantes
- Mejor cuando hay pocos datos numéricos
- Los atributos mas importantes están en la raíz

Árbol de decisión

- En cada paso elije el atributo que mejor separa los grupos.
- Divide los datos de acuerdo al valor (ramas)
- Vuelve a buscar el mejor atributo y repite los pasos anteriores

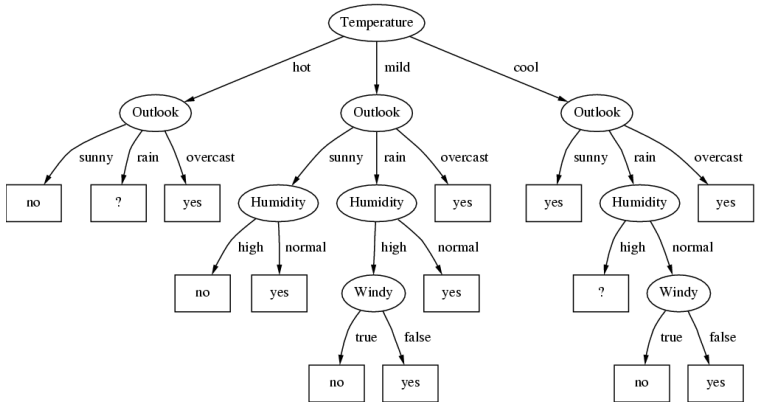

¿Cómo funciona?

¿Cómo funciona?

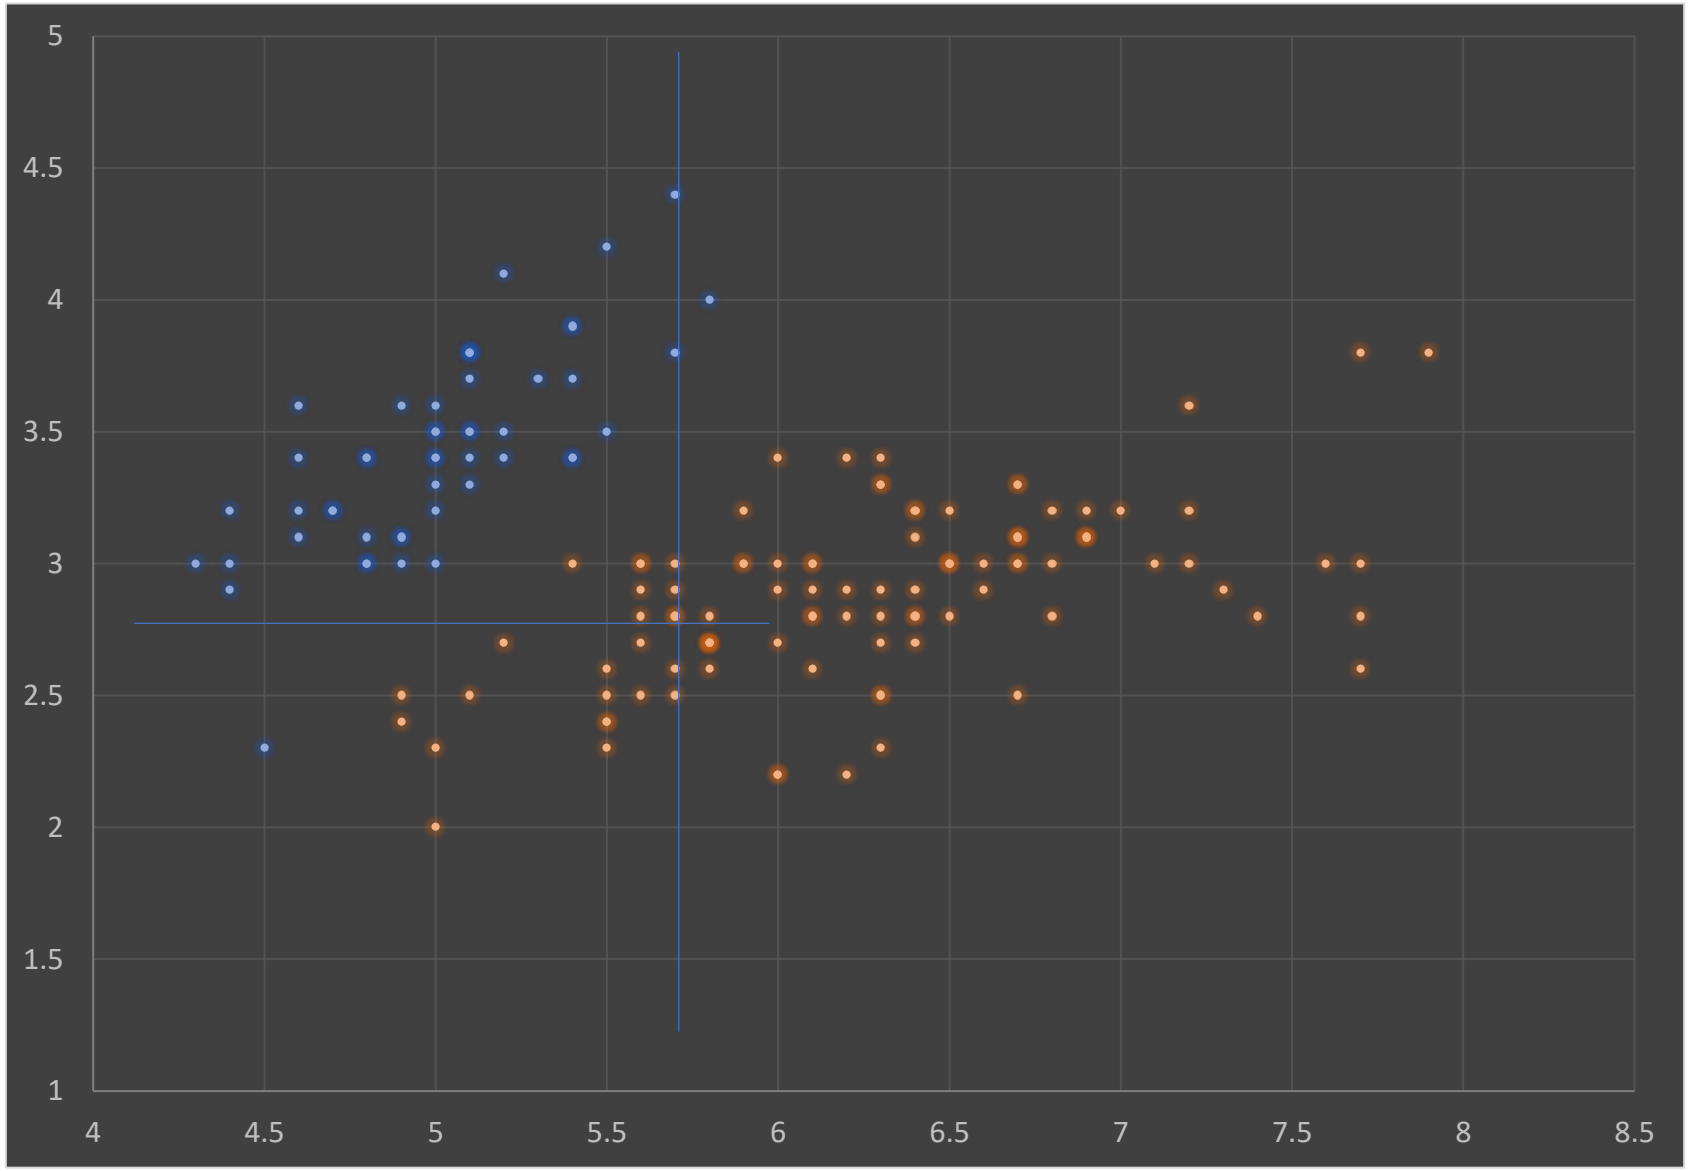

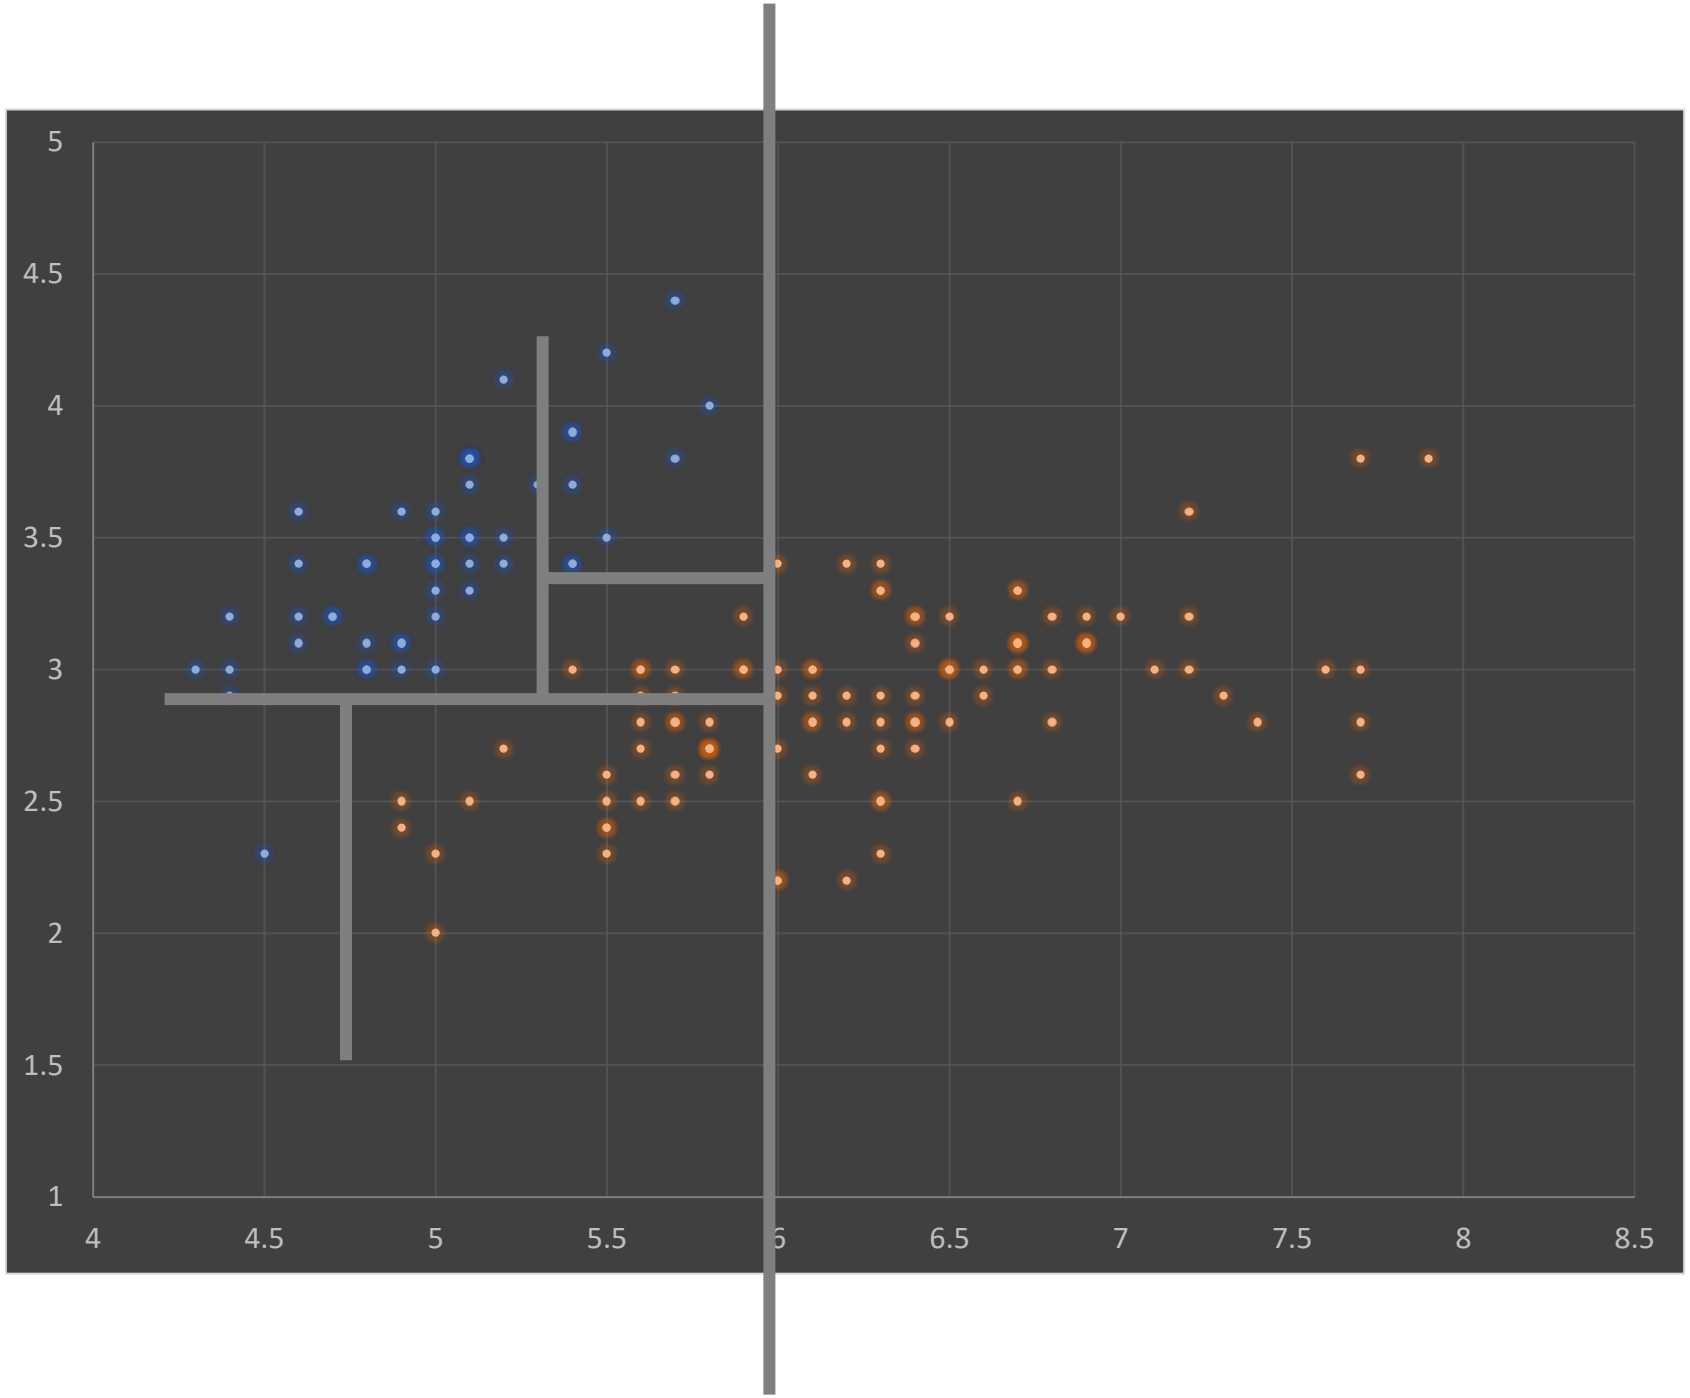
5
4.5
4
3.5
3
2.5
2
1.5
1
4
4.5
5
5.5
6
6.5
7
7.5
8
8.5

Árbol de decisión

Mejorar con respecto a la distribución inicial

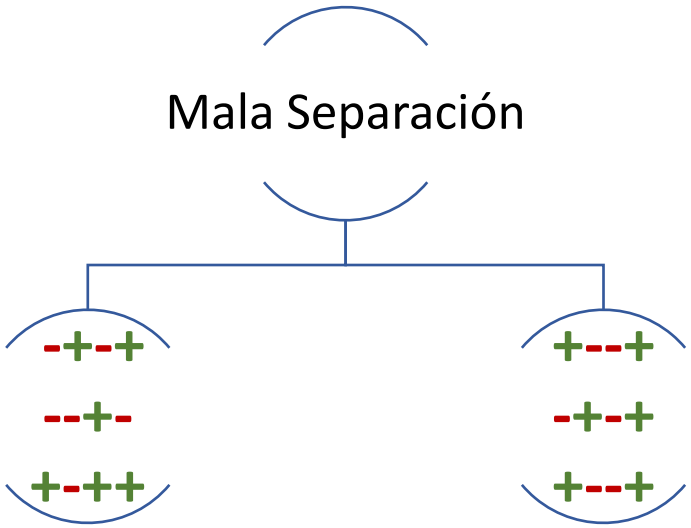

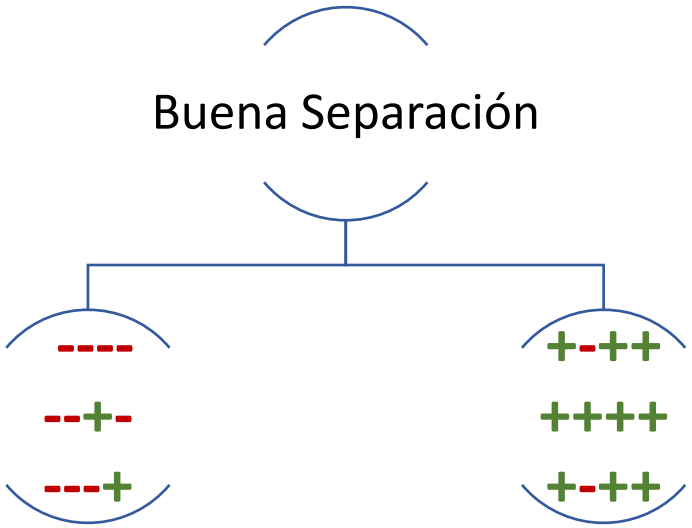

¿Cómo funciona?

Árbol de decisión

Para un nuevo registro, se busca que reglas cumple.

Se obtiene un resultado de acuerdo a ellas.

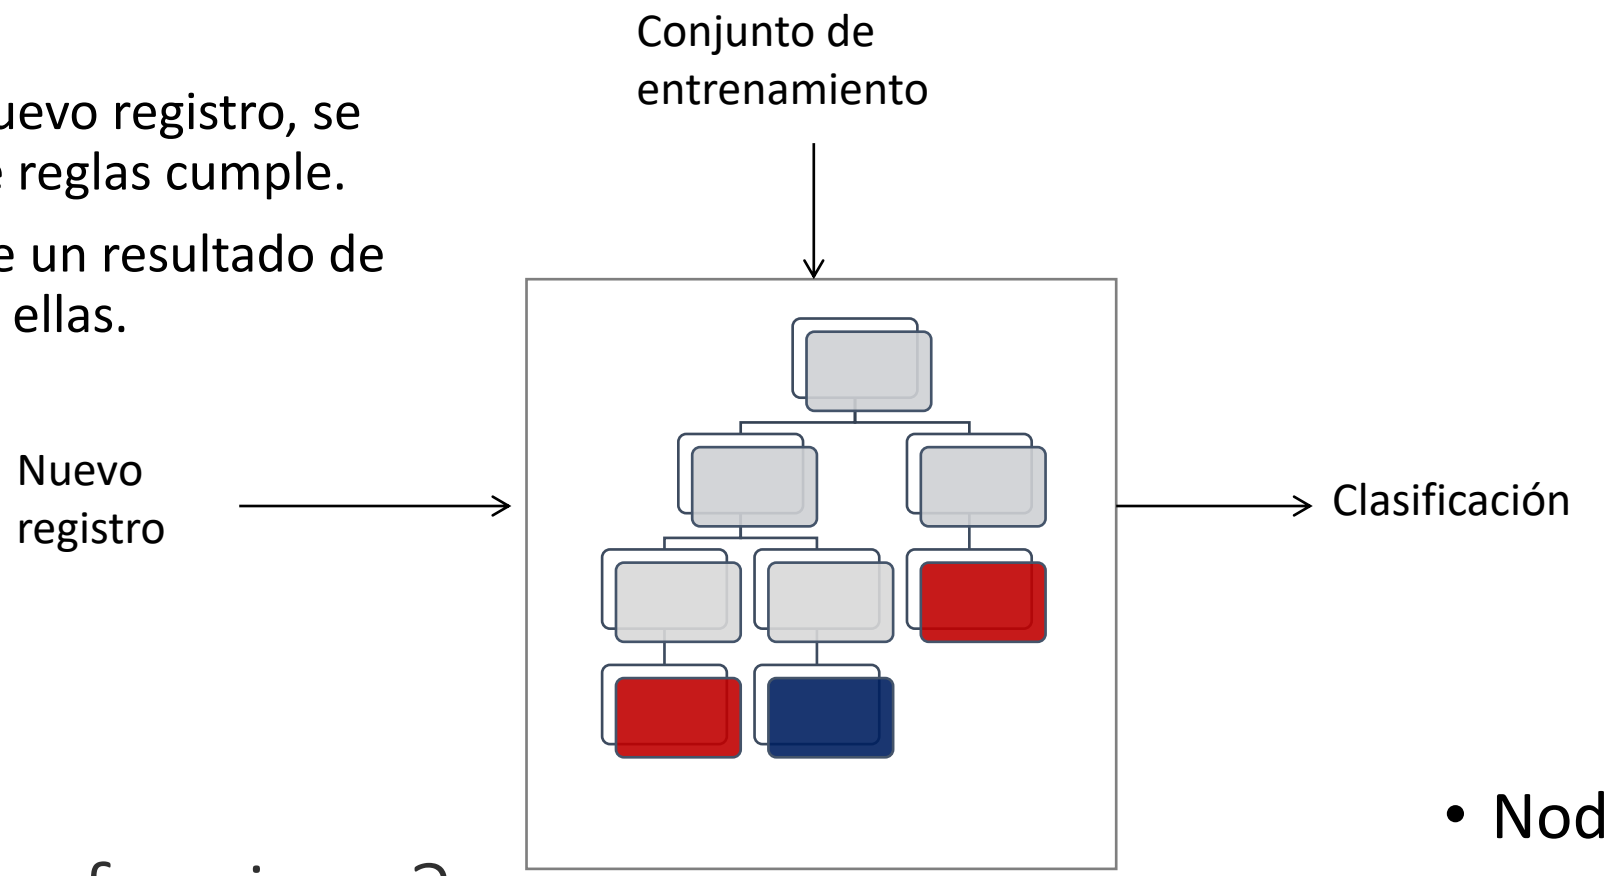

¿Cómo funciona?

- Nodos
- Hojas

Árbol de decisión

Métodos distintos

- CHAID, CART, ID3, C4.5

(criterios de corte)

Parámetros

- Podar el árbol
- Profundidad => para no tener reglas muy complicadas

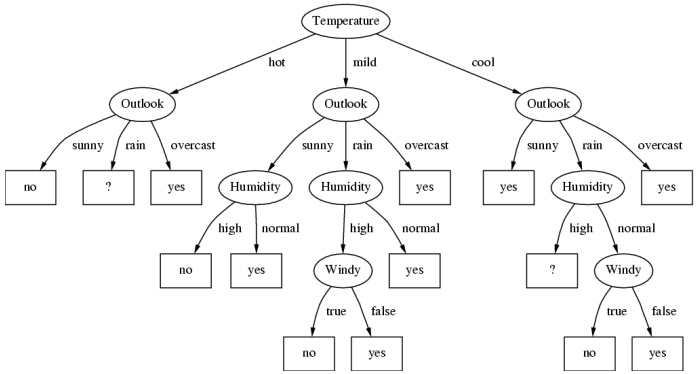

¿Cómo elije cada atributo?

Árbol de decisión

Condiciones de terminación

- Si tenes un nodo homogéneo
- Si la proporción es mayoritaria para un caso
- Profundidad. No más de tantos atributos.

Árbol de decisión

Output del modelo

- Árbol
- Reglas de asignación
- Concentración de casos en cada nodo

Puedo elegir con que nodos quedarme

Random Forest - LightGBM

- Child node
- Node concentration
- Max lenght

Árboles ejemplo Python