Analytics

Clase IV

Julia Picabea

Abril 2026

Next week en Analytics

14h	CHARLA C.V.
15h-17h	PRESENTACIONES

15-20 MINUTOS	TODOS PRESENTAN
5 MINUTOS Q&A	PARA TODOS

Como decidir entre dos modelos?

- Contexto de negocio: que problema quiero resolver?
- Uso de los resultados: como voy a aplicar el modelo?
- Como los mido? Que métrica elegi?
- Cual es la complejidad de cada uno?
- Costo de mantenimiento?

Como decidir entre dos modelos?

Modelo A y B desarrollados para predecir Churn.
Resumen de evaluación de modelos

	Modelo A	Modelo B
Recall	69%	77%

Puedo decir que es mejor el modelo B?
Cuantos registros elegí para llegar a esos valores?

Como decidir entre dos modelos?

Cuantos registros elegí para llegar a esos valores?

Modelo A

Predicción/Real	0	1
0	359	117
1	575	257

832K registros

Modelo B

Predicción/Real	0	1
0	55	87
1	879	287

1162K registros

Modelo A es recall al 64%

Modelo B es recall al 89%

	Modelo A	Modelo B
Recall	69%	77%

Como decidir entre dos modelos?

Modelo A y B desarrollados para predecir Churn.
Resumen de evaluación de modelos

	Modelo A	Modelo B
Recall	69%	77%

Falta saber a que porcentaje del total tenes que agarrar para llegar a ese Recall

Comparar curva ROC

Modelo A es recall al 64%

Modelo B es recall al 89%

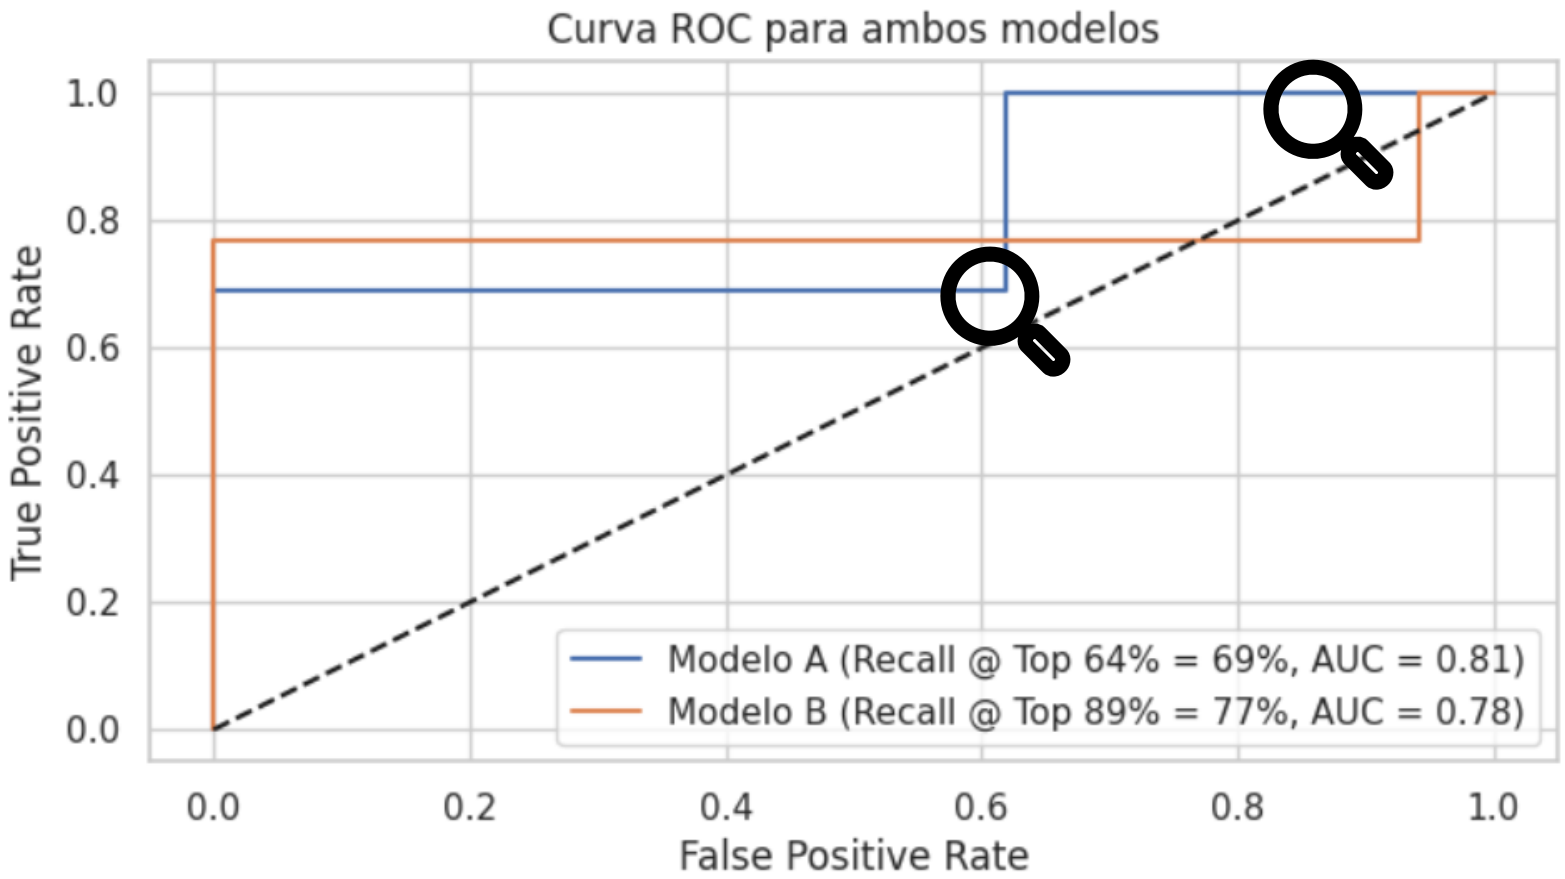

Comparar curva Recall

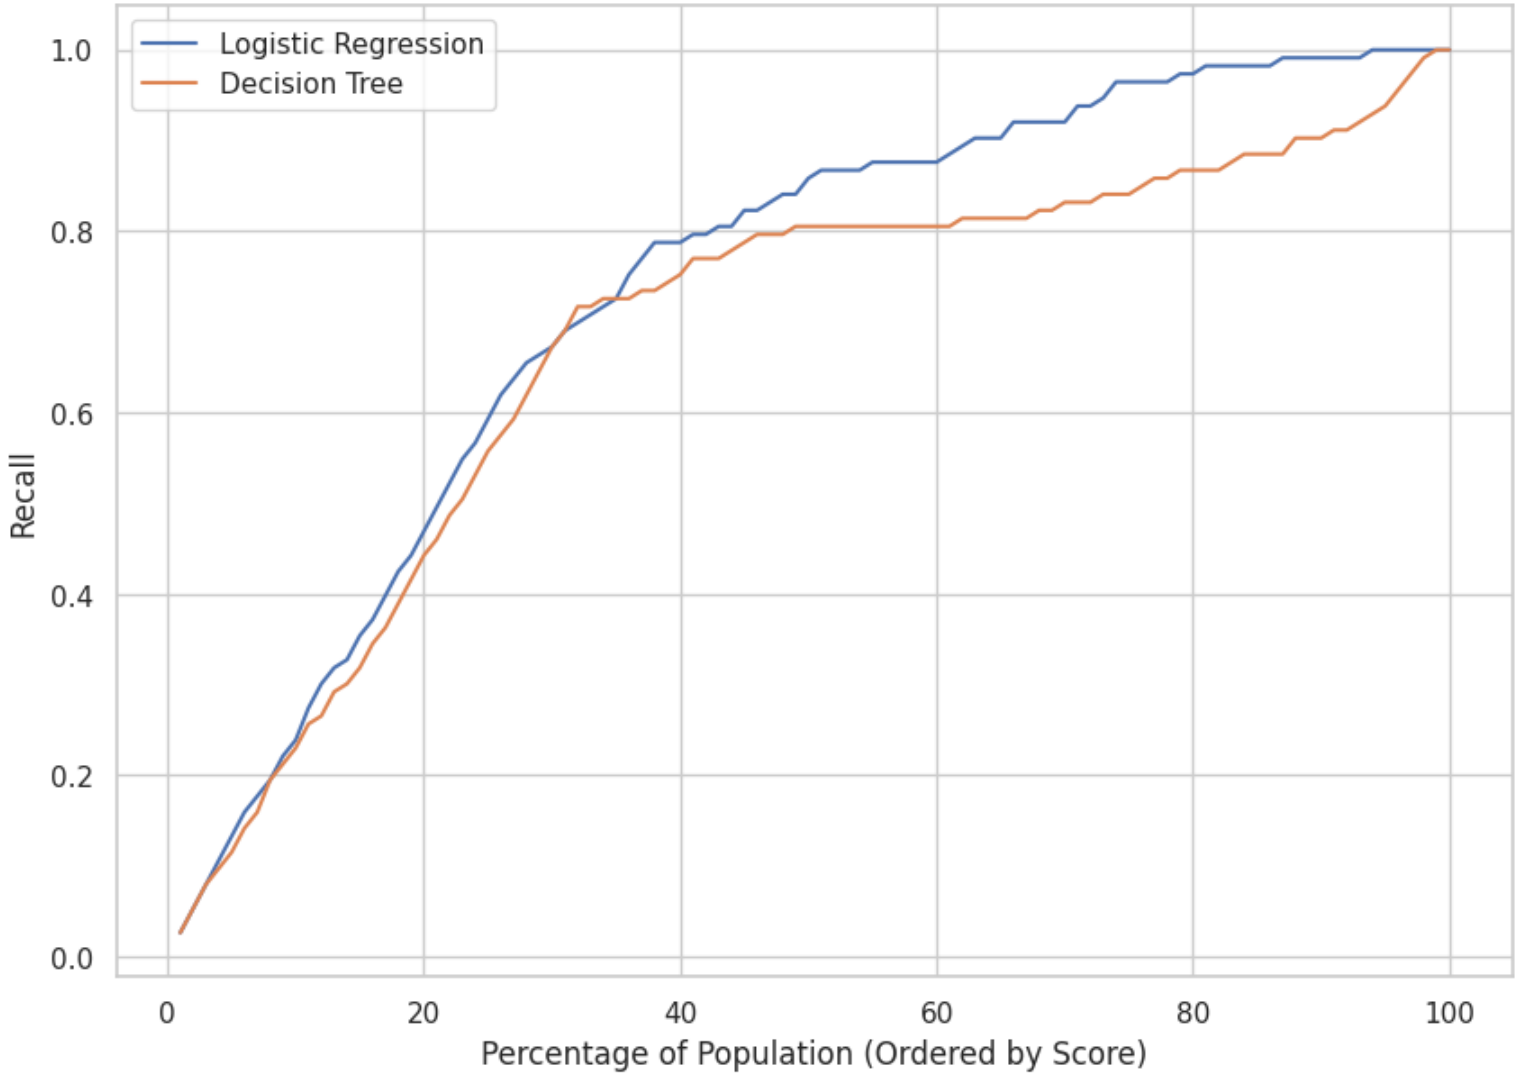

Comparar curva ROC

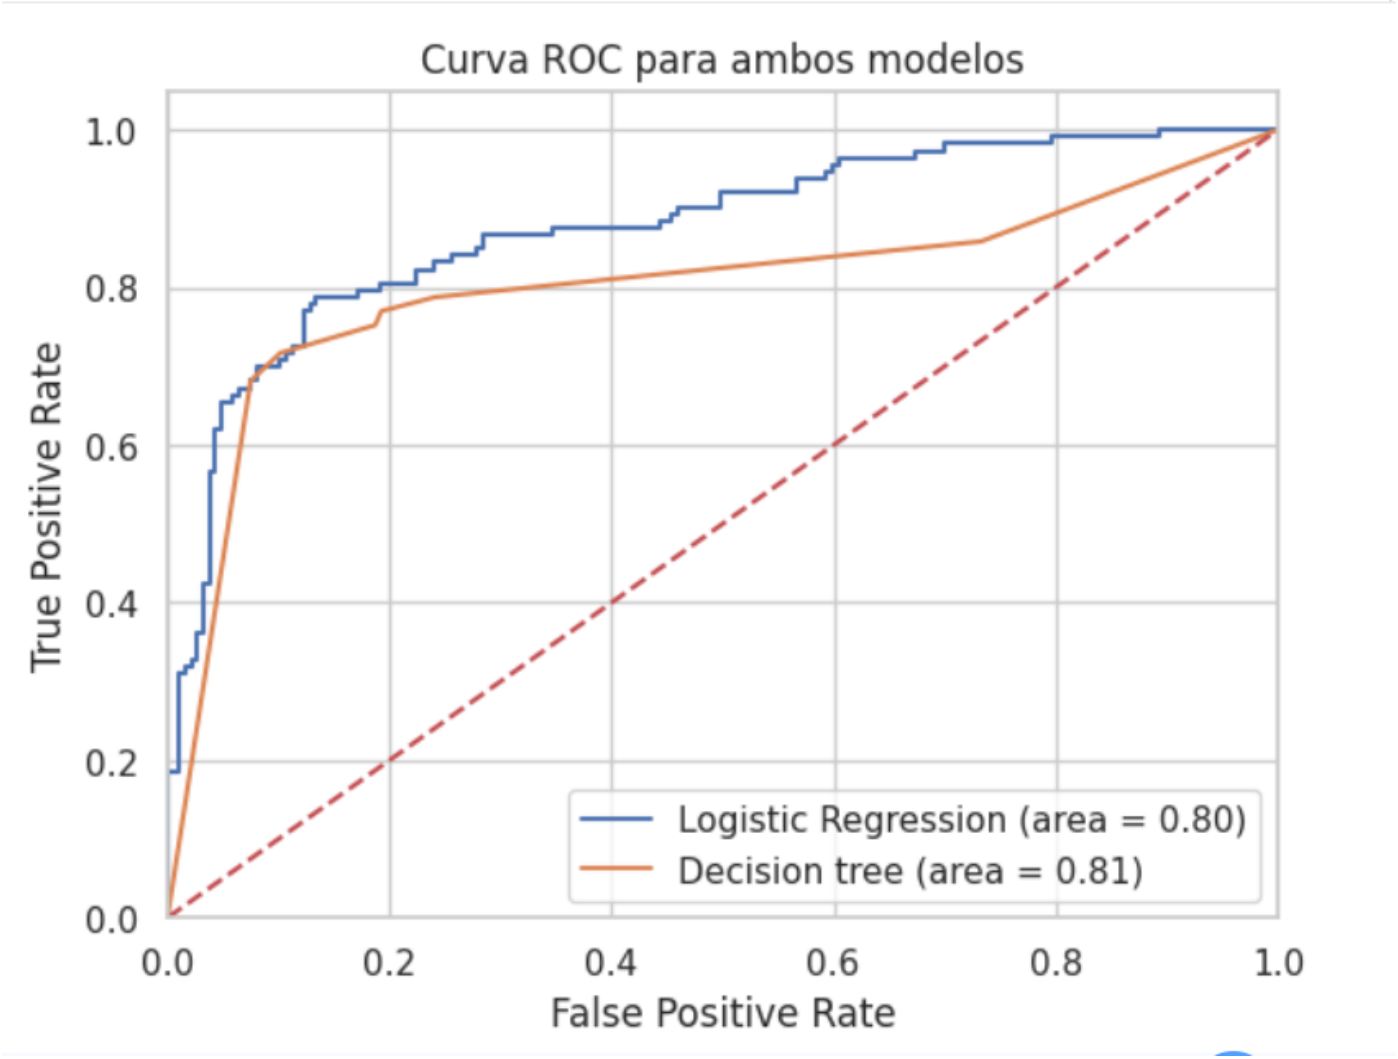

	Supervisado	No supervisado
Objetivo	Predecir salidas para datos nuevos.	Encontrar estructura en los datos.
Aplicaciones	Marketing personalizado. Sentiment Analysis. Churn/Atrition.	Detección de anomalías. Agrupar comportamientos parecidos.
Complejidad		Suelen se mas complejos.
Contras	Dependen mucho de los labels de entrada.	Difíciles de interpretar y pueden no se explicativos.
	Árboles de decisión Modelos de regresión	Pca K-medias

K medias

K medias

Características

- Aprendizaje no supervisado
- Agrupa los registros que son parecidos
- Hay q definir cuantos grupos se quiere
- Decidir que métrica usar

Gráficamente

(a)

Gráficamente

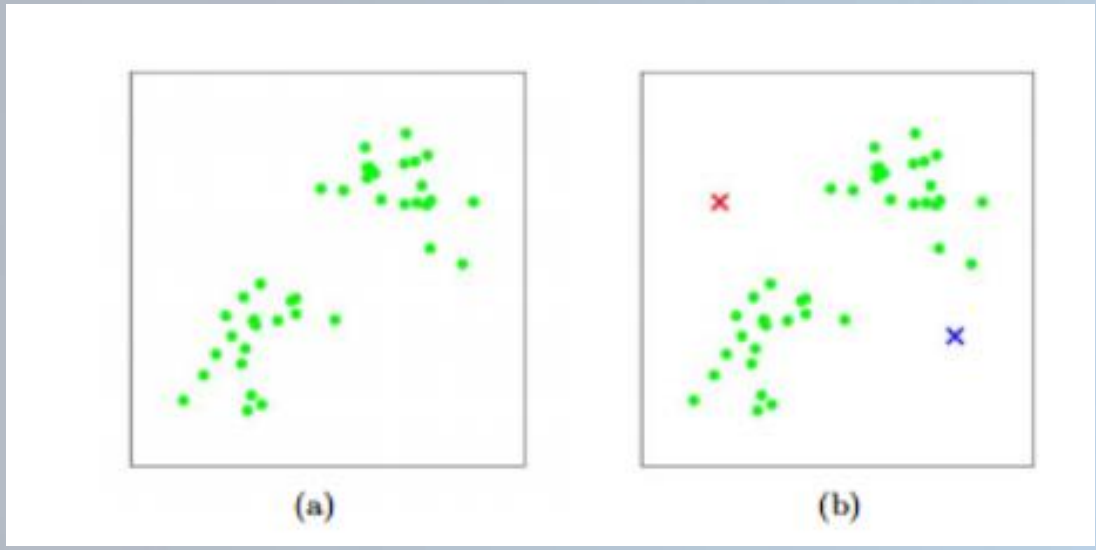

Gráficamente

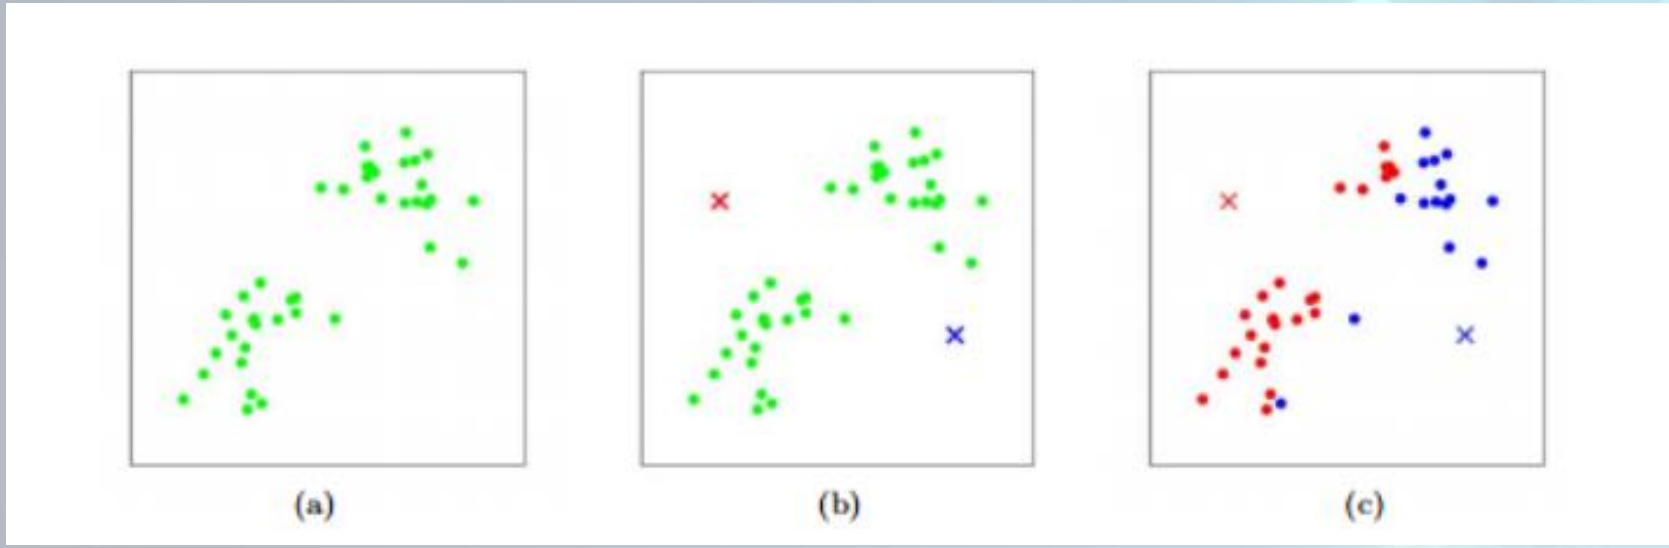

Gráficamente

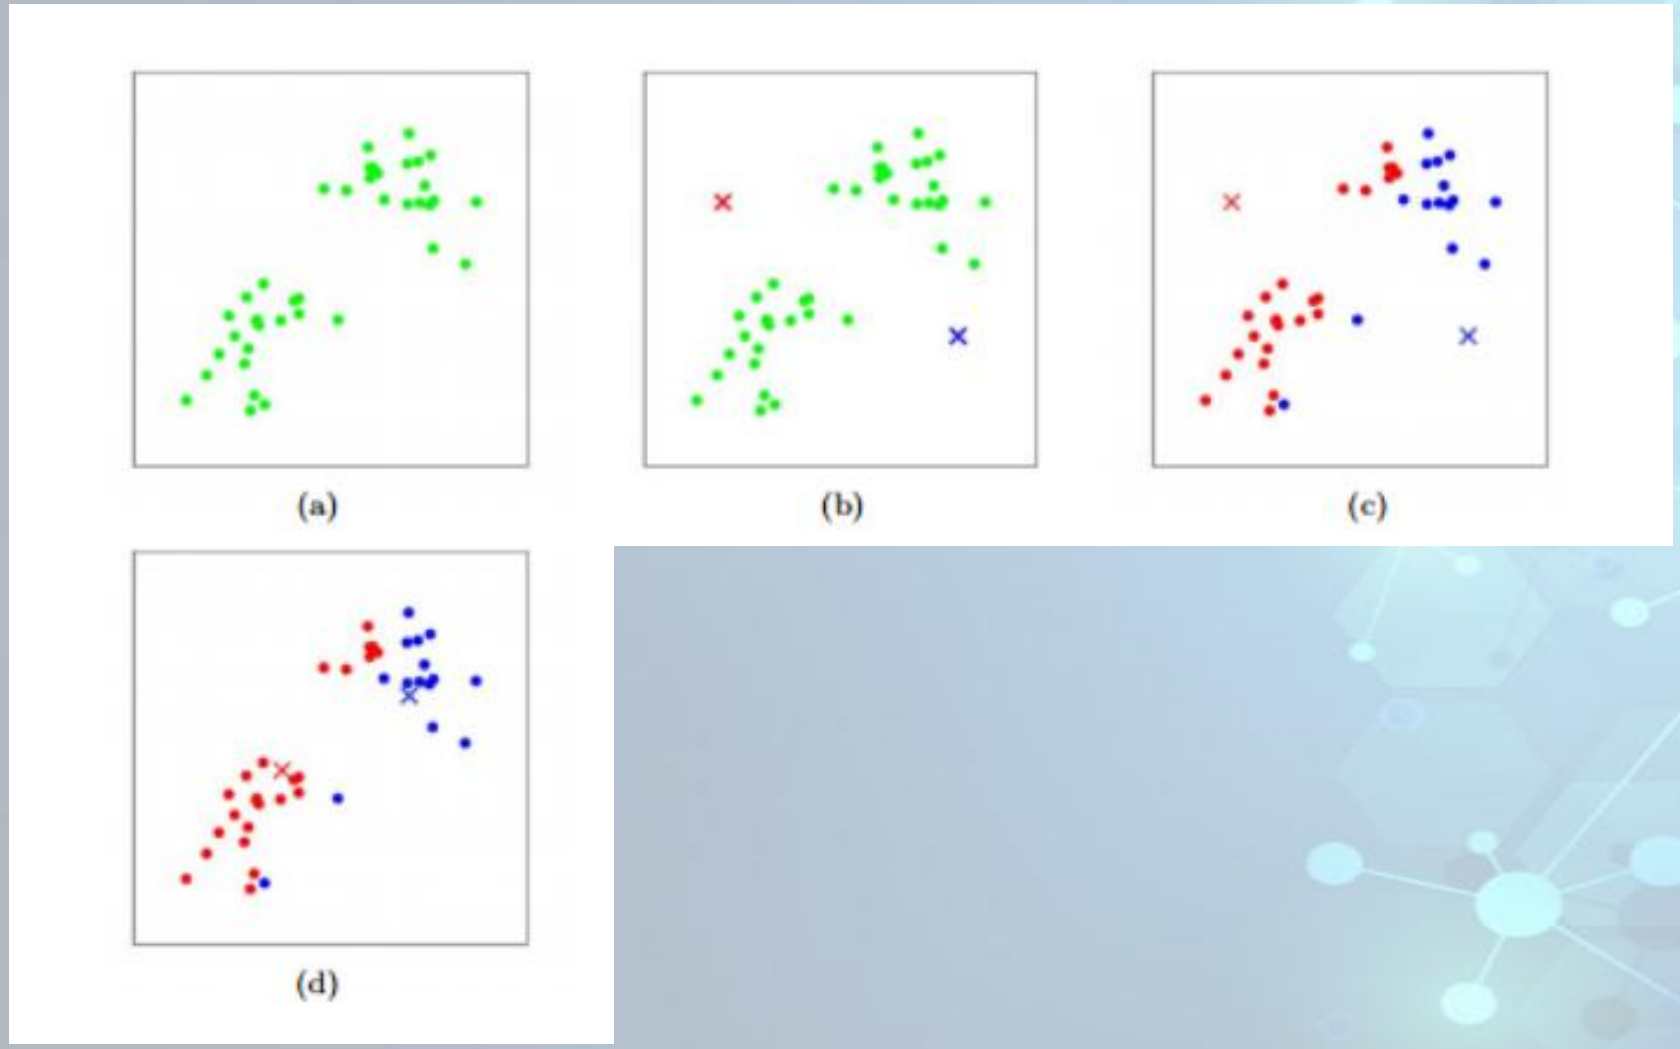

Gráficamente

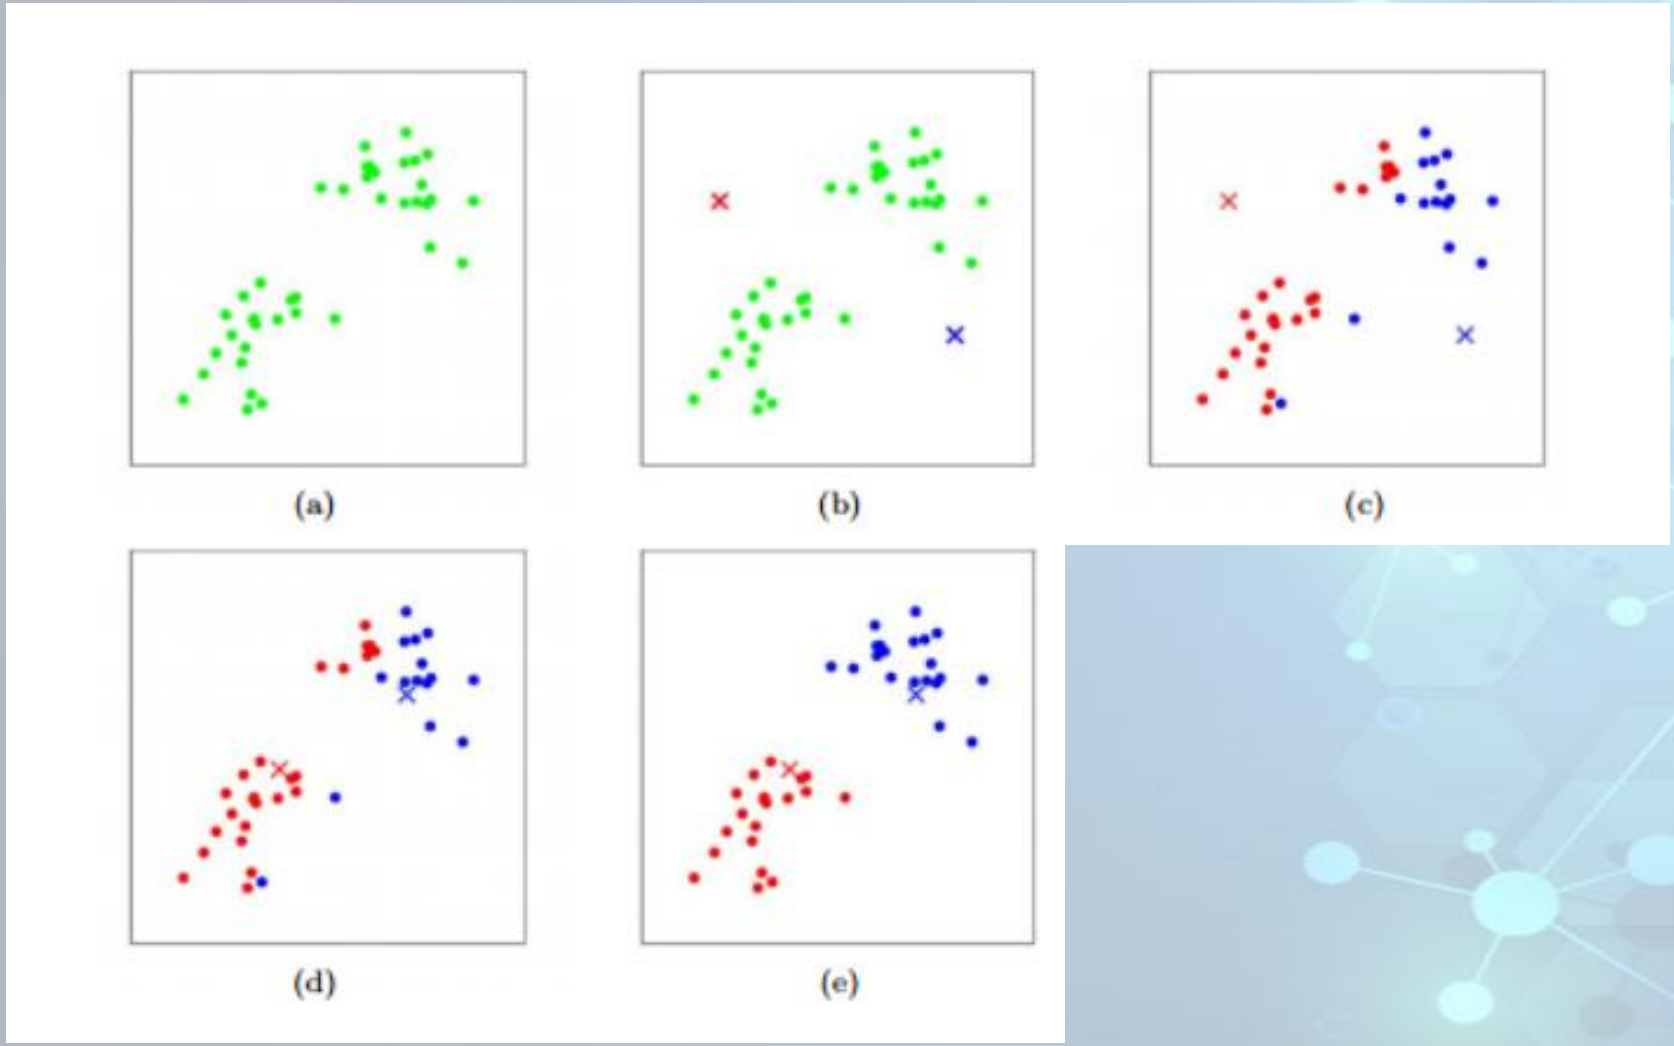

Gráficamente

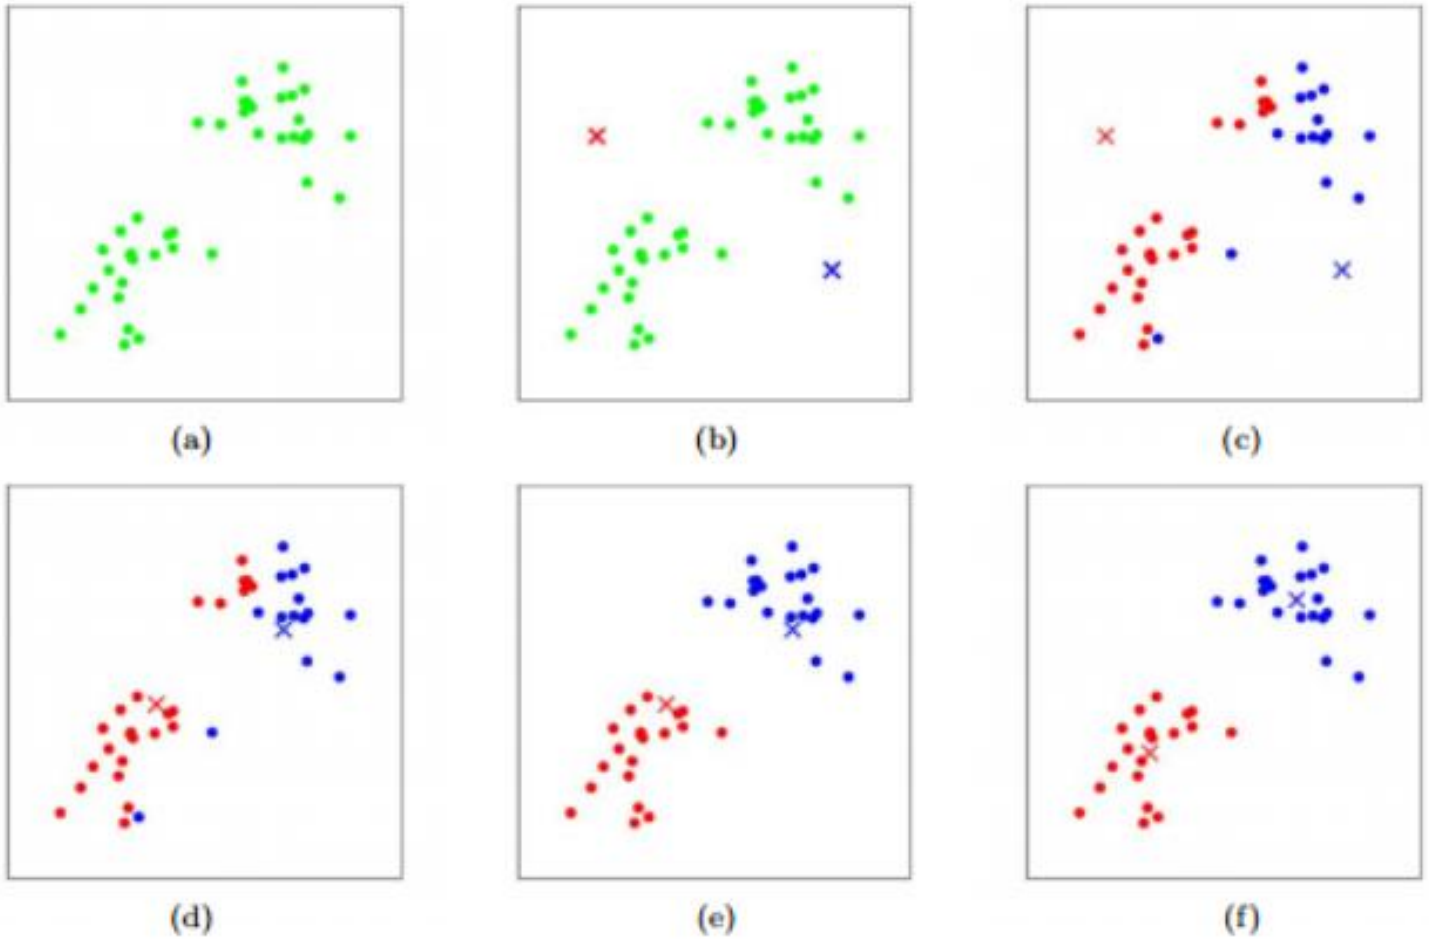

K medias

- Elije k centroides
- Calcula la distancia de cada punto a los centros
- Lo agrupa con el que tiene distancia mínima
- Recalcula los centroides por cada grupo
- Vuelve al punto 2

Termina cuando no hay cambios o max iteración

¿Cómo funciona?

K medias

Contras

- Difícil de interpretar
- Sensible a los centros iniciales
- Hay que definir a priori cuantos grupos

K-medias

Métrica	Descripción
Centroides	Que tan separados están los centroides
Elbow/Codo	Cuantos grupos conviene usar
Silueta	Que tan bien definidos están los clusters

Métricas comunes

K-medias

Gráfico de elbow (codo)

Cantidad de grupos vs Suma de distancias

- Mayor k menor suma
- Codo cuando la mejora empieza a ser menor

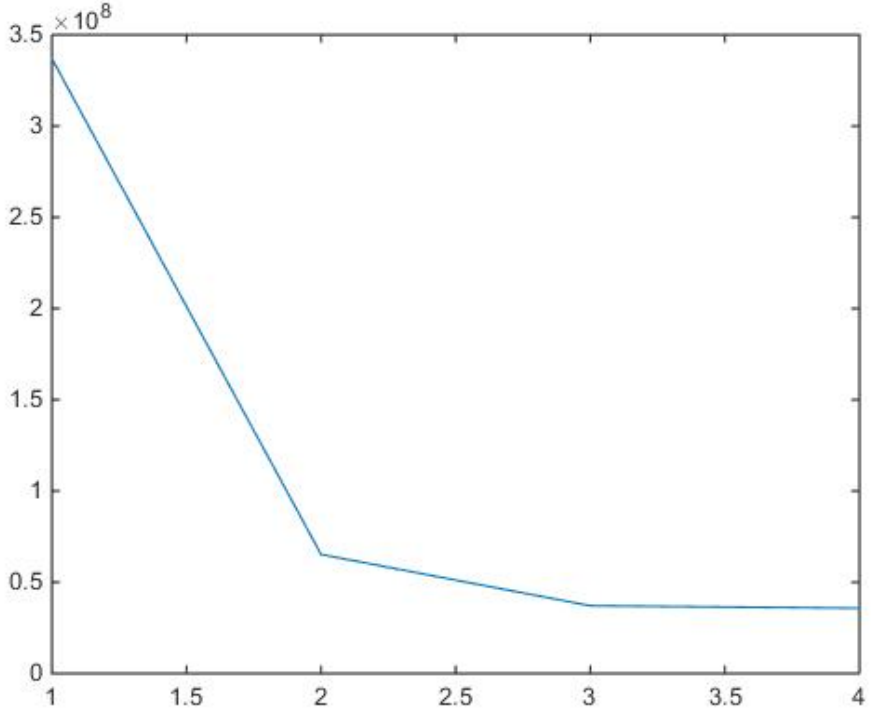

K-medias

Gráfico de silhouete (silueta)

Homogeneidad: que tan parecidos son dentro del cluster

Medida entre [-1, 1] de que tan bien asignado esta ese registro a un cluster.

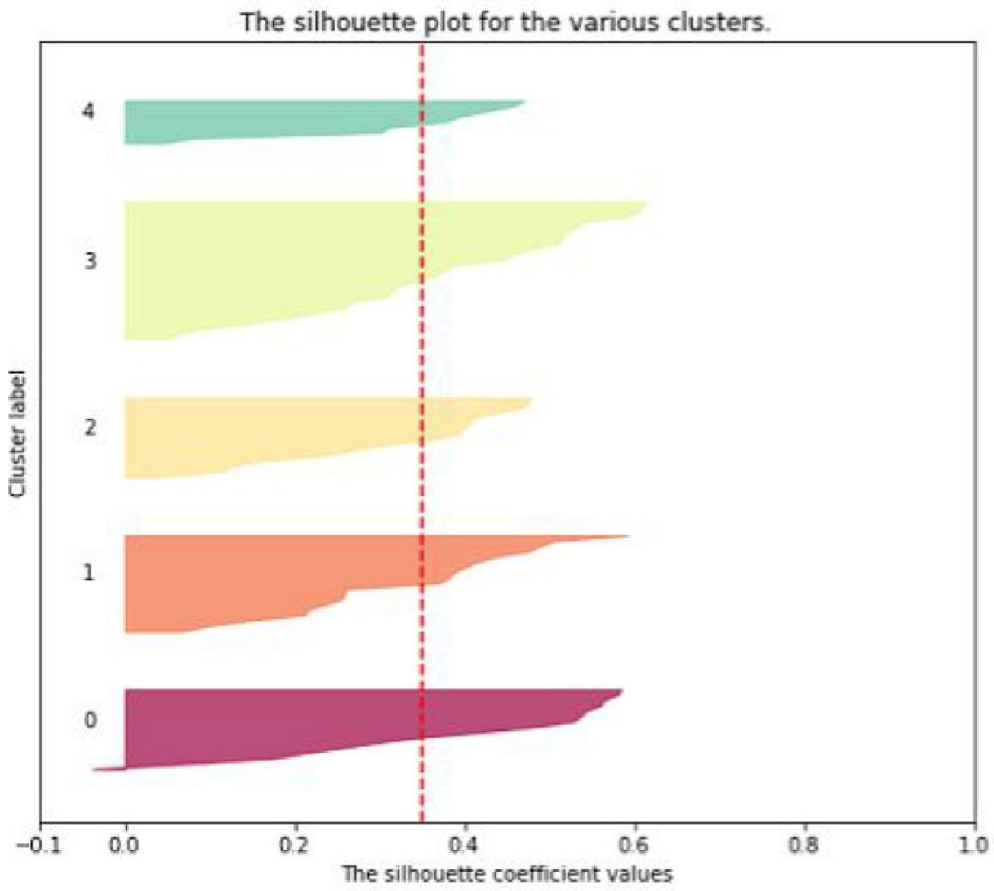

K-medias

Gráfico de silhouete (silueta)

Que tan parecido es el registro a los registros del mismo cluster comparado con los otros clusters.

$$\mathrm{S(i)} = \frac{b(i) - a(i)}{\max(b(i), a(i))}$$

$a(i)$ es el promedio de las distancias a todos los puntos del mismo cl

$b(i)$ es el promedio de las distancias al cl mas cercano (no asignado)

K-medias

Gráfico de silhouete (silueta)

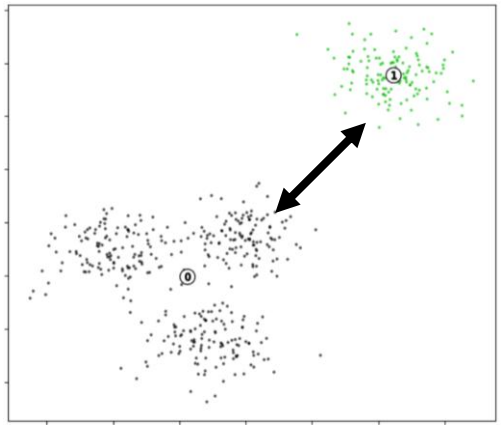

CS alto
Separación clara
- 0.85

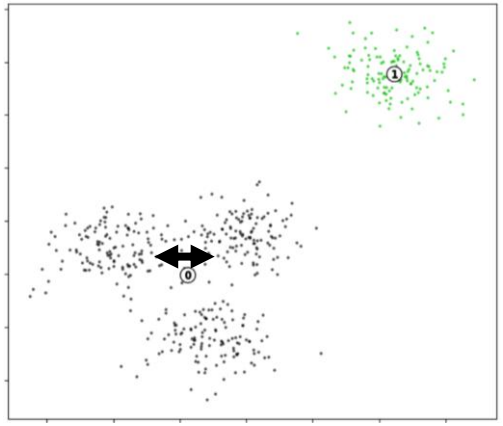

CS bajo
Separación difusa
- 0.35

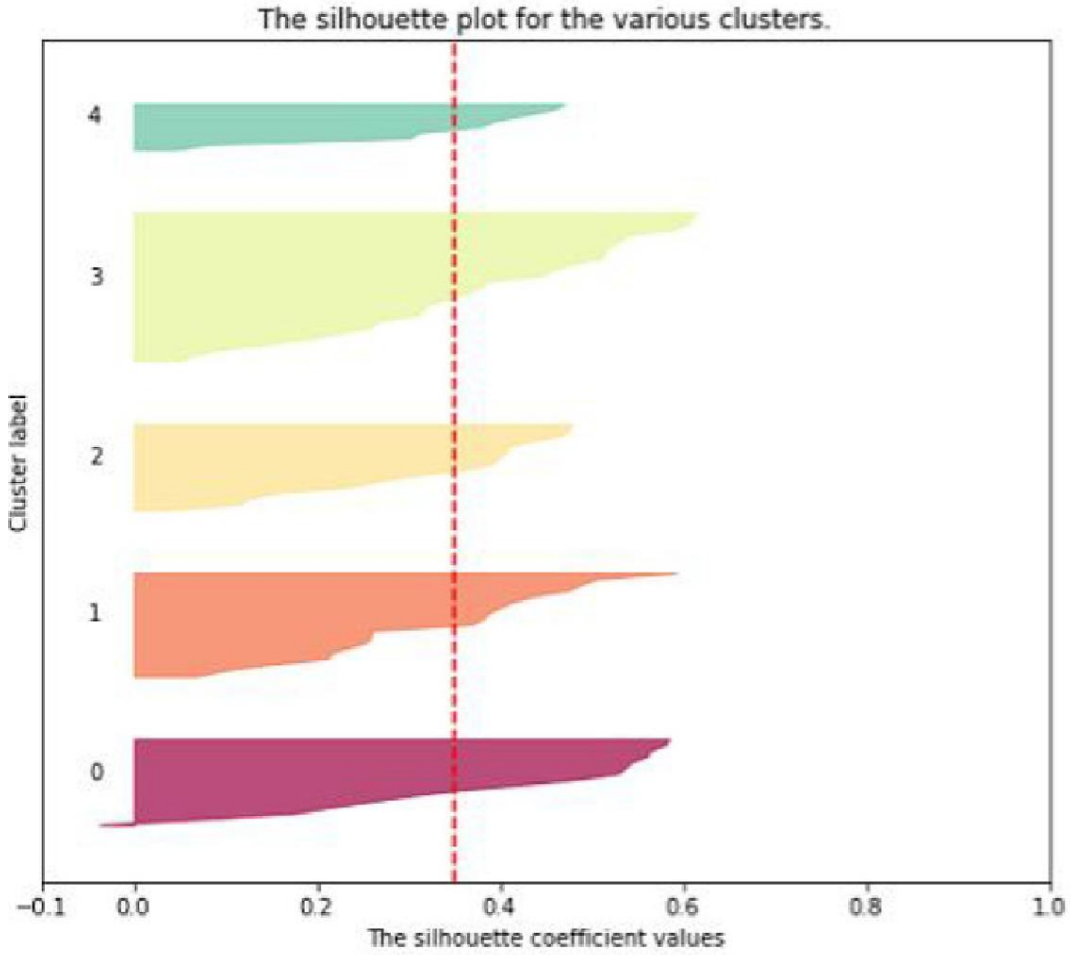

K-medias

Gráfico de silhouete (silueta)

- Tamaño de los clusters
- Diversidad del cluster
- Registros mal clasificados

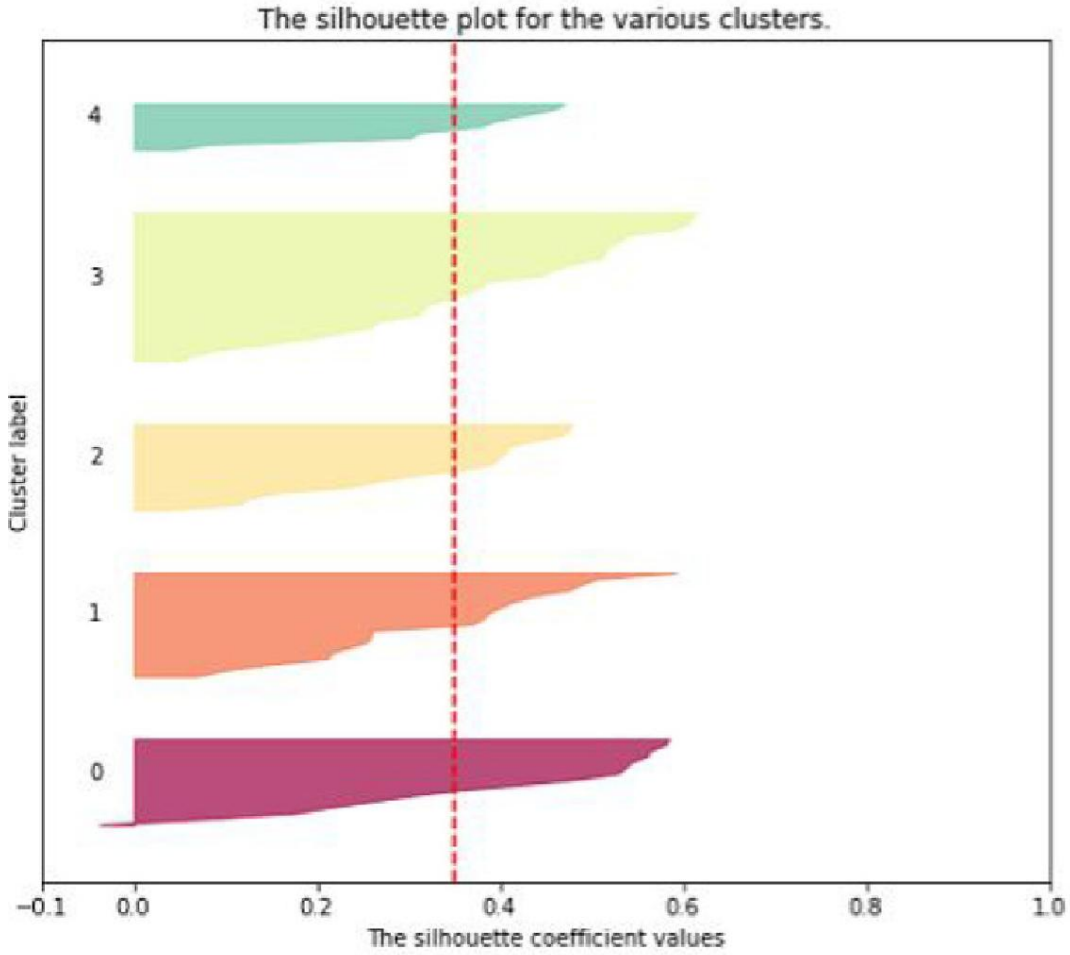

Evaluando resultados de kmedias

https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html

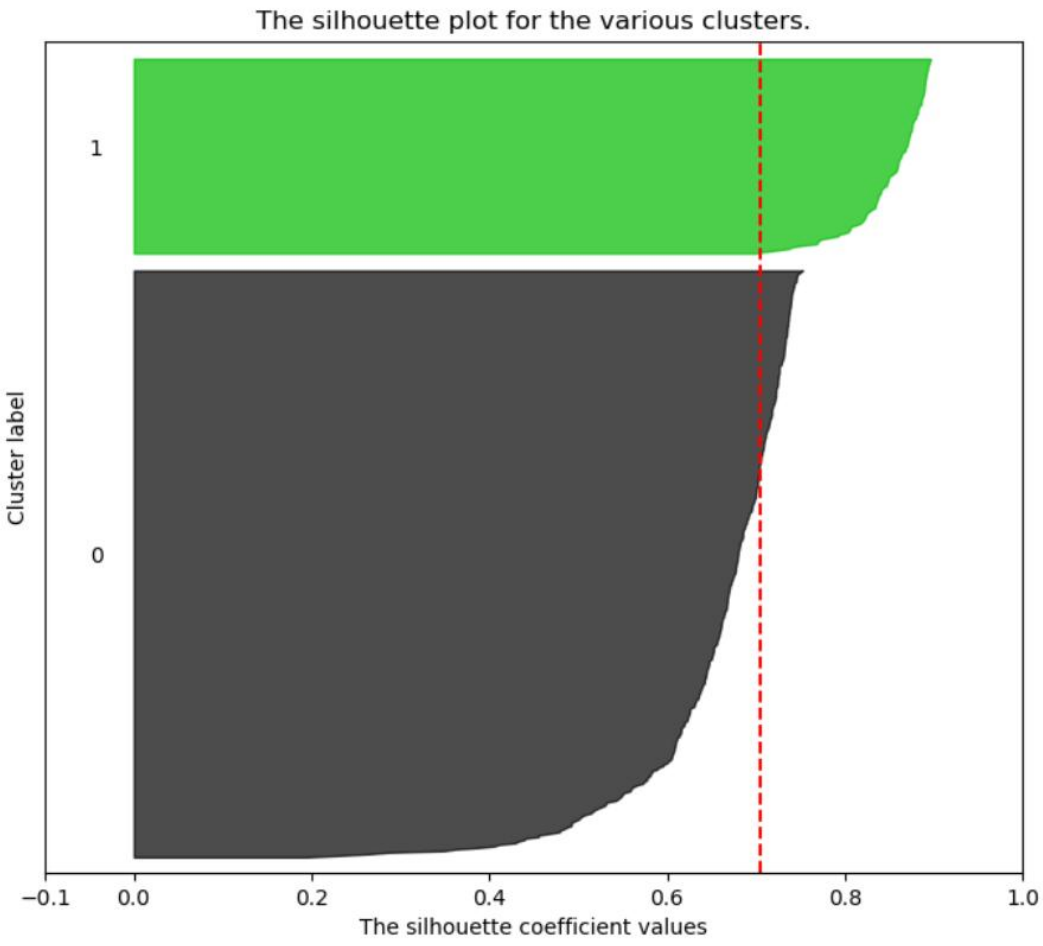
The silhouette plot for the various clusters.
Cluster label
1
0
−0.1
0.0
0.2
0.4
0.6
0.8
1.0
The silhouette coefficient values

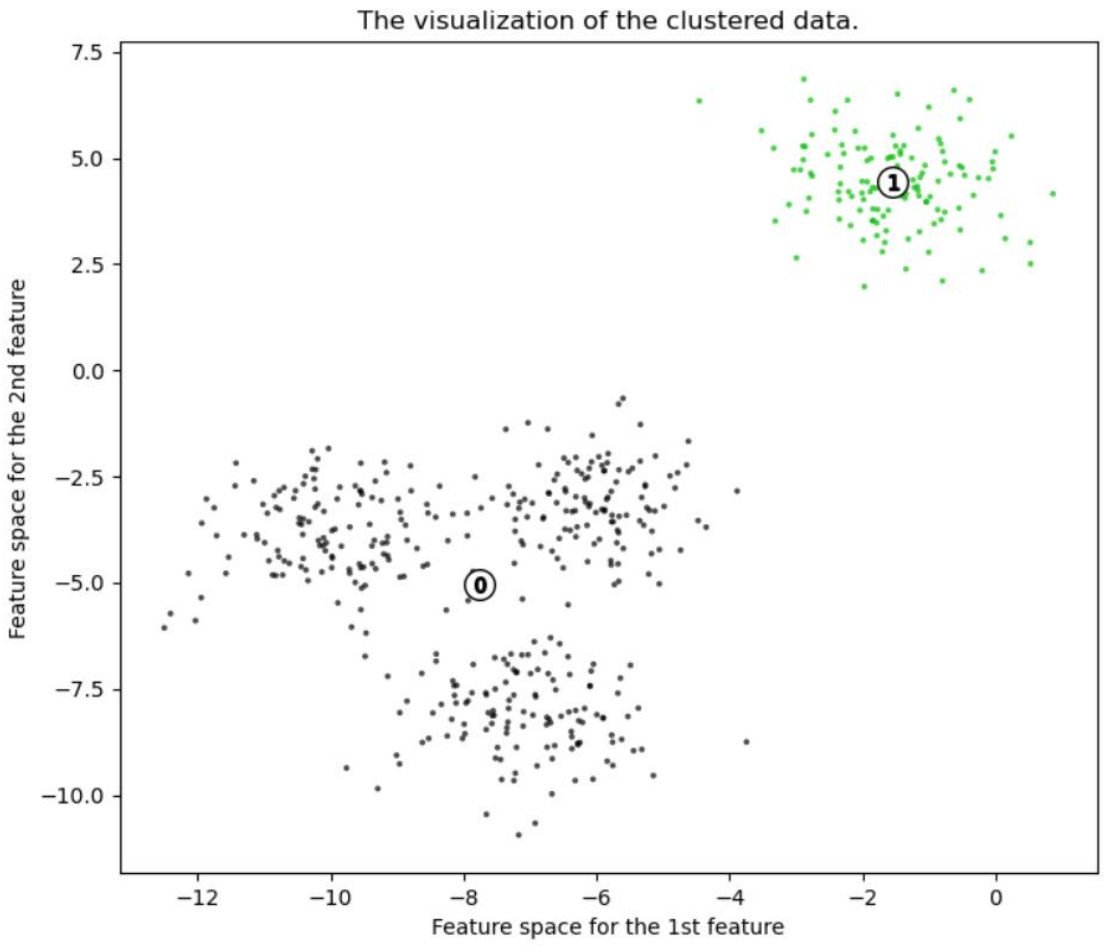
The visualization of the clustered data.
Feature space for the 2nd feature
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
1
0
−12
−10
−8
−6
−4
−2
0
Feature space for the 1st feature

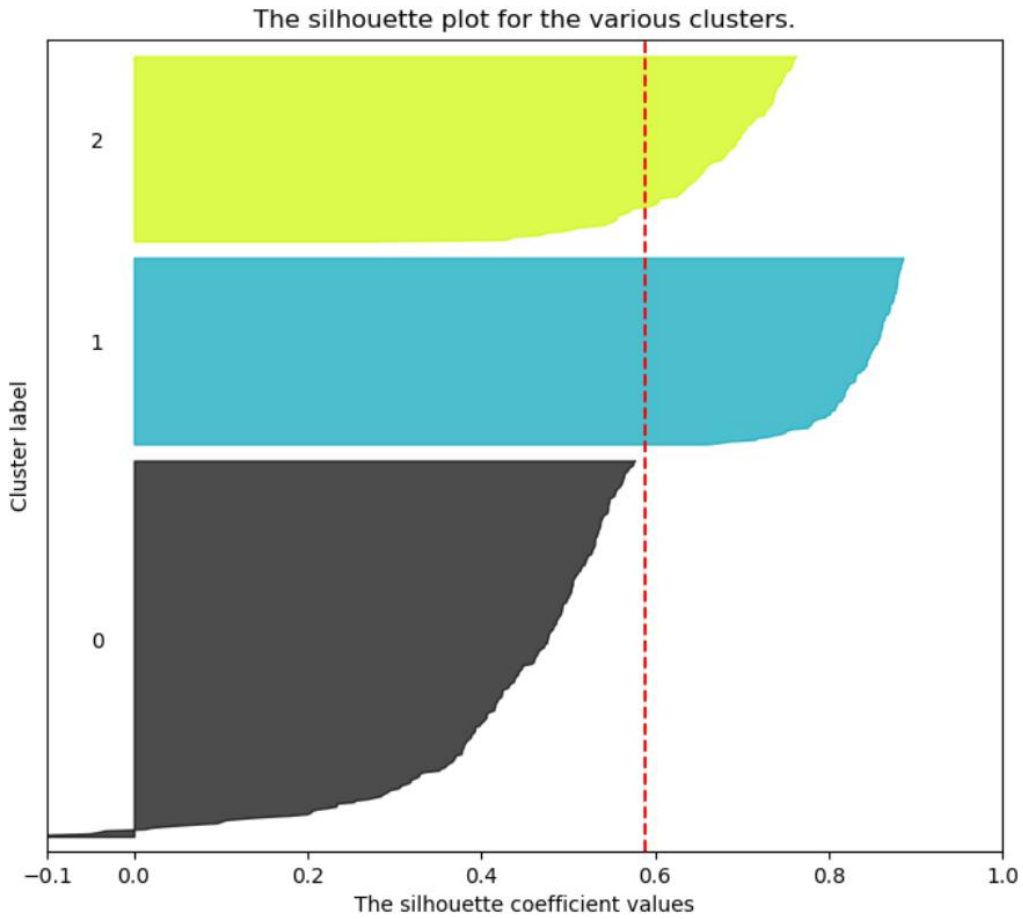
The silhouette plot for the various clusters.
Cluster label
2
1
0
−0.1
0.0
0.2
0.4
0.6
0.8
1.0
The silhouette coefficient values

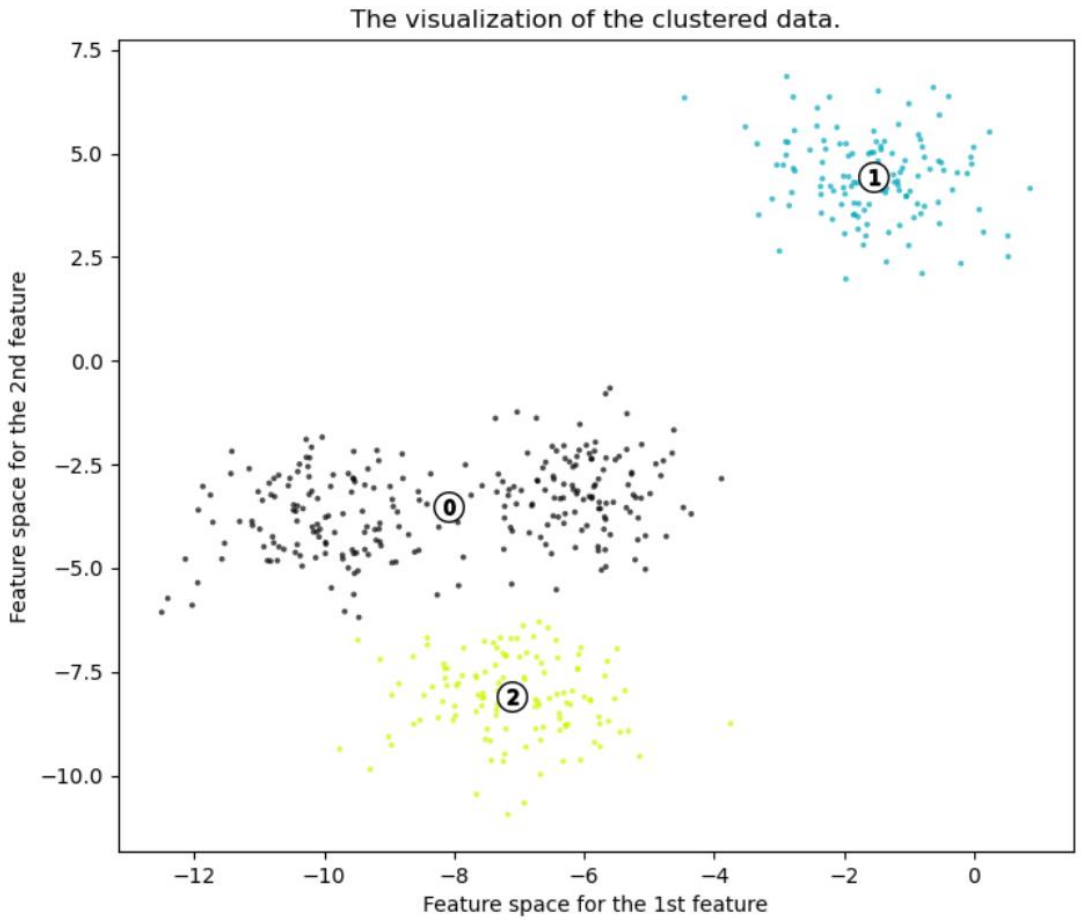
The visualization of the clustered data.
Feature space for the 2nd feature
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
1
0
2
−12
−10
−8
−6
−4
−2
0
Feature space for the 1st feature

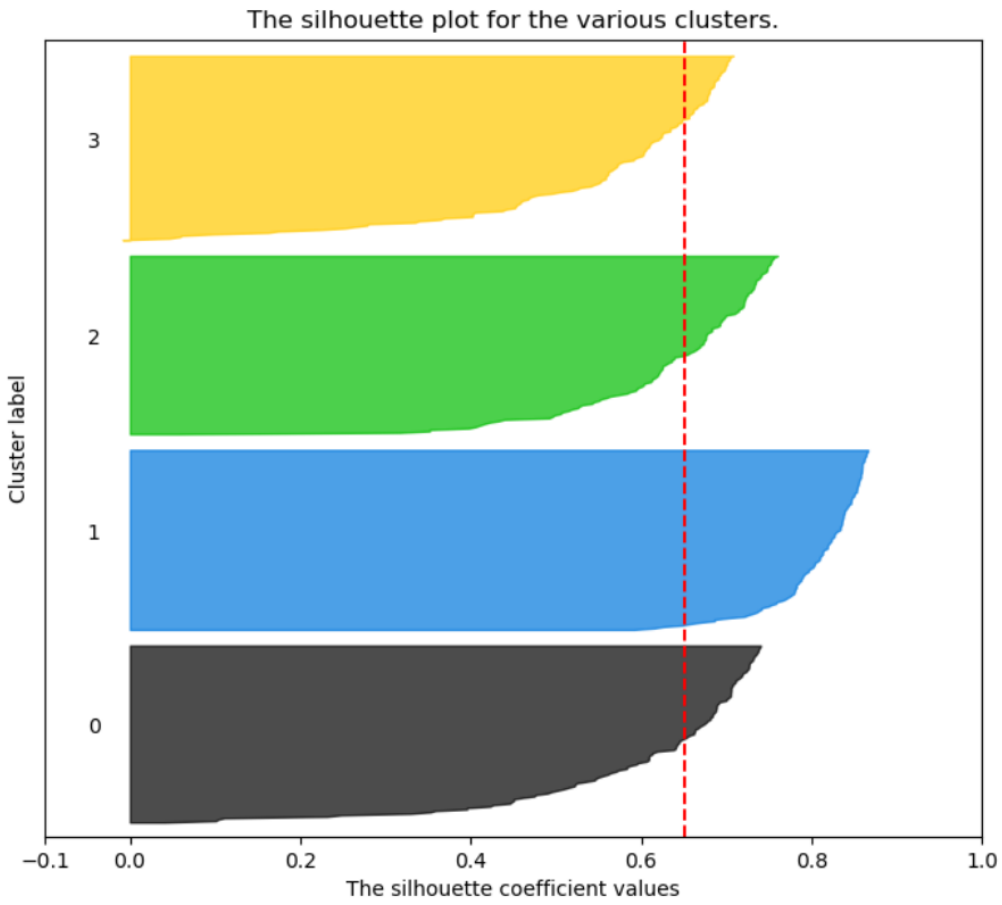
The silhouette plot for the various clusters.
Cluster label
3
2
1
0
−0.1
0.0
0.2
0.4
0.6
0.8
1.0
The silhouette coefficient values

The visualization of the clustered data.
Feature space for the 2nd feature
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
−12
−10
−8
−6
−4
−2
0
Feature space for the 1st feature
1
0
3
2

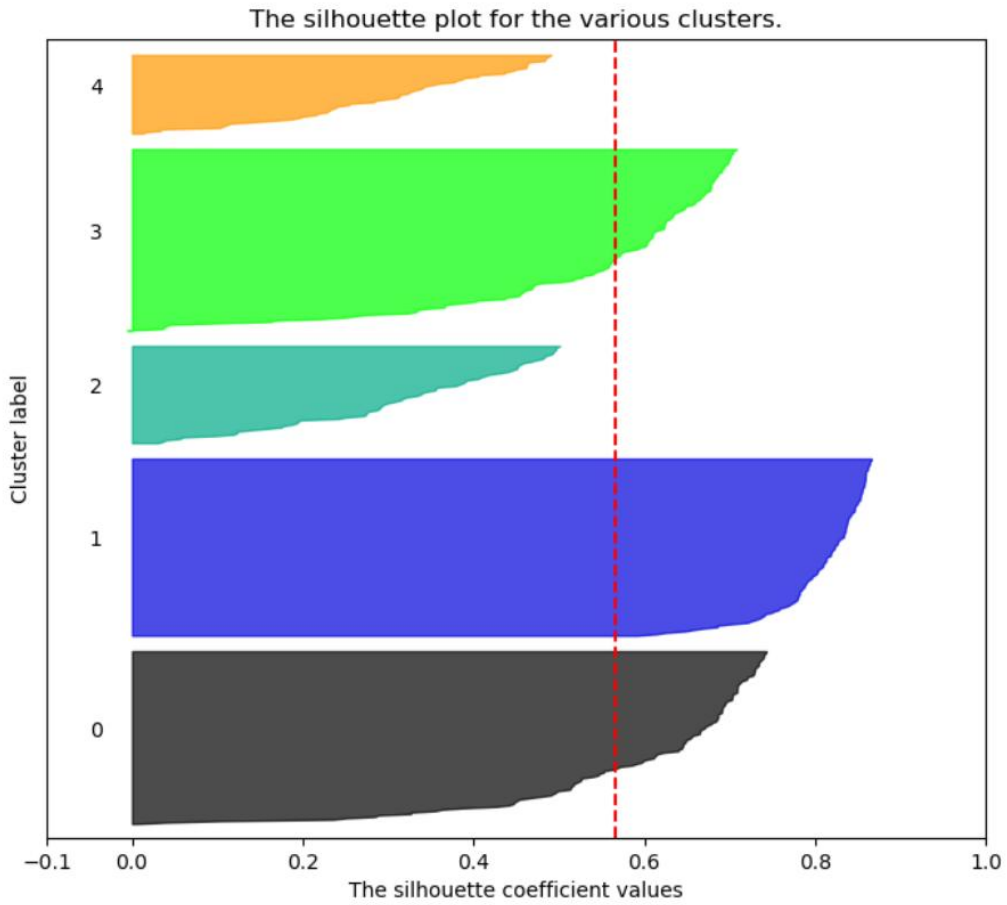
The silhouette plot for the various clusters.
Cluster label
4
3
2
1
0
−0.1
0.0
0.2
0.4
0.6
0.8
1.0
The silhouette coefficient values

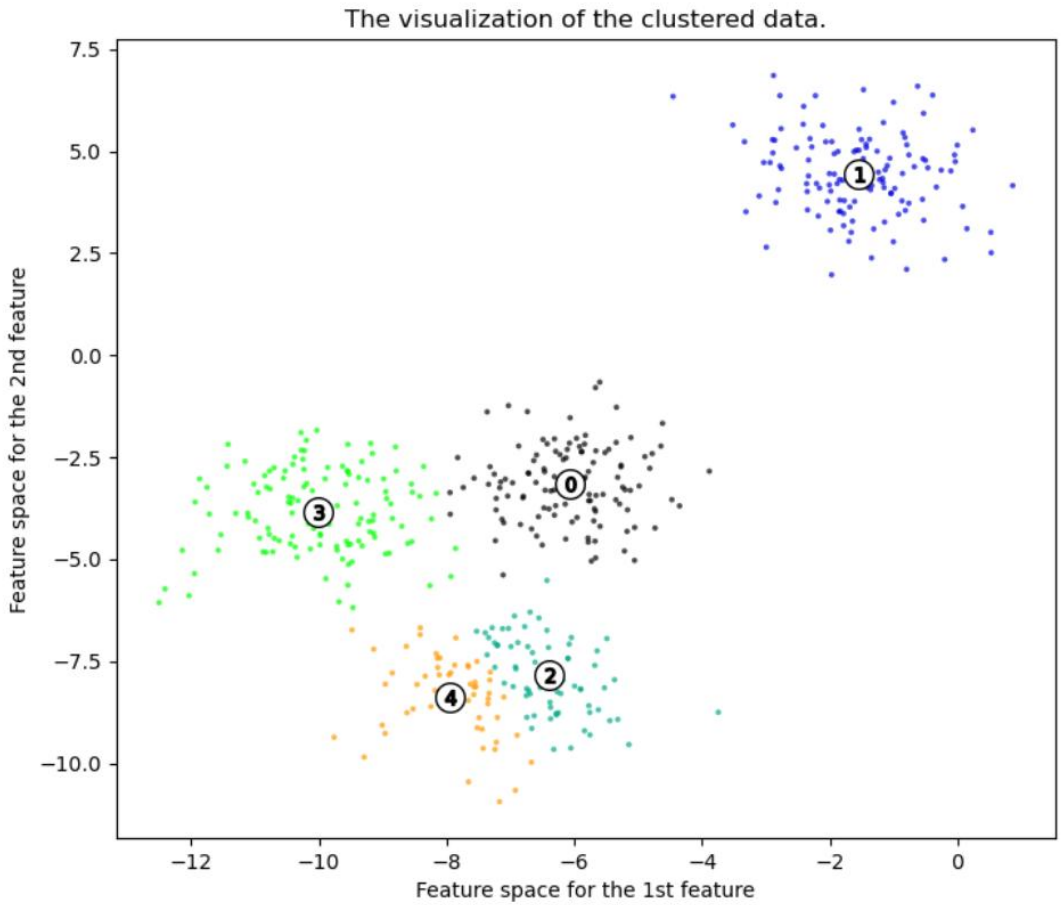
The visualization of the clustered data.
Feature space for the 2nd feature
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
−12
−10
−8
−6
−4
−2
0
Feature space for the 1st feature
1
0
3
2
4

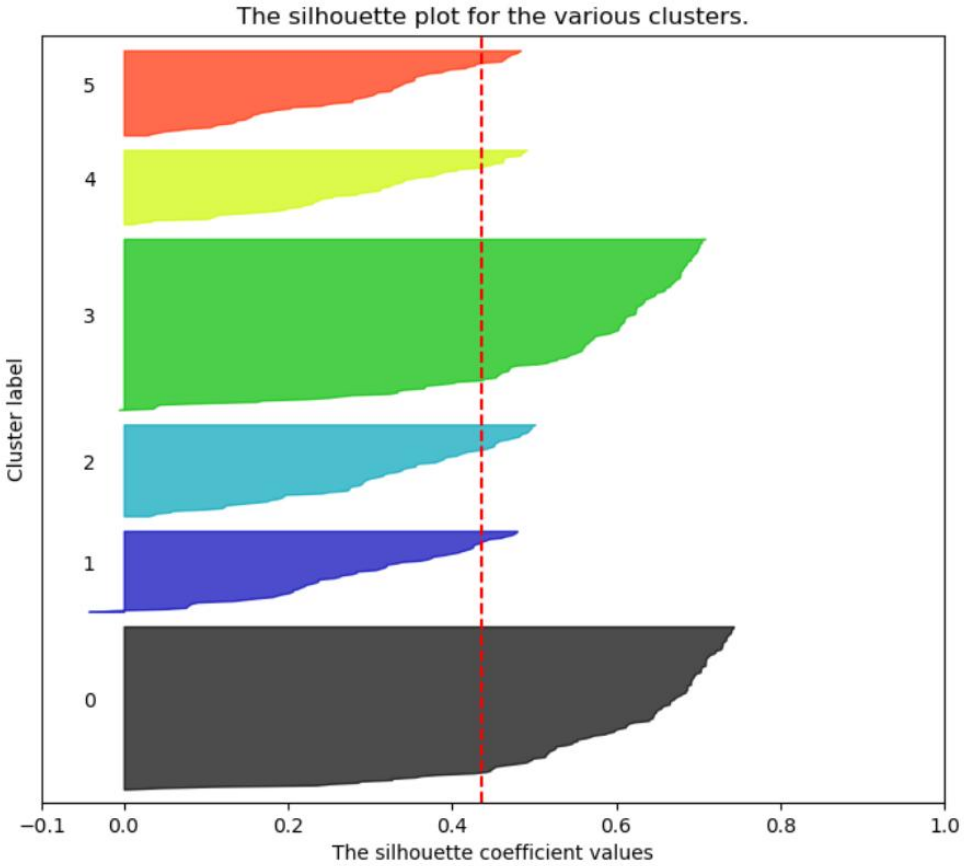
The silhouette plot for the various clusters.
Cluster label
5
4
3
2
1
0
−0.1
0.0
0.2
0.4
0.6
0.8
1.0
The silhouette coefficient values

The visualization of the clustered data.
Feature space for the 2nd feature
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
−12
−10
−8
−6
−4
−2
0
Feature space for the 1st feature
1
5
0
3
2
4

Analytics Descriptivo

01 Cual es el objetivo?

02 Que datos estan disponibles?

03 Que calidad tienen?

04 Que metricas son relevantes?

05 Quienes son los usuatios?

Desarrollo de modelos

01 Objetivo y uso

02 Identificar fuente de datos

03 Tipo de modelo

04 Benchmark & Metricas

05 Monitoreo

Desarrollo de modelos

01 Objetivo y uso

- Identificar el problema a atacar
- Simplificar el problema tanto como se pueda

Desarrollo de modelos

02 Identificar fuente de datos

- Identificar y recolectar de datos disponibles
- Limpieza de datos
- Análisis exploratorio de datos

Desarrollo de modelos

03 Tipo de modelo

- Identificar el modelo correcto para el problema y los datos

Desarrollo de modelos

04 Benchmark & Metricas

- Definir métrica a mejorar
- Calcular benchmark
- Que quiere decir mejorar

Desarrollo de modelos

05 Monitoreo

- Como voy a evaluar que siga sirviendo

Ciclo de Modelos

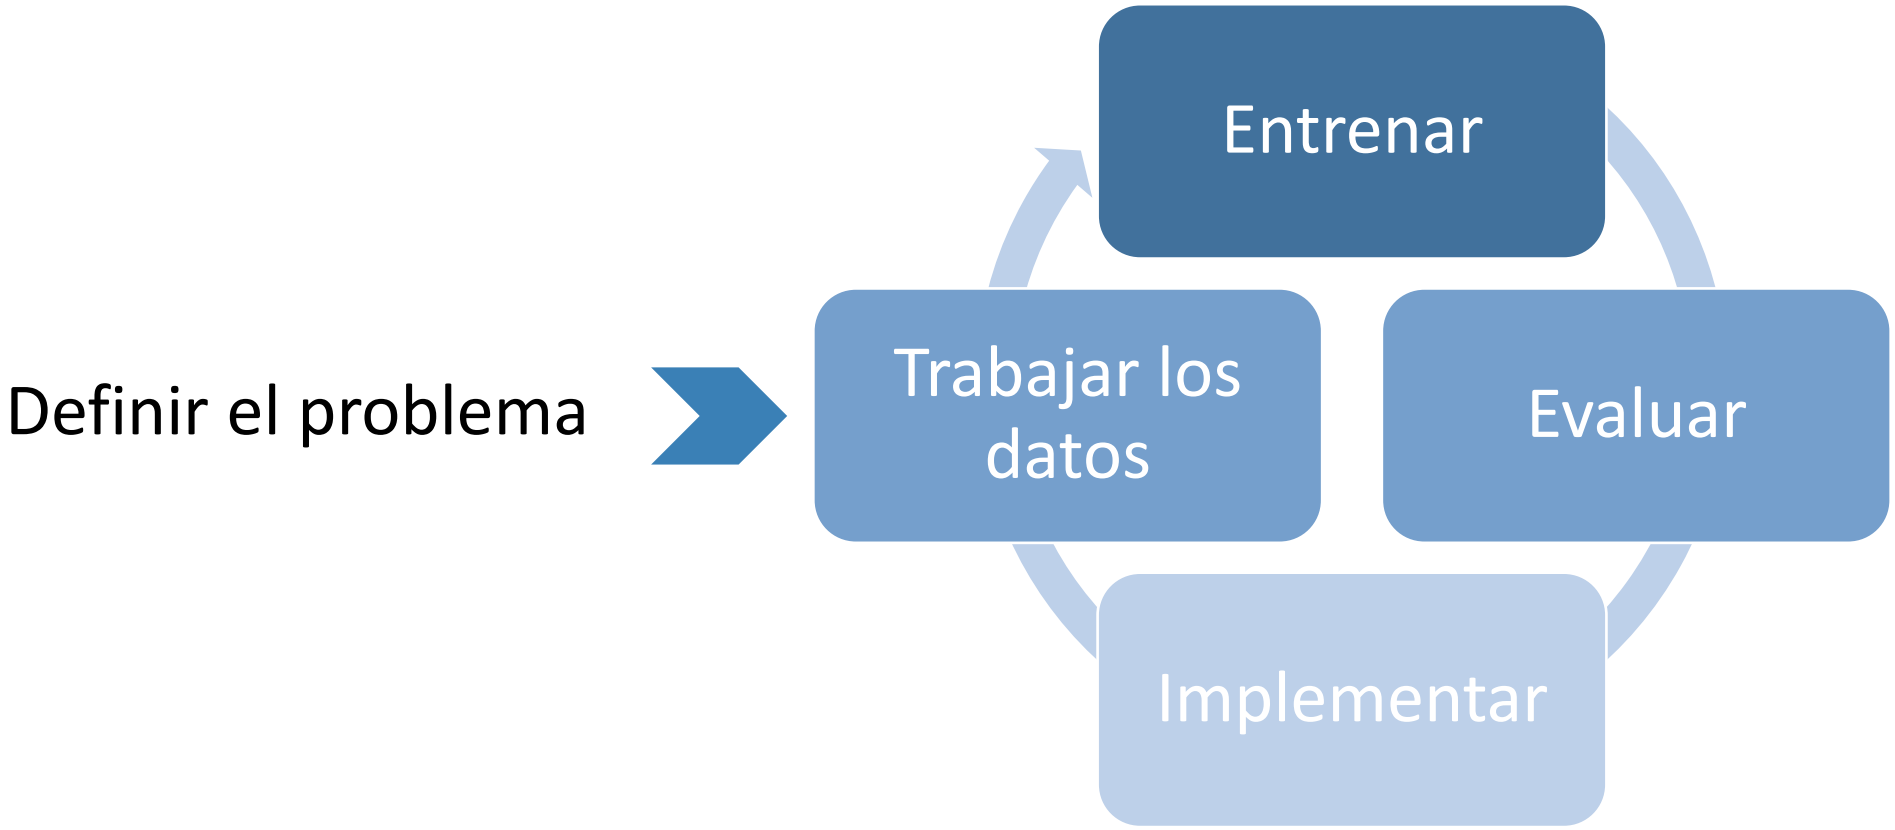

Navaja de Occam

Principio de Parsimonia

“En igualdad de condiciones, quedarse con el modelo mas sencillo”

Balance entre precisión y generalización:

- Evita overfitting
- Mejor inrepretabilidad

“Los modelos envejecen”

Los datos son dinámicos

Los modelos se arman en datos medidos:

- Si los datos cambian los coeficientes dejan de ajustar.
- Revisar y actualizar los modelos periódicamente!

“Los modelos envejecen”

- Predecir comportamiento de clientes.

El mercado cambia con el tiempo, las preferencias cambian, y los competidores tambien. Hay que reevaluar periodicamente. Agregar datos nuevos.

- Clasificar imágenes médicas (e.g x-ray or MRI), si el modelo funciona bien y la tecnología no cambia, envejece menos.

Otros modelos

- Sistemas de recomendación
- SVM
- Redes Neuronales
- Text Analytics
- Sentiment Analysis
- Modelos Generativos

Sistemas de recomendación

Enfoques:

- Filtrado colaborativo: personas que hicieron lo mismo
- Filtrado basado en contenido: productos que se consumen juntos
- Recomendaciones contextuales: basado en búsquedas
- Embeddings

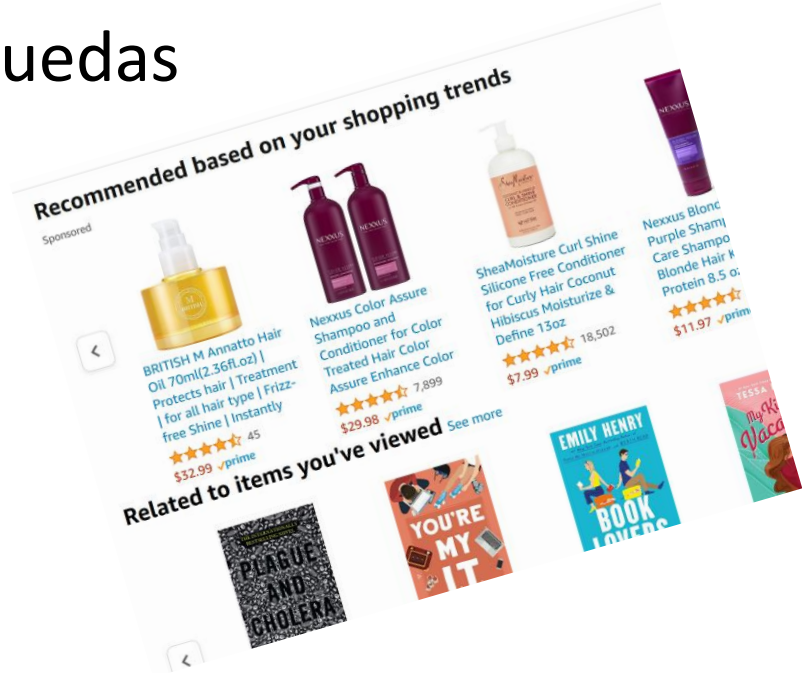

Support Vector Machine

- Aprendizaje supervisado
- Clasificación
- No es tan interpretable

Que hace?

- Maximizar margen entre clases → mas robustez
- Usa vectores de soporte par definir la frontera

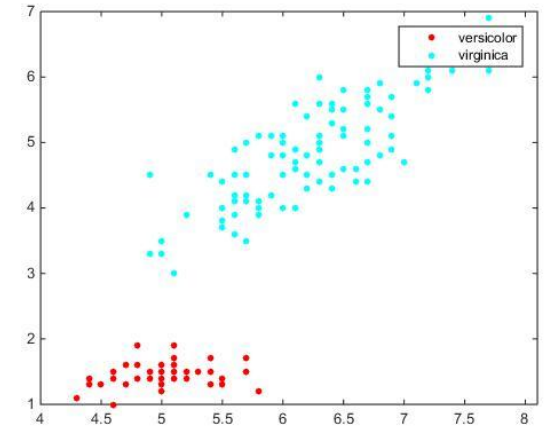

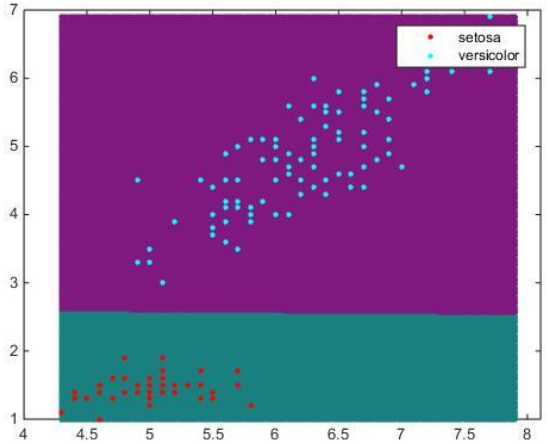

Redes Neuronales

- Aprendizaje supervisado/no supervisado
- Clasificación/Regresión
- Caja negra

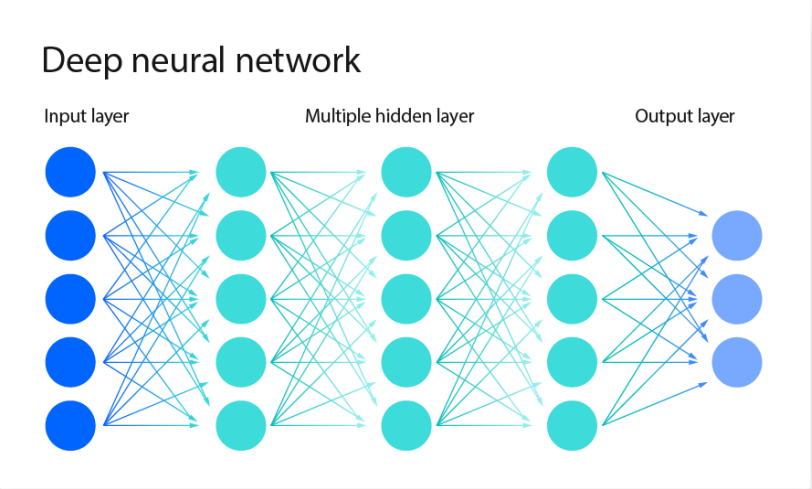

Porque son útiles?

- Aprenden **relaciones no lineales** y complejas
- Funcionan bien con **grandes volúmenes de datos**
- Se adaptan a una gran variedad de problemas

CUIDADO CON SOBREAJUSTE

Text Analytics – Sentiment Analysis

Objetivos

- Feedback de consumidores
- Comentarios en redes
- Atención digital
- Identificar temas claves

Se pueden usar los modelos que vimos

Gen AI

Crear contenido nuevo (texto, imágenes, código, audio, etc.)

¿Para qué se usa en Analytics?

- Generación automática de **informes y dashboards**
- Análisis y resumen de grandes volúmenes de texto
- Generación de contenido

Requiere validación humana

Porque usarlo?

- Acelera tareas rutinarias
- Interacción con lenguaje natural

TEXT ANALYTICS

Text Analytics

- Extraer información a partir de volúmenes de texto.
- Transformar texto no estructurado en un formato estructurado.
- Comprender contenido.
- Aplicar técnicas de ML, estadística y NLP para interpretar los datos.

Preprocesamiento, extraer features y aplicar modelo

Aplicaciones

- Clustering (ej: Clasificacion de logs de mantenimiento).

- Concept or Entity Extraction : reconocer y clasificar elementos del texto en categorías predefinidas, como nombre de personas, organizaciones, expresiones.

- Análisis de Sentimiento.

- Identificar temas clave dentro de los datos.

De donde se obtienen los texto?

Web Scraping / APIs

Comentarios ingresados en mi pagina

Encuestas

Transcipts de llamadas

Proceso de Text Analytics

Para aplicar los modelos necesitamos convertir el texto en datos numéricos/en una matriz.
Definir representaciones reducidas de los textos.

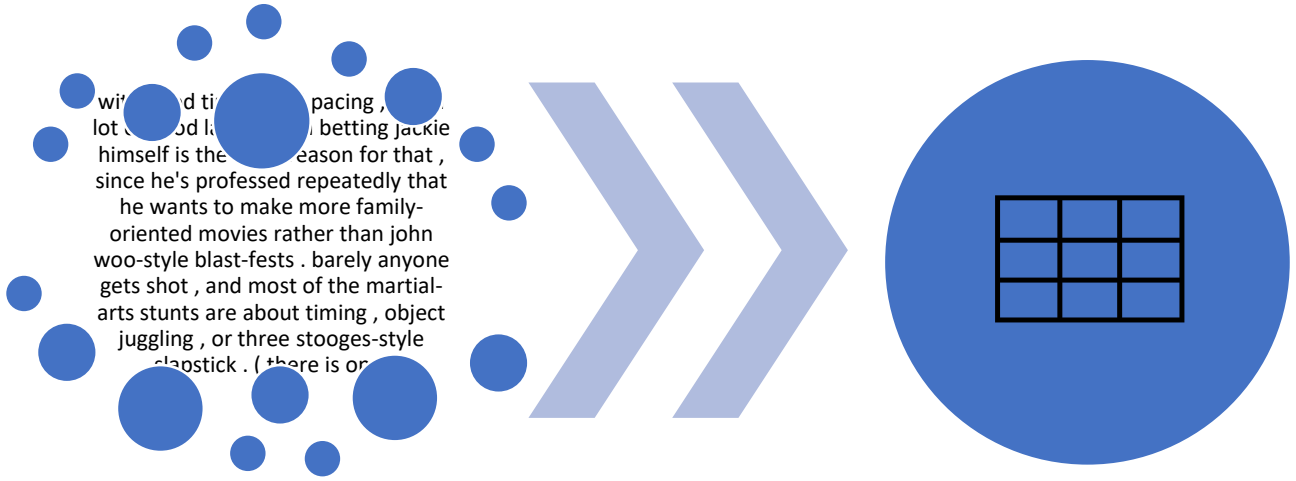

Texto

Matriz numérica

Proceso de Text Analytics

Para aplicar los modelos necesitamos convertir el texto en datos numéricos/en una matriz.
Definir representaciones reducidas de los textos.

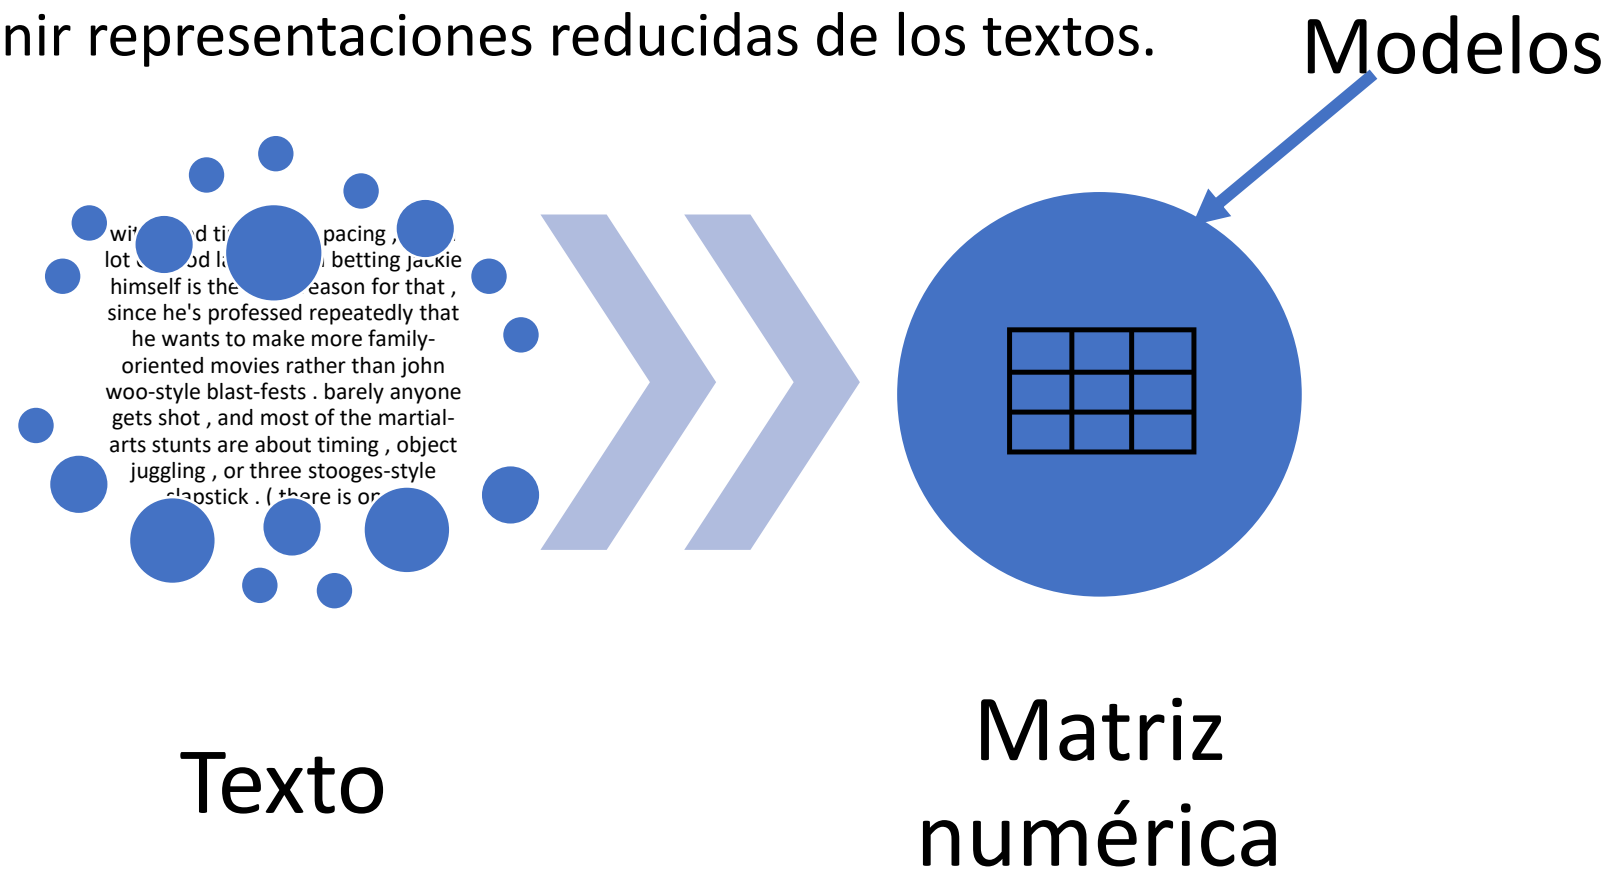

Preprocesamiento

- Limpieza del texto (mayúsculas, símbolos, stopwords)
- Tokenization: separar el texto en unidades menores
- Stemmization: llevar a la raíz (verbos conjugados)
- Lematization: reduce a la palabra base (bueno, mejor)

Feature Extraction

- Métricas (frecuencia de palabras, largo)
- N-gramas: ayuda a capturar el sentido
- Indicadores semánticos
- Bag of words (conjunto de palabras con su frecuencia)
- Embeddings (modelos preentrenados)
- Construcción de vocabulario

Proceso completo

- Web Scraping
- Transcripts
- Comentarios

- Limpieza
- Feature Extraction
- Entity Recognition

- Dashboards
- Modelo Supervisado
- No supervisdo
- Modelos de Lenguaje

Nube de palabras

- Identifica las palabras mas repetidas
- Las grafica en función de frecuencia

Ejemplo Python

```python

for i in range(0,200):
    A = text[i]
    A = A.replace('\n', '')
    A = A.replace('*', '')
    A = A.replace(',', '')
    A_words = A.split(" ")
    #corpus.append(A_words)

from sklearn.feature_extraction.text import CountVectorizer

max_features = 150 # max_features dimension reduction
count_vectorizer = CountVectorizer(stop_words = "english",max_f
# stop_words parameter = automatically remove all stopwords
# lowercase parameter
# token_pattern removing other karakters like .. !

sparce_matrix = count_vectorizer.fit_transform(text).toarray()

print("Most used {} words: {}".format(max_features,count_vector


# %%
```

Sentiment Analysis-Opinion Mining

- Feedback Consumidores
- Comentarios en Redes
- Conversaciones

Sentiment Analysis

Sentiment Analysis

Definir/Buscar diccionarios

Modelar

Prompts a modelos preentrenados

POSITIVAS

NEGATIVAS

Embeddings

Transformaciones

Los datos como vienen no se pueden usar

- Ciudad → recodificación

Ciudad	Ciudad codificada	One hot
Bs As	1	1,0,0,0
Tandil	2	0,1,0,0
Córdoba	3	0,0,1,0
Bariloche	4	0,0,0,1

Embeddings

Otra forma de representar data

Representaciones numéricas de baja dimensión
Capturan similitudes (distancias, significado, …)

Ciudad	Embedding
Bs As	[0.5, 0.8, 0]
Tandil	[0.5, 0.2, 0]
Córdoba	[0.2, 0.9, 0.3]
Bariloche	[0.1, -0.4, 0.3]

Embeddings

Otra forma de representar data: Palabras, Usuarios, Productos

Cómo los hago?

- Usar embeddings ya preentrenados
- Entrenar uno

Qué hacer con los embeddings?

- Usarlos como input en un modelo
- Clustering
- Visualización